OPENCLASSROOMS

Formation Ingénieur Machine Learning

Projet:
Anticipez les besoins en consommation de bâtiments

25 Mars 2023

thomas.durandtexte@protonmail.com

CONTEXTE

Seattle

Seattle

Ville **neutre** en
émissions carbone
d'ici **2050**

Seattle

Ville **neutre** en **émissions carbone** d'ici **2050**

On s'intéresse :

Seattle

Ville **neutre** en **émissions carbone** d'ici **2050**

On s'intéresse :

à la consommation d'**énergie**

Seattle

Ville **neutre** en **émissions carbone** d'ici **2050**

On s'intéresse :

à la consommation d'**énergie**

aux émissions de **CO_2**

Seattle

Ville **neutre** en
émissions carbone
d'ici **2050**

On s'intéresse :

à la consommation d'**énergie**

aux émissions de **CO_2**

des bâtiments
non destinés à l'habitation

Seattle

Ville **neutre** en
émissions carbone
d'ici **2050**

On s'intéresse :

à la consommation d'**énergie**

aux émissions de **CO_2**

des bâtiments
non destinés à l'habitation

On a:

les **relevés 2016**

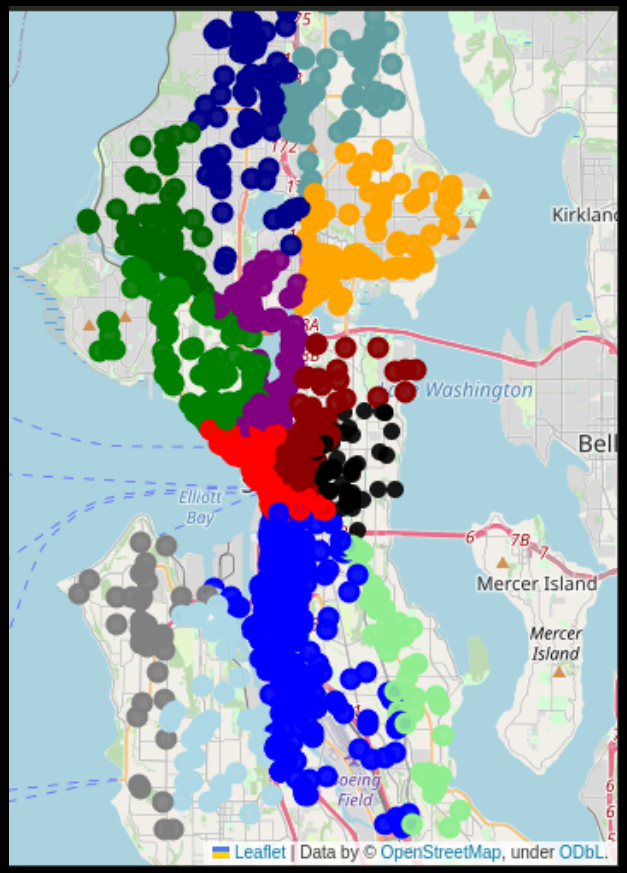
Kirkland
Washington
Bell
Elliott Bay
Mercer Island
Mercer Island
Leaflet | Data by © OpenStreetMap, under ODbL.

3376 entrées:
1708 résidentielles
1668 non résidentielles

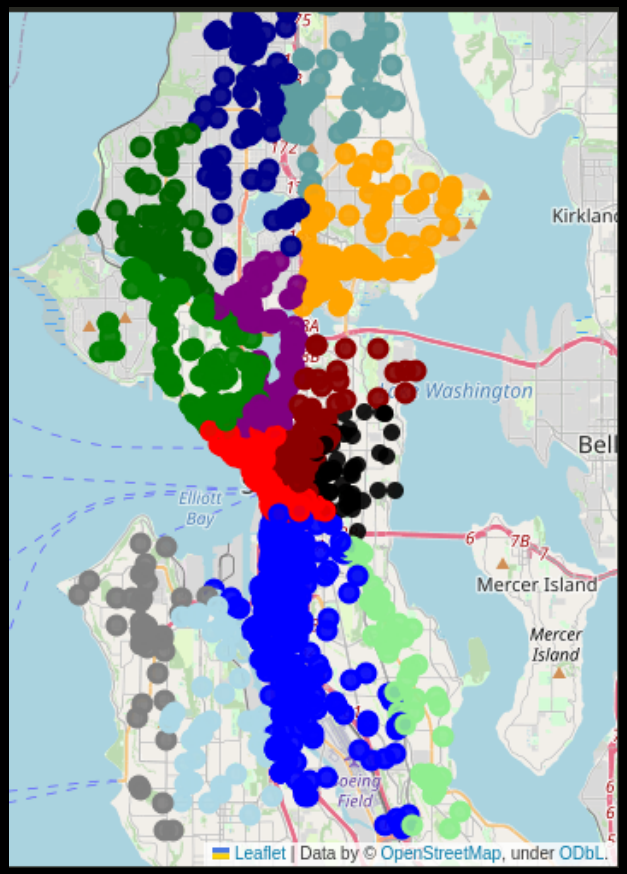

3376 entrées:
1708 résidentielles
1668 non résidentielles

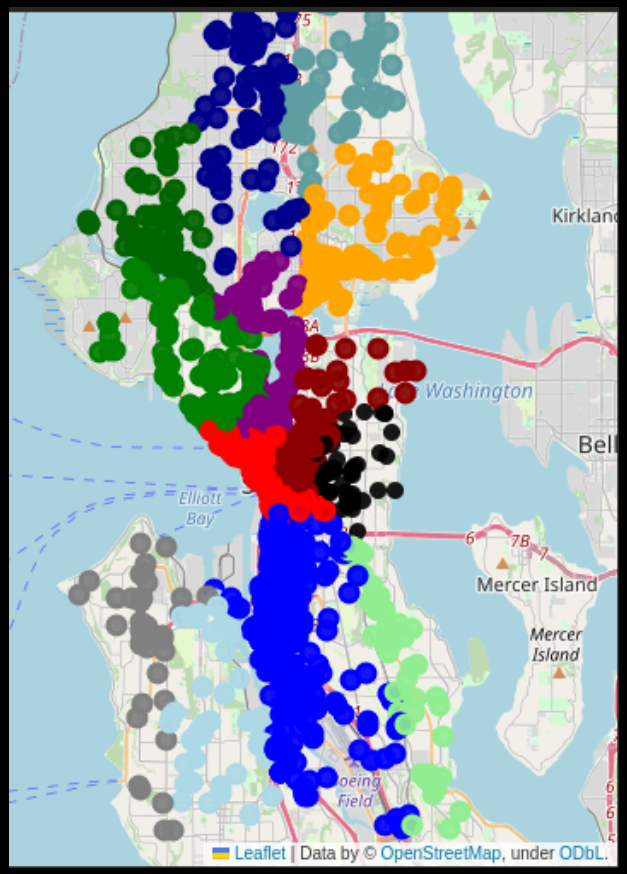

45 variables

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

3376 entrées:
1708 résidentielles
1668 non résidentielles

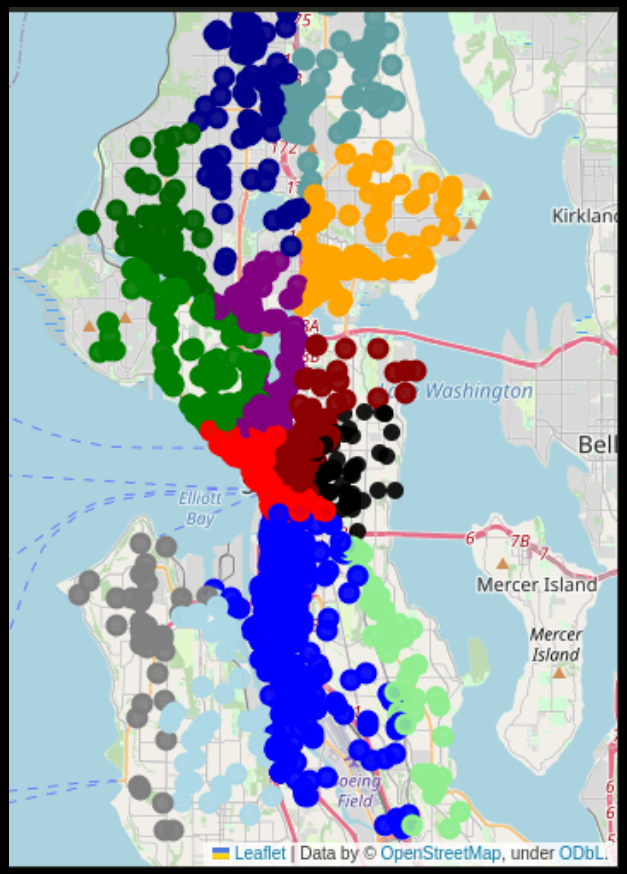

45 variables

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

Dates

- date des données
- date de construction

3376 entrées:
1708 résidentielles
1668 non résidentielles

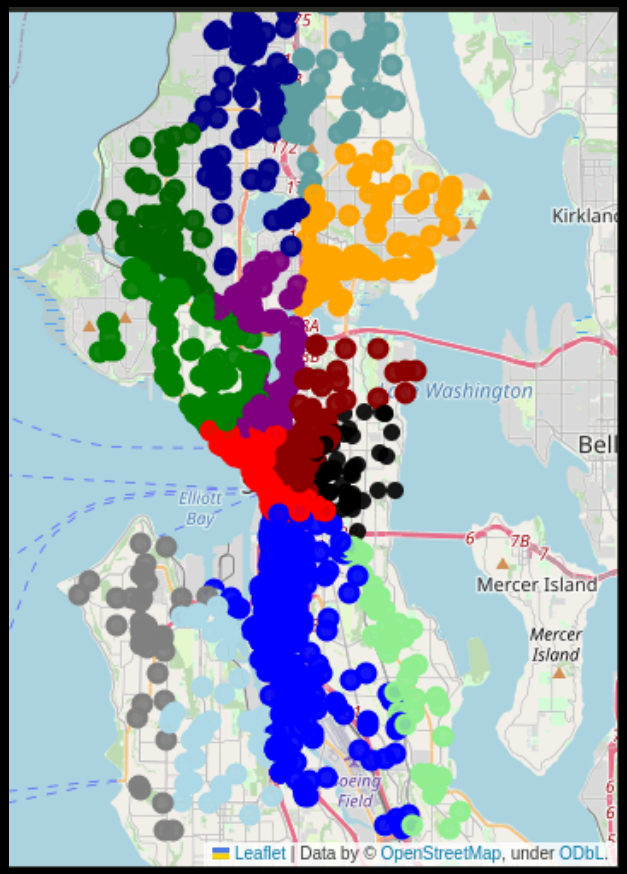

45 variables

3376 entrées:
1708 résidentielles
1668 non résidentielles

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

Dates

- date des données
- date de construction

Dimensions

- nombre de bâtiments
- nombre de niveaux
- surface
- surface parking

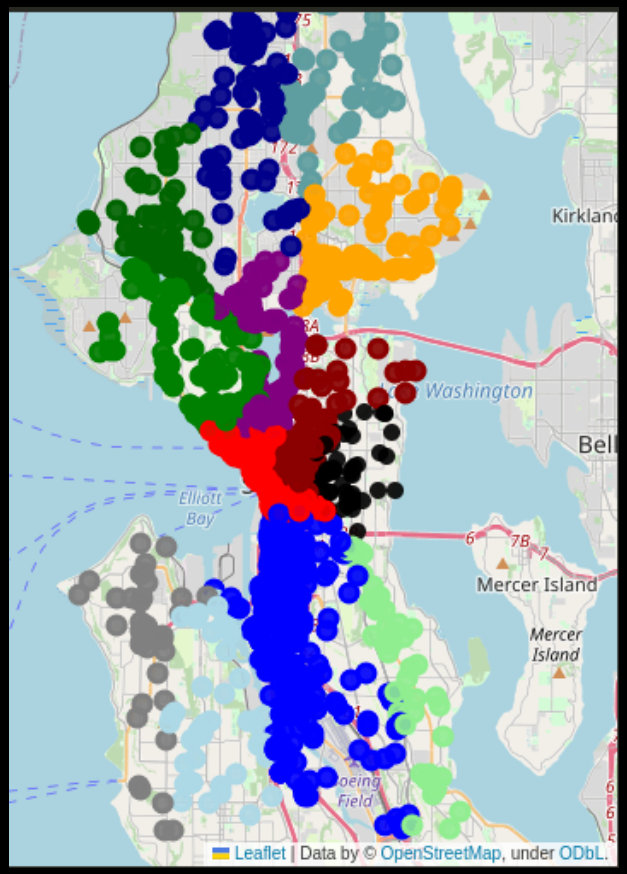

45 variables

3376 entrées:
1708 résidentielles
1668 non résidentielles

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

Dates

- date des données
- date de construction

Dimensions

- nombre de bâtiments
- nombre de niveaux
- surface
- surface parking

Certification

- EnergySTARSCORE
- dates de certification

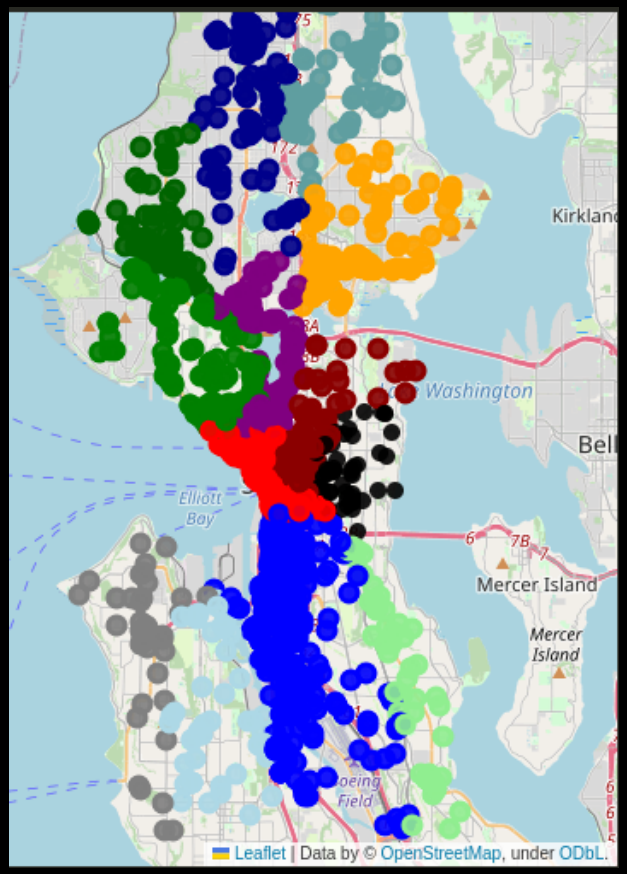

45 variables

3376 entrées:
1708 résidentielles
1668 non résidentielles

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

Dates

- date des données
- date de construction

Dimensions

- nombre de bâtiments
- nombre de niveaux
- surface
- surface parking

Certification

- EnergySTARSCORE
- dates de certification

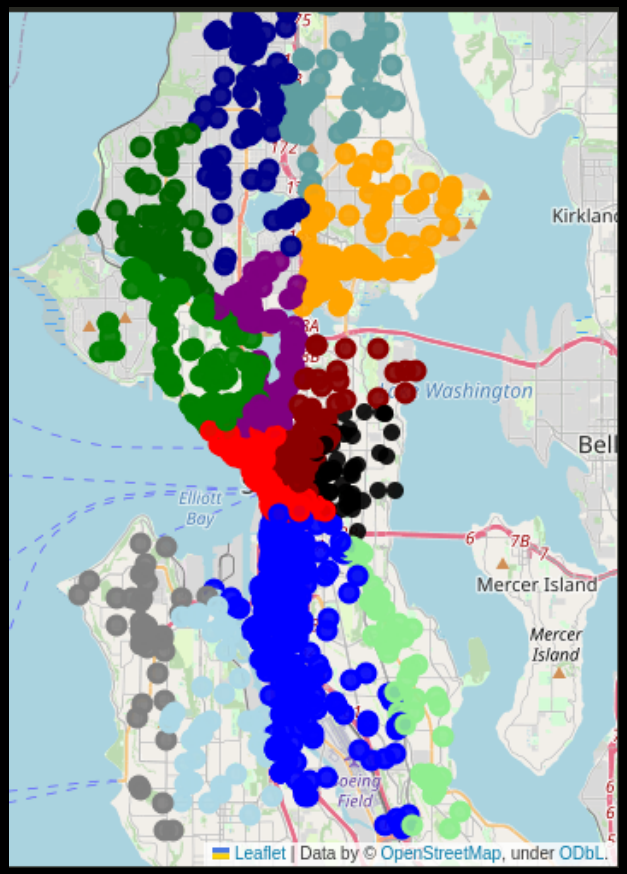

45 variables

Utilisations

- type de propriété
- type de bâtiment
- utilisations principales
- surface par utilisation
- ...

3376 entrées:
1708 résidentielles
1668 non résidentielles

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

Dates

- date des données
- date de construction

Dimensions

- nombre de bâtiments
- nombre de niveaux
- surface
- surface parking

Certification

- EnergySTARSCORE
- dates de certification

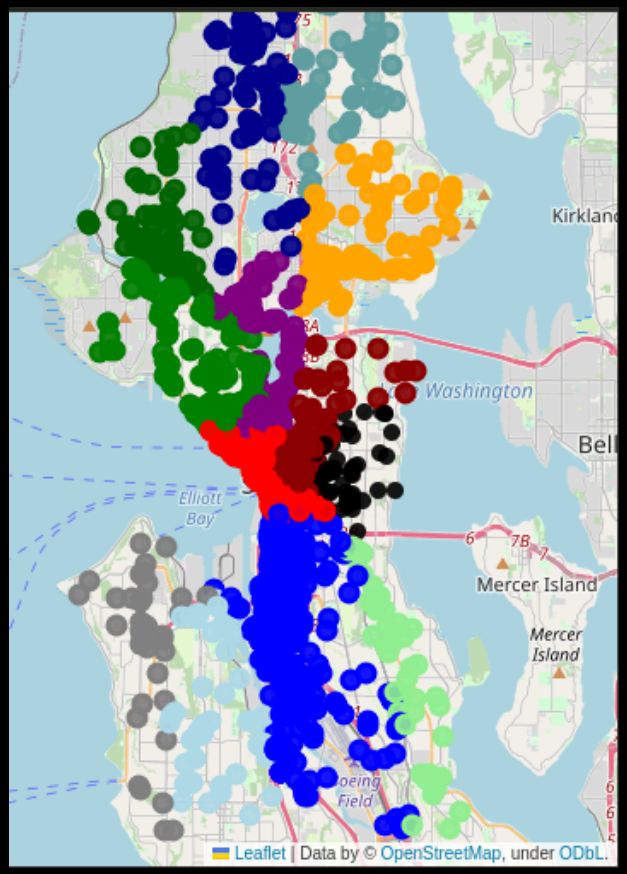

45 variables

Utilisations

- type de propriété
- type de bâtiment
- utilisations principales
- surface par utilisation
- ...

Consommation & émissions

- conso. elec./gas/steam
- consommation totale
- émissions totales
- ...

3376 entrées:
1708 résidentielles
1668 non résidentielles

Identification & localisation

- id
- nom
- adresse
- zipcode
- ...

Dates

- date des données
- date de construction

Dimensions

- nombre de bâtiments
- nombre de niveaux
- surface
- surface parking

Certification

- EnergySTARSCORE
- dates de certification

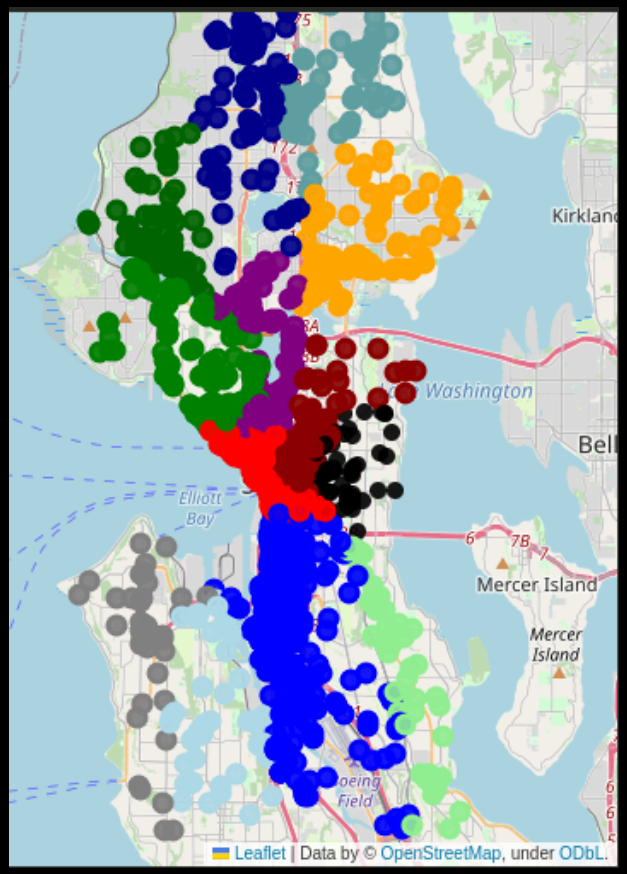

45 variables

Utilisations

- type de propriété
- type de bâtiment
- utilisations principales
- surface par utilisation
- ...

Consommation & émissions

- conso. elec./gas/steam
- consommation totale
- émissions totales
- ...

Autres

- DefaultData
- ComplianceStatus
- Outlier

Relevés

Relevés

→ Modélisation

Relevés

Modélisation → Prédiction

Relevés

Modélisation → Prédiction

Prédiction → **Consommation** totale

Prédiction → **Émissions** totales

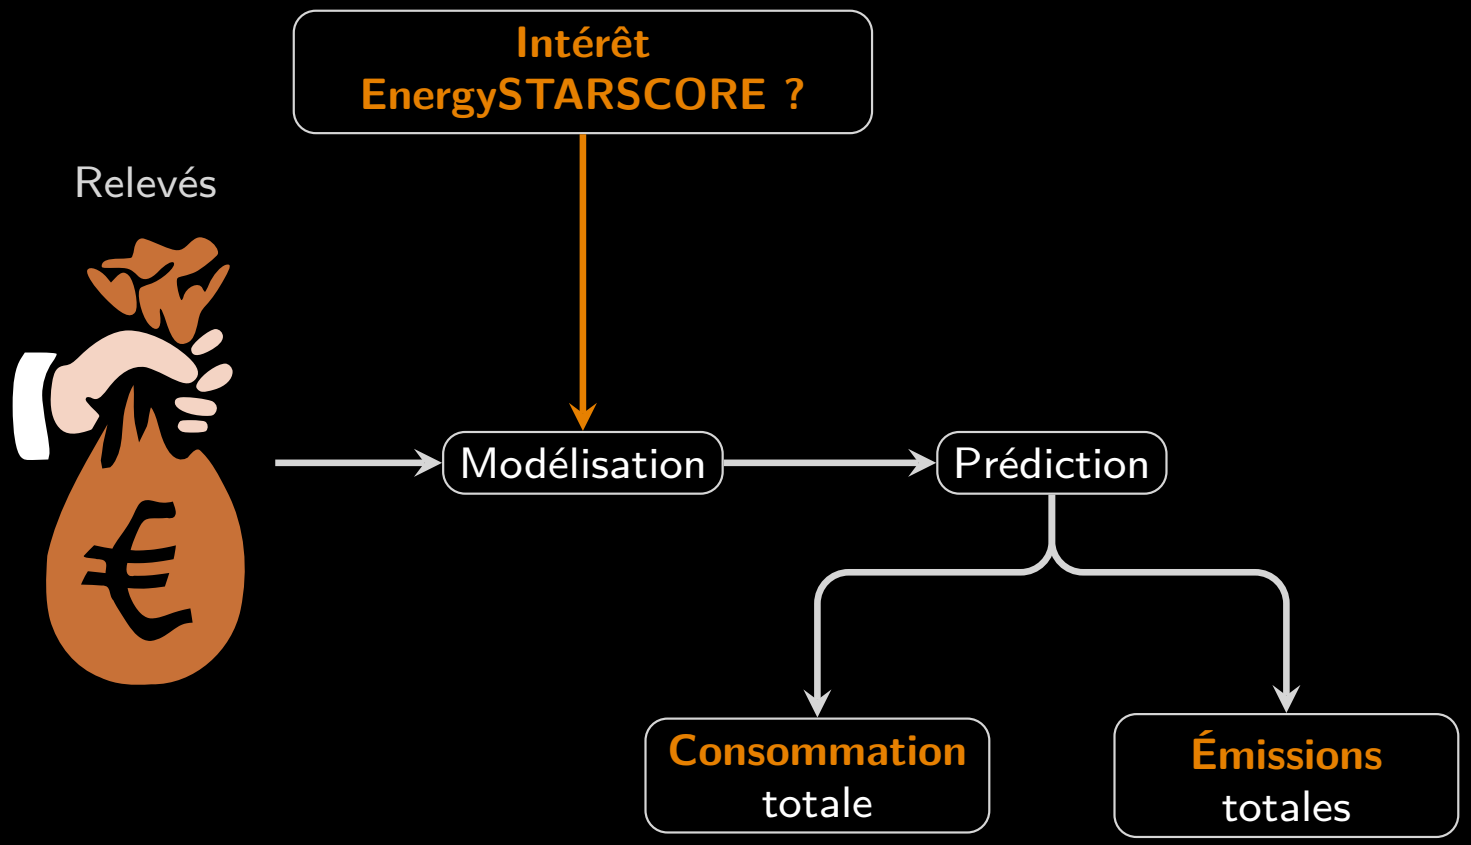
Intérêt
EnergySTARSCORE ?
Relevés
Modélisation
Prédiction
Consommation
totale
Émissions
totales

EXPLORATION DES DONNÉES & DÉFINITION DES VARIABLES CIBLES

EXPLORATION DES DONNÉES & DÉFINITION DES VARIABLES CIBLES

Épuration des données

Suppression des **variables en double**:

Suppression des **variables en double**:

Électricité (kBtu)

Électricité (kWh)

Suppression des **variables en double**:

Électricité (kBtu)

Électricité (kWh)

Gas naturel (kBtu)

Gas naturel (therms)

Suppression des **variables en double**:

- Électricité (kBtu)
- Électricité (kWh)
- Gas naturel (kBtu)
- Gas naturel (therms)
- Consommation totale (kBtu)

Suppression des **variables en double**:

- Électricité (kBtu)
- Électricité (kWh)
- Gas naturel (kBtu)
- Gas naturel (therms)
- Consommation totale (kBtu)

Suppression des **variables en double**:

Électricité (kBtu)

Électricité (kWh)

Gas naturel (kBtu)

Gas naturel (therms)

Consommation totale (kBtu)

Suppression des **entrées "invalides"**:

Suppression des **variables en double**:

Électricité (kBtu)

Électricité (kWh)

Gas naturel (kBtu)

Gas naturel (therms)

Consommation totale (kBtu)

Suppression des **entrées "invalides"**:

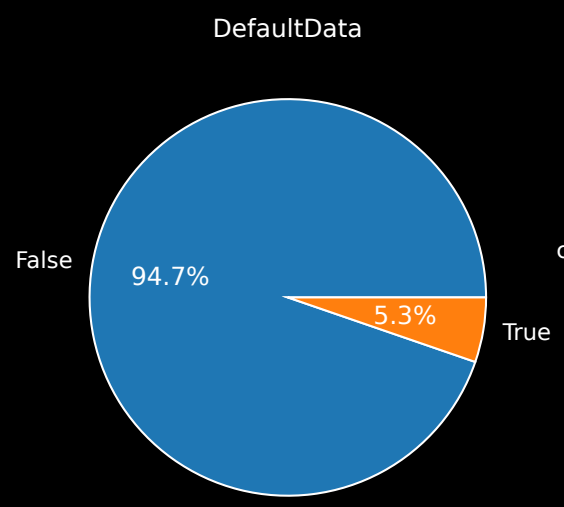

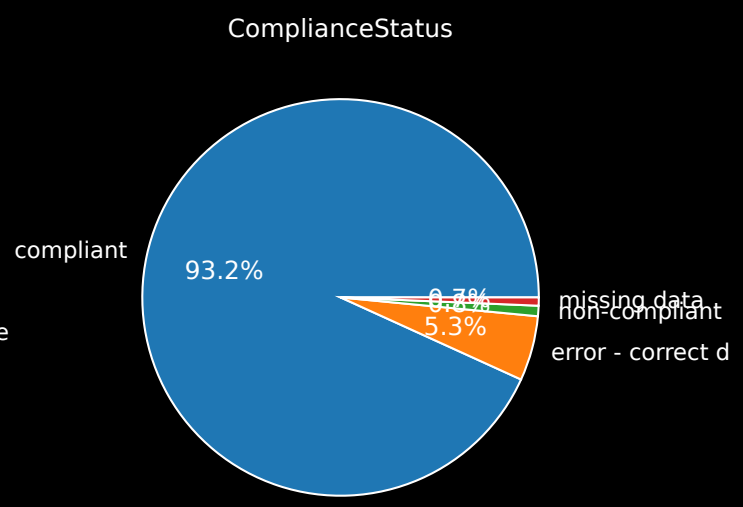

EXPLORATION DES DONNÉES & DÉFINITION DES VARIABLES CIBLES

Vérification des données

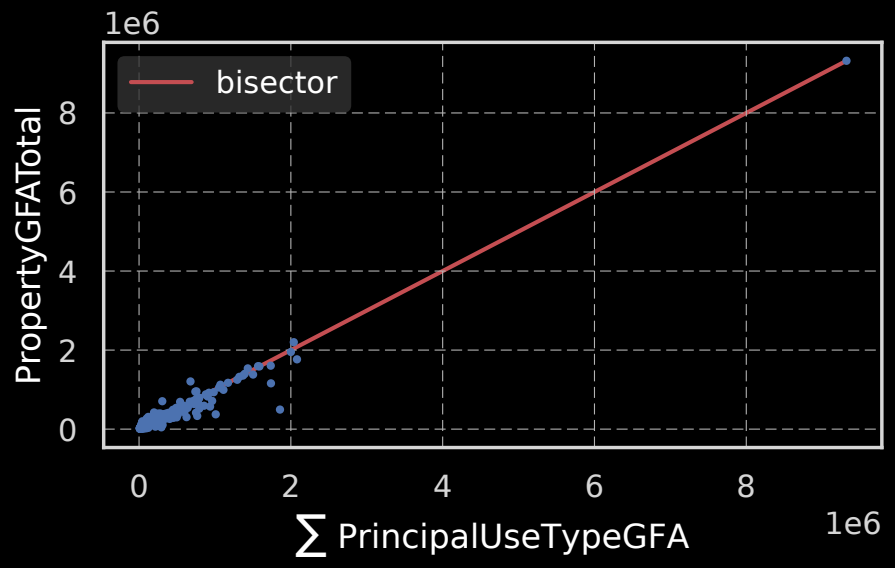
1e6
bisector
PropertyGFATotal
8
6
4
2
0
0
2
4
6
8
1e6
∑ PrincipalUseTypeGFA

Référénce
GFA Buidlings

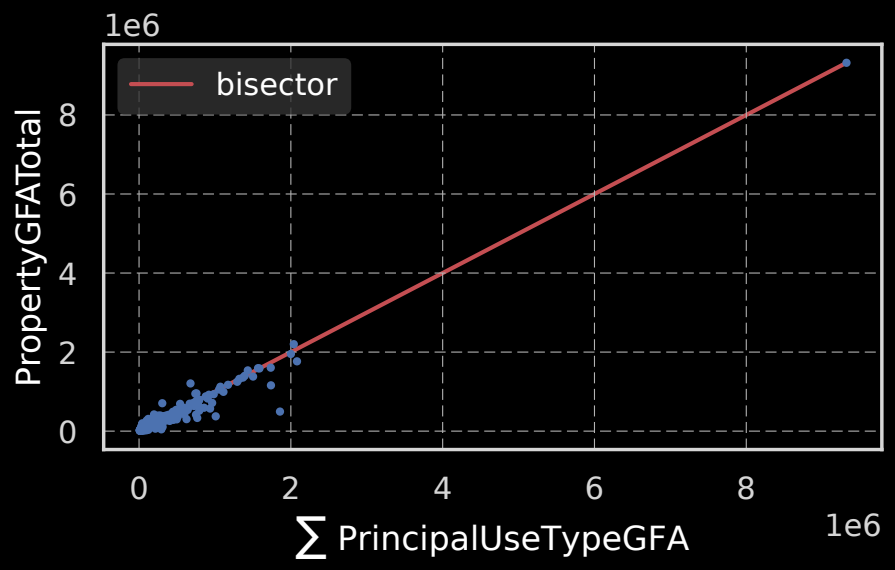

Référénce
GFA Buidlings

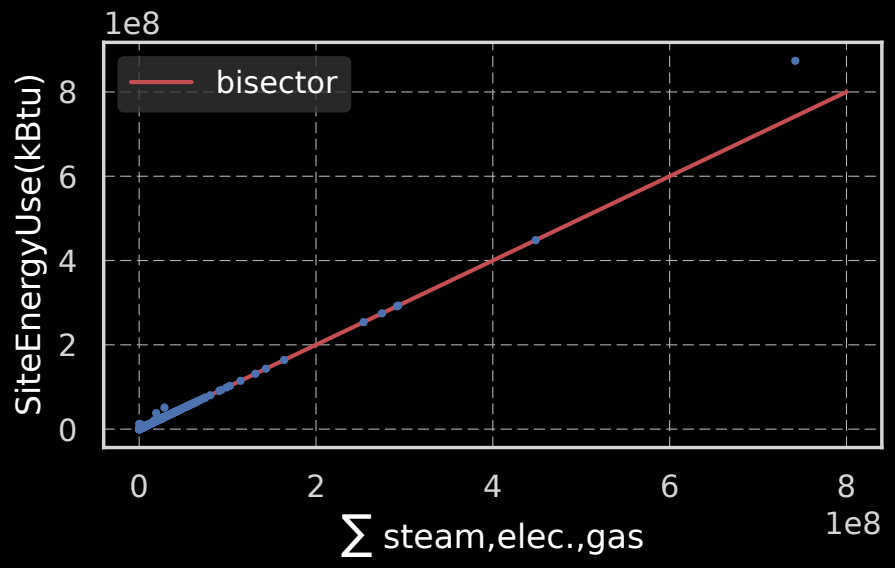

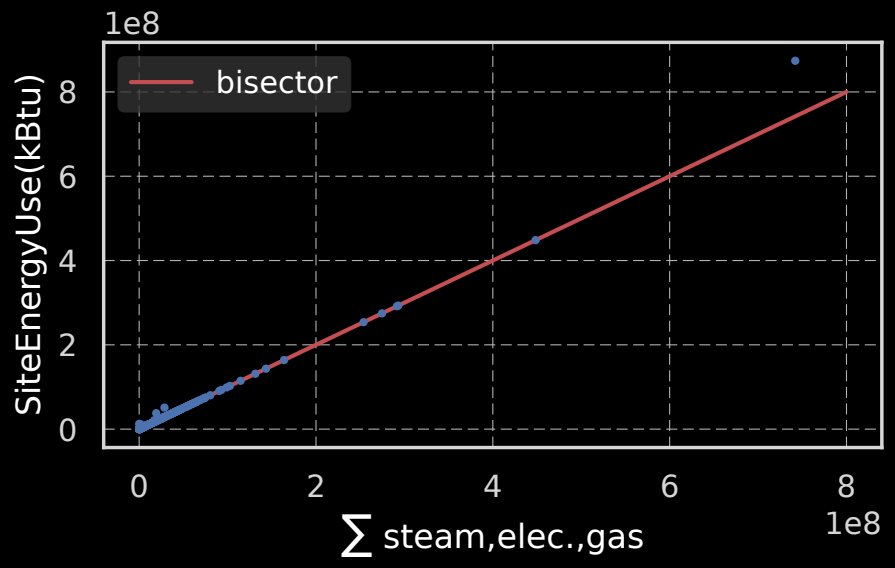

Référénce
GFA Buidlings

Re-calcul consom-
mation totale

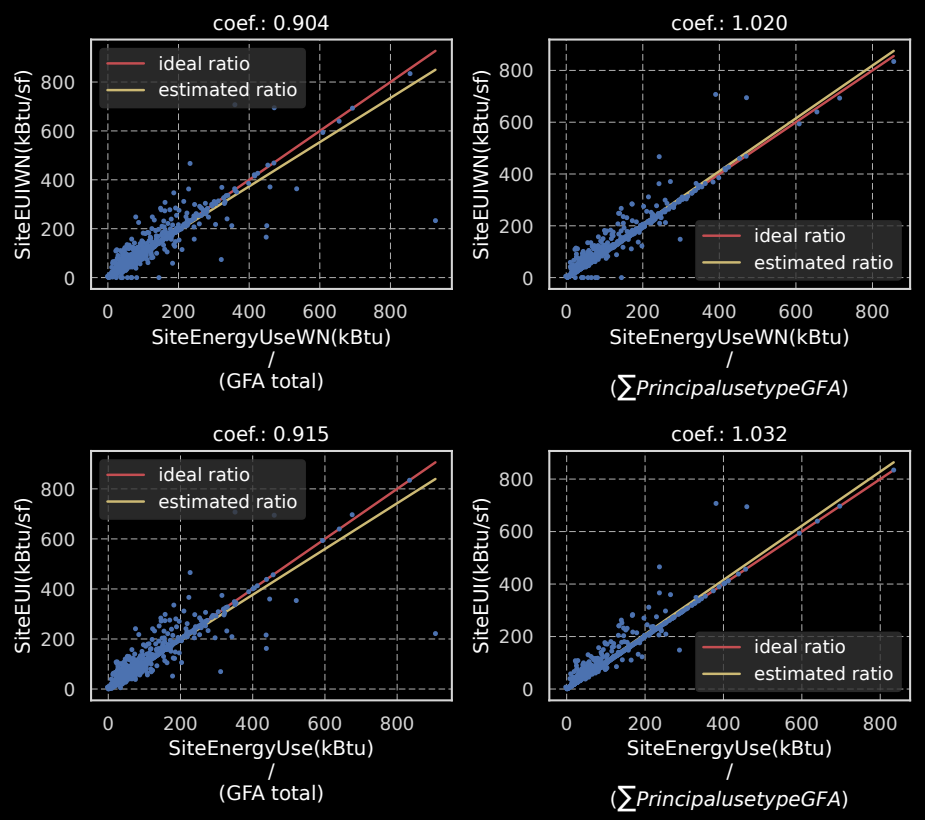

Référénce
GFA Buidlings

Re-calcul consom-
mation totale

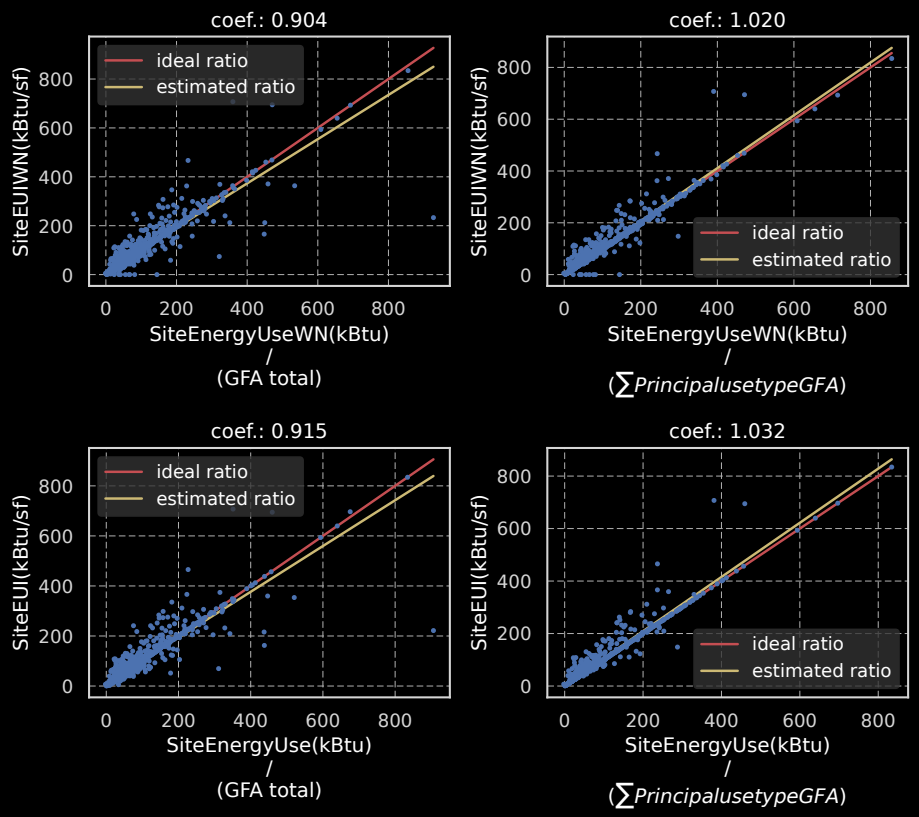

Référénce
GFA Buidlings

Re-calcul consom-
mation totale

Re-calcul consom-
mation surfacique

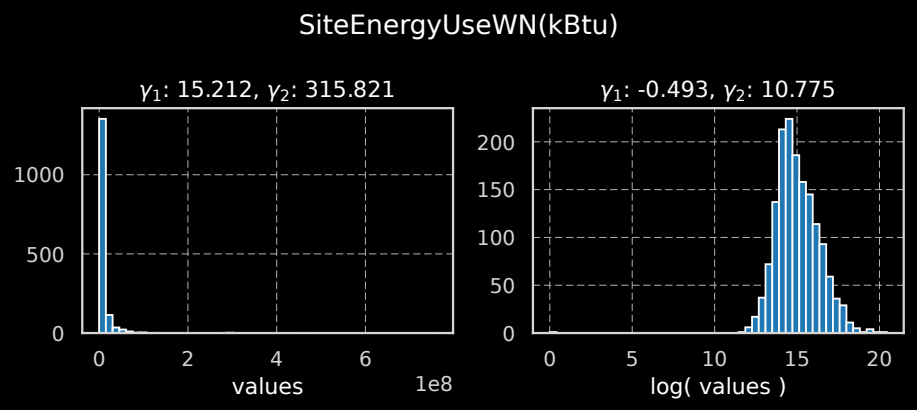

Référénce
GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

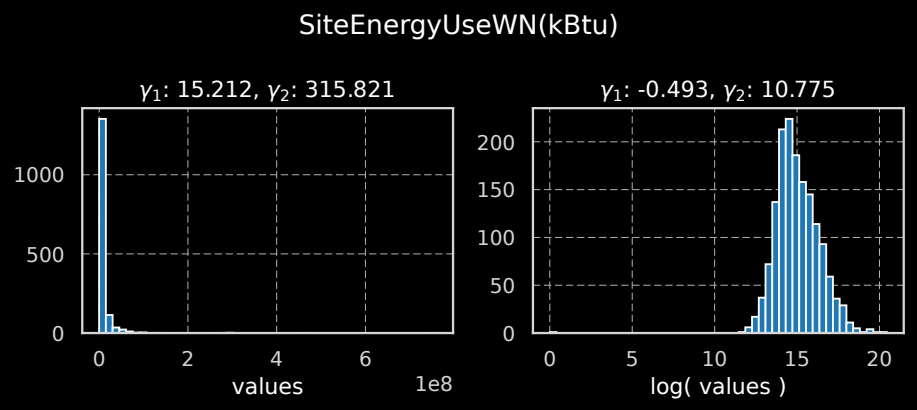

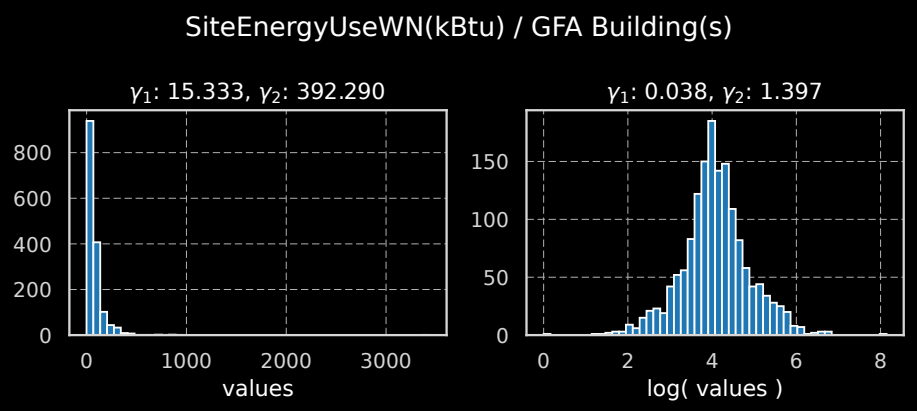

Référénce
GFA Buidlings

Re-calcul consom-
mation totale

Re-calcul consom-
mation surfacique

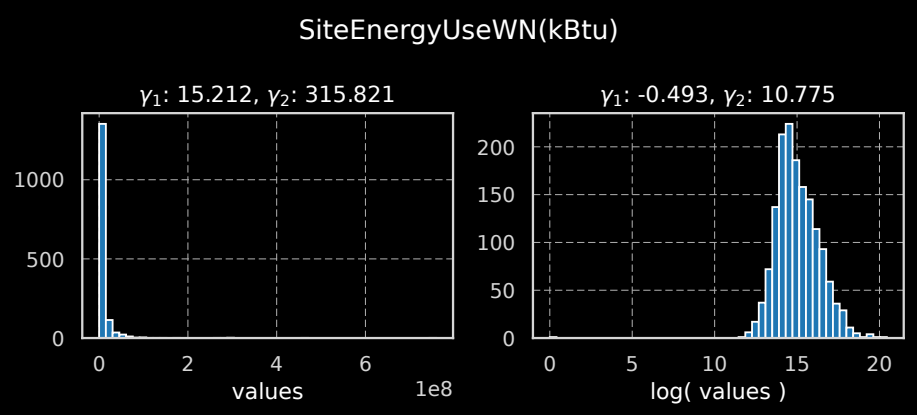

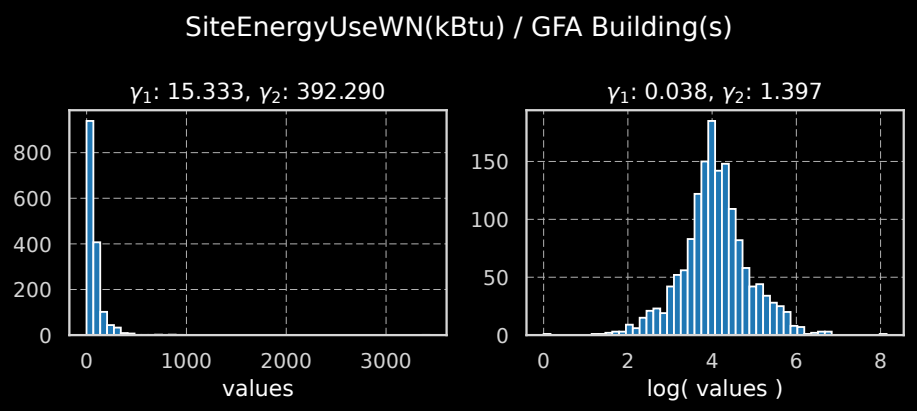

Référénce
GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

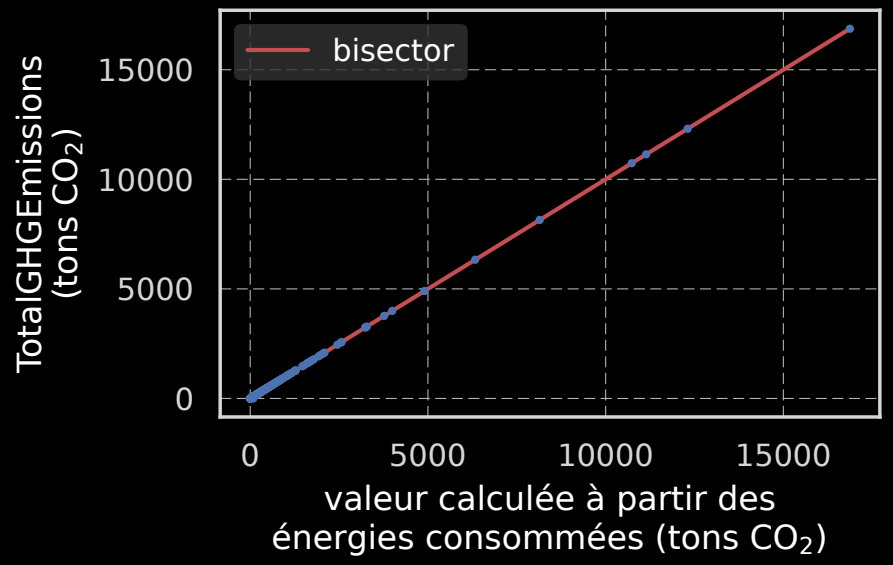

Référénce
GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

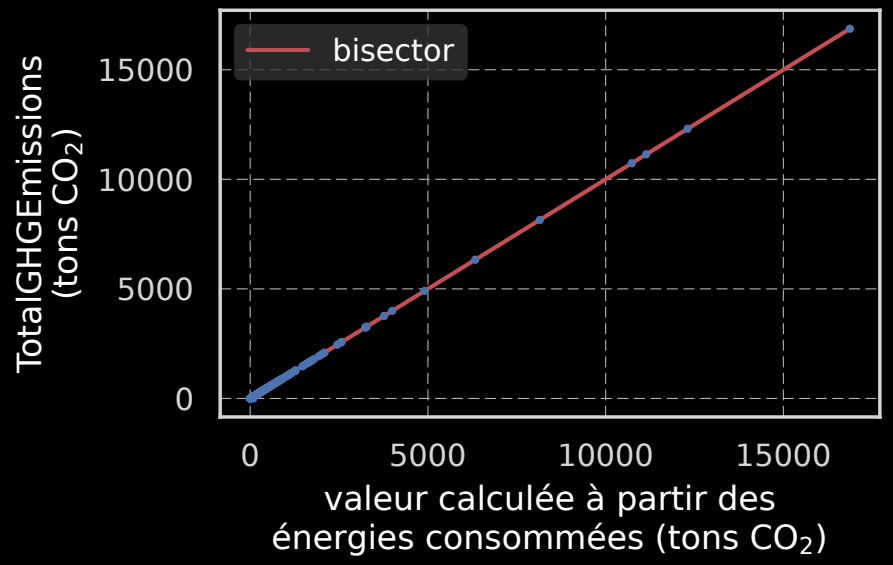

Référénce GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

Calcul des émissions à partir de la consommation

Référénce
GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

Calcul des émissions à partir de la consommation

Nécessité de re-calculer des variables

Référénce GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

Calcul des émissions à partir de la consommation

Nécessité de re-calculer des variables

Utilisation des valeurs "Weather Normalized"

Référénce GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

Calcul des émissions à partir de la consommation

Nécessité de re-calculer des variables

Utilisation des valeurs "Weather Normalized"

Modélisation de la consommation surfacique

Référénce GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

Calcul des émissions à partir de la consommation

Nécessité de re-calculer des variables

Utilisation des valeurs "Weather Normalized"

Modélisation de la consommation surfacique

Prédiction des émissions à partir des prédictions sur la consommation

Référénce GFA Buidlings

Re-calcul consommation totale

Re-calcul consommation surfacique

Cible : consommation surfacique

Calcul des émissions à partir de la consommation

FEATURE ENGINEERING

FEATURE ENGINEERING

Corrélation des variables initiales

Heatmap des corrélations linéaires

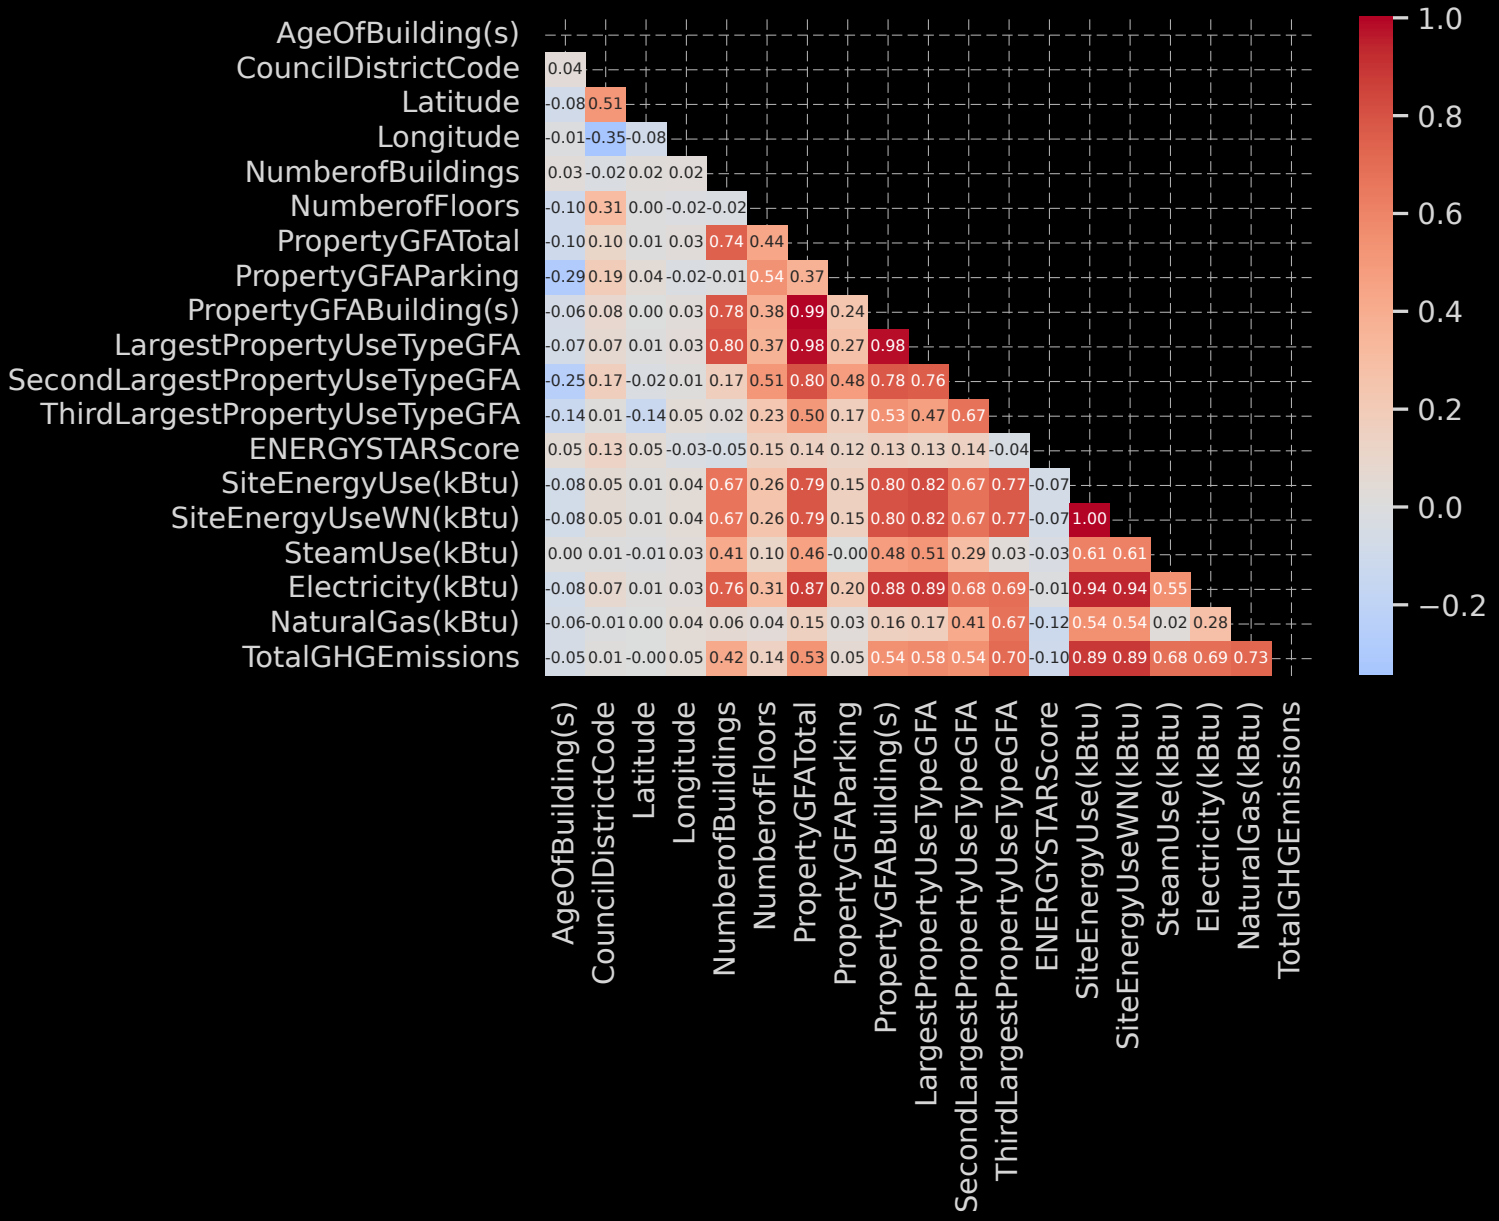

Multi-colinéarité (Variance Inflation Factor)

	feature	VIF
4	NumberofBuildings	113400533.76
6	PropertyGFATotal	inf
7	PropertyGFAParking	inf
8	PropertyGFABuilding(s)	inf
9	LargestPropertyUseTypeGFA	30.29
10	SecondLargestPropertyUseTypeGFA	5.9
11	ThirdLargestPropertyUseTypeGFA	6.29
14	Electricity(kBtu)	5.85
15	NaturalGas(kBtu)	5.52

Multi-colinéarité (Variance Inflation Factor)

	feature	VIF
4	NumberofBuildings	113400533.76
6	PropertyGFATotal	inf
7	PropertyGFAParking	inf
8	PropertyGFABuilding(s)	inf
9	LargestPropertyUseTypeGFA	30.29
10	SecondLargestPropertyUseTypeGFA	5.9
11	ThirdLargestPropertyUseTypeGFA	6.29
14	Electricity(kBtu)	5.85
15	NaturalGas(kBtu)	5.52

Présence de **fortes multi-colinéarités**

FEATURE ENGINEERING

Analyse en Composantes Principales

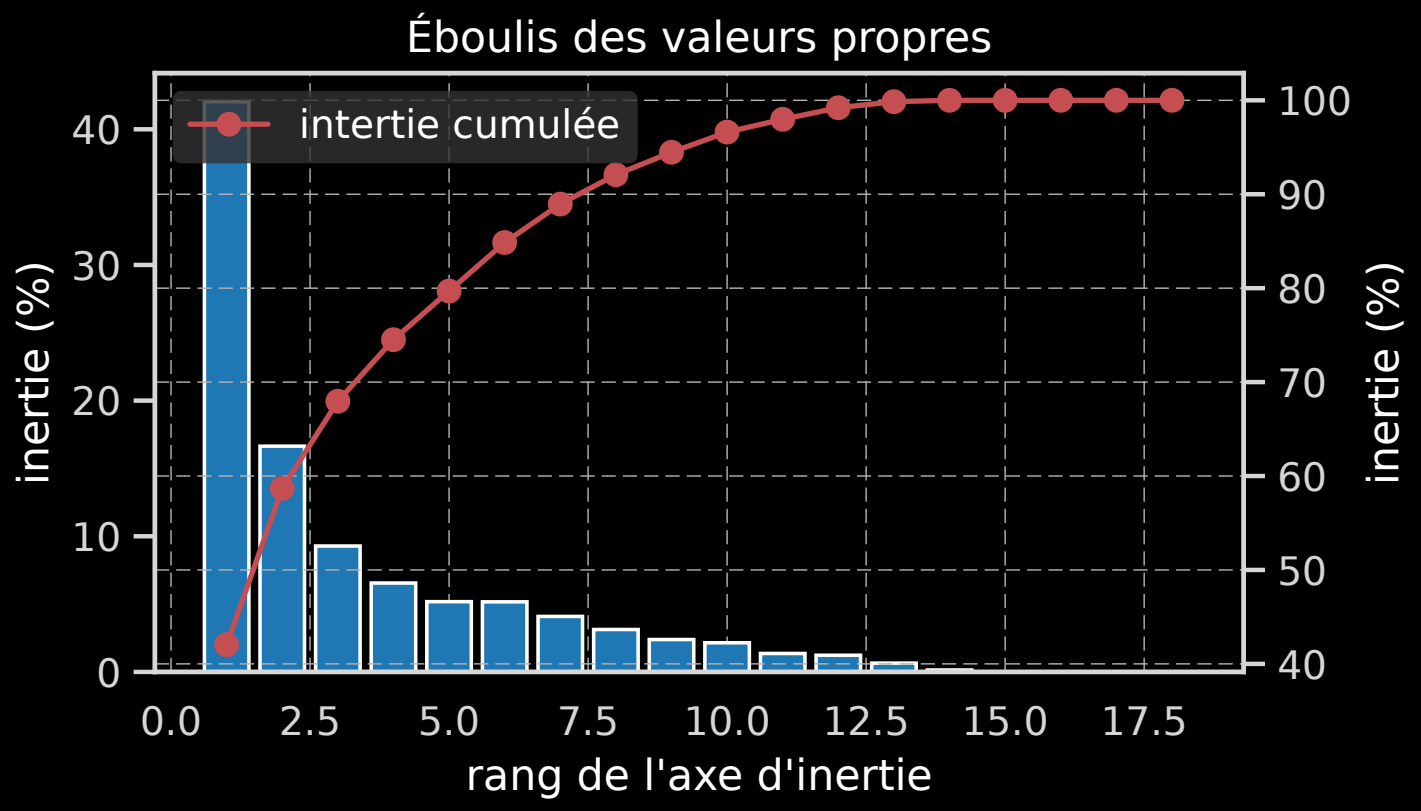
Éboulis des valeurs propres
intertie cumulée
inertie (%)
inertie (%)
rang de l'axe d'inertie
0
10
20
30
40
40
50
60
70
80
90
100
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5

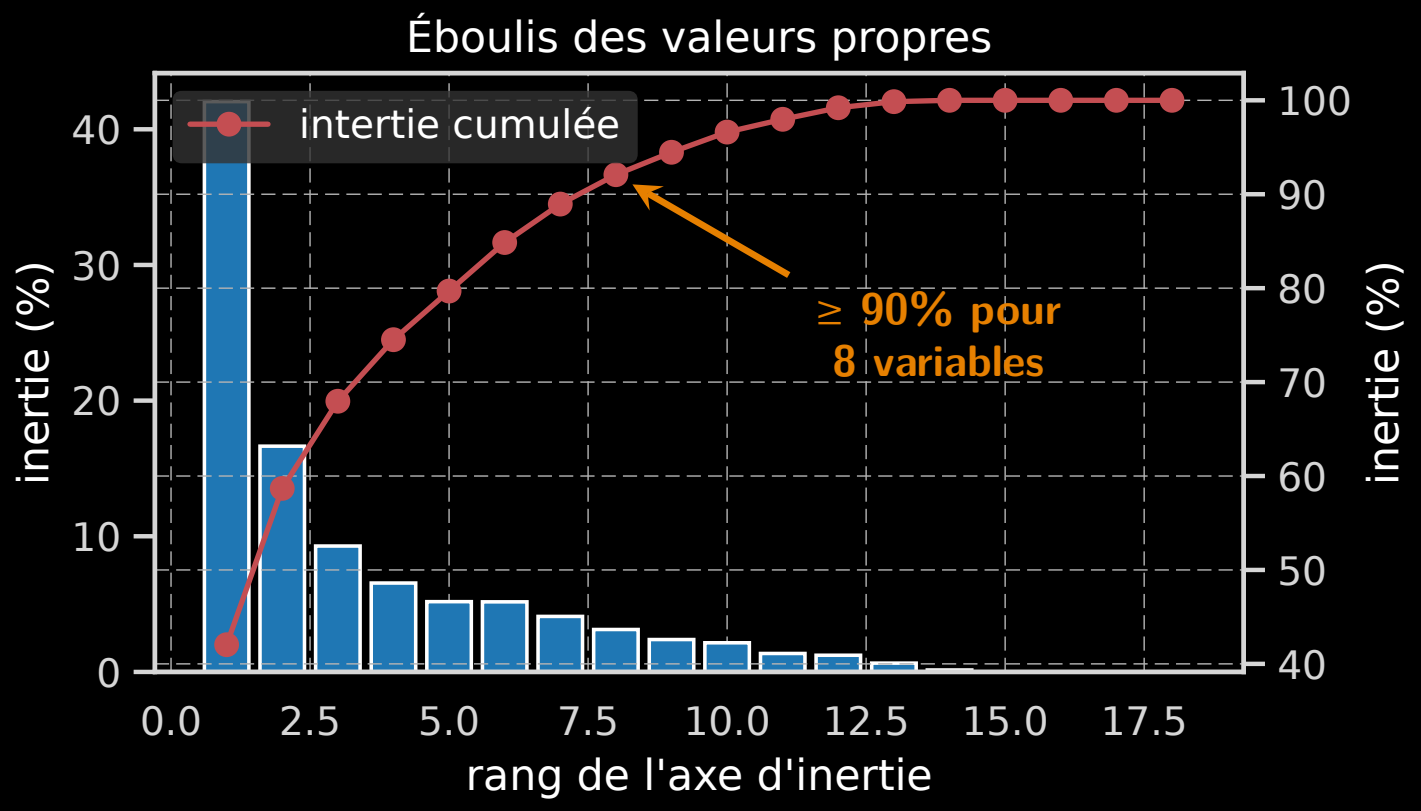
Éboulis des valeurs propres
intertie cumulée
≥ 90% pour
8 variables
inertie (%)
inertie (%)
rang de l'axe d'inertie
0
10
20
30
40
40
50
60
70
80
90
100
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5

Projection des variables sur les principaux axes d'inertie:

	AgeOfBuilding(s)	CouncilDistrictCode	Latitude	Longitude	NumberofBuildings	NumberofFloors	PropertyGFATotal	PropertyGFAParking	PropertyGFABuilding(s)	LargestPropertyUseTypeGFA	SecondLargestPropertyUseTypeGFA	ThirdLargestPropertyUseTypeGFA	SiteEnergyUse(kBtu)	SiteEnergyUseWN(kBtu)	SteamUse(kBtu)	Electricity(kBtu)	NaturalGas(kBtu)	TotalGHGEmissions
F1	-12	6	-4	2	2	22	30	18	29	31	32	28	32	32	6	34	23	26
F2	10	-24	-13	9	6	-34	-30	-29	-26	-25	-6	19	25	25	-5	2	41	38
F3	-4	-55	-50	51	32	5	11	1	12	10	1	-2	-8	-8	-9	1	-13	-13
F4	59	13	-32	-12	7	20	1	-28	9	6	-9	-2	1	1	61	1	-6	3
F5	-34	15	26	11	69	-7	-8	11	-13	-7	-3	-15	4	4	47	5	-2	5
F6	27	13	-8	-46	61	-6	5	-9	9	2	3	9	-0	-0	-52	8	-3	-9
F7	50	14	54	60	10	8	4	-6	6	5	2	6	-1	-1	-18	-4	5	1
F8	-30	-5	21	-1	-2	-16	10	-76	32	5	8	27	-6	-6	8	4	-15	-13

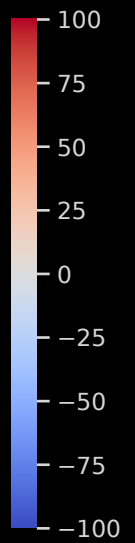

FEATURE ENGINEERING

Type d'énergies consommées

Corrélation importante
entre la consommation totale et la consommation élec./gas/vapeur (54% à 96%)

Corrélation importante entre la consommation totale et la consommation élec./gas/vapeur (54% à 96%)

Des **ratios** sont calculés pour éviter la **fuite de données** : valeurs normalisées par la consommation totale

Corrélation importante entre la consommation totale et la consommation élec./gas/vapeur (54% à 96%)

Des **ratios** sont calculés pour éviter la **fuite de données** : valeurs normalisées par la consommation totale

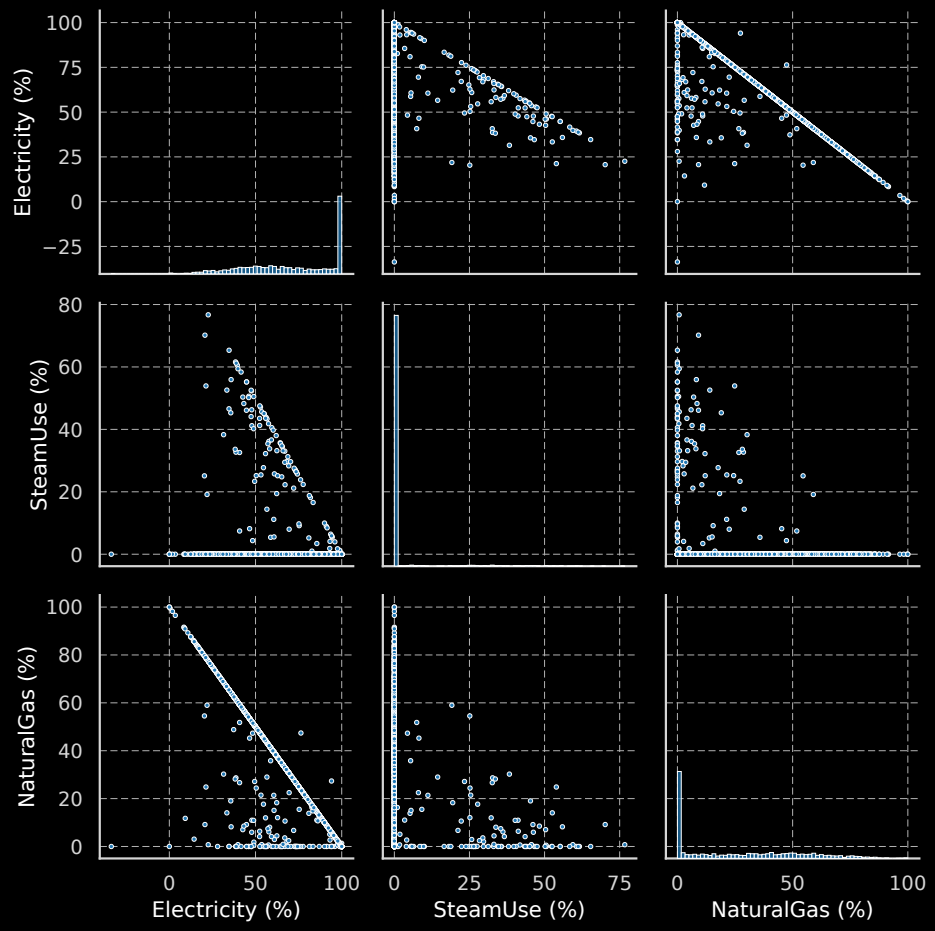

FEATURE ENGINEERING

Surfaces et types d'utilisations

Données initiales:

- 3 premières utilisations principales
- 63 catégories

Données initiales:

- 3 premières utilisations principales
- 63 catégories

$\downarrow$

Re-classement en 19 catégories

Données initiales:

- 3 premières utilisations principales
- 63 catégories

Re-classement en 19 catégories

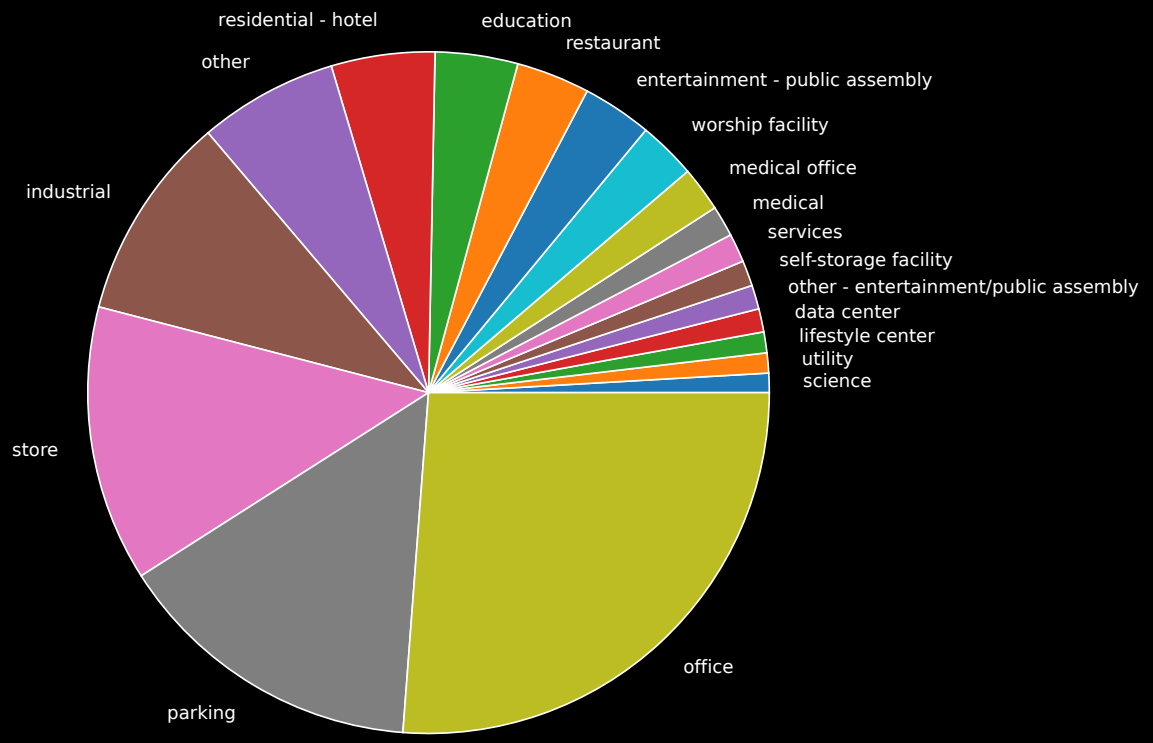

Données initiales:

- 3 premières utilisations principales
- 63 catégories

↓

Re-classement en 19 catégories

↓

Codé selon la méthode "**One Hot Encoding**"
Surfaces normalisées par le "GFA Building(s)"

Données initiales:

- 3 premières utilisations principales
- 63 catégories

↓

Re-classement en 19 catégories

↓

Codé selon la méthode "**One Hot Encoding**"
Surfaces normalisées par le "GFA Building(s)"

	ohe0 data center	ohe0 education	ohe0 entertainment - public assembly	ohe0 industrial	ohe0 lifestyle center
16	0.0	0.0	0.0	0.0	0.87
17	0.0	0.0	0.0	0.0	0.0
18	0.0	0.0	0.29	0.0	0.0
19	0.0	0.0	0.0	0.0	0.0
20	0.0	0.0	0.0	0.0	0.0

FEATURE ENGINEERING

Nouvelles variables

Données **temporelles**:

Données **temporelles**:

Date des données

Date de construction

Données **temporelles**:

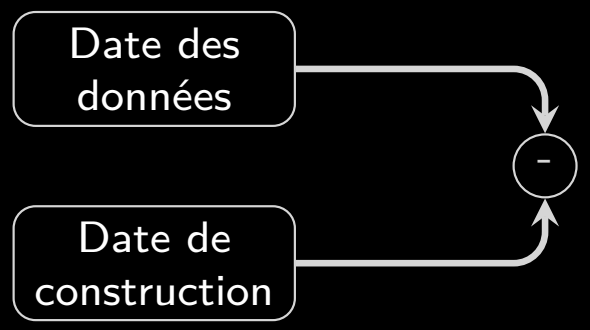

Données **temporelles**:

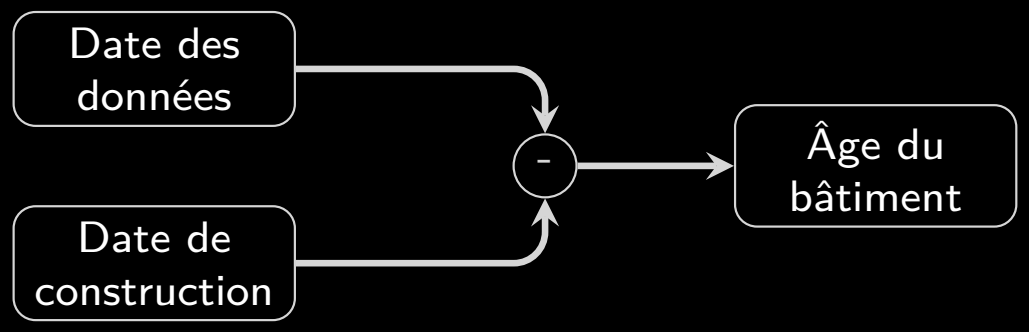

Données **temporelles**:

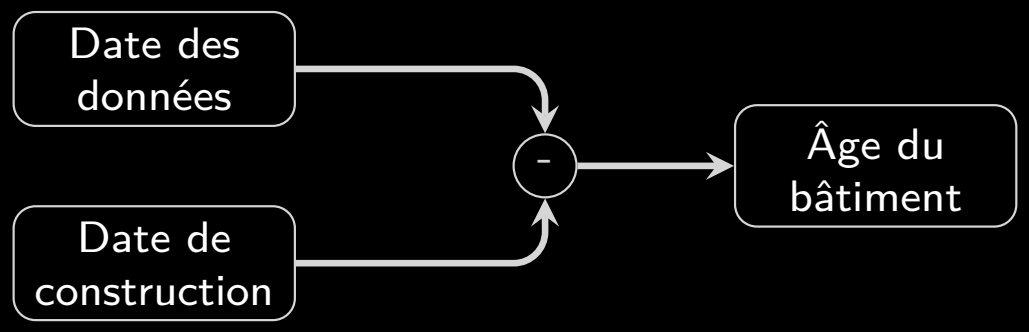

Variables liées à l'équation de **transferts thermiques**:

Données **temporelles**:

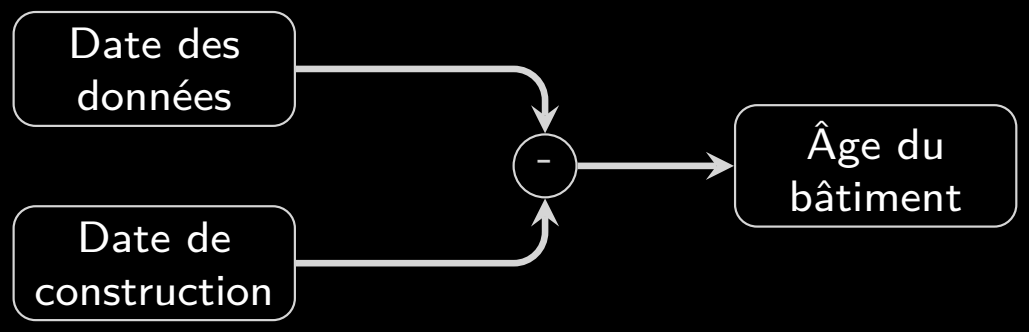

Variables liées à l'équation de **transferts thermiques**:

Nombre de bâtiments

Nombre de niveaux

Données **temporelles**:

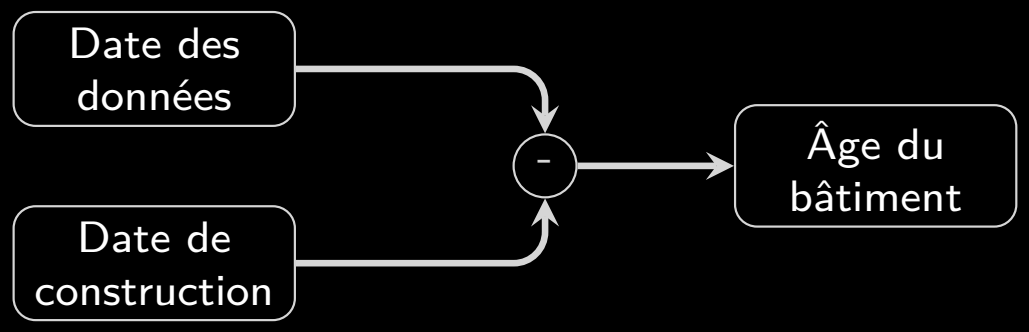

Variables liées à l'équation de **transferts thermiques**:

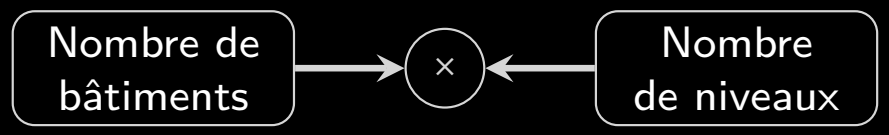

Données **temporelles**:

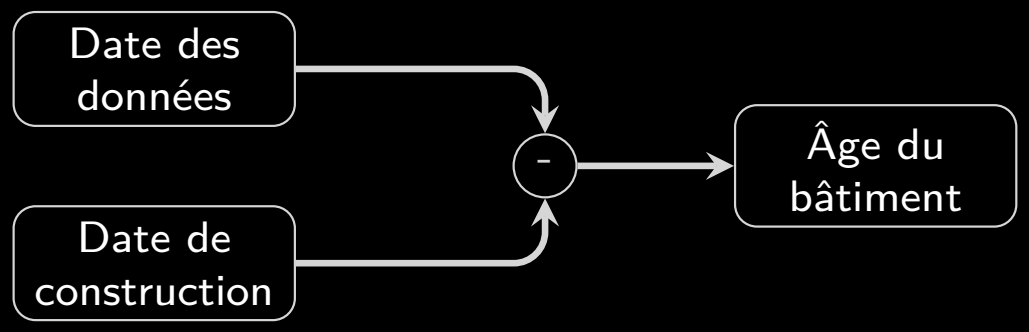

Variables liées à l'équation de **transferts thermiques**:

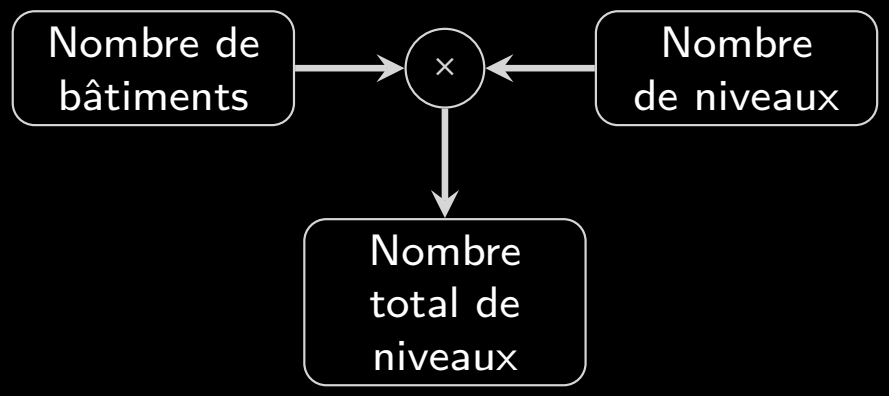

Données **temporelles**:

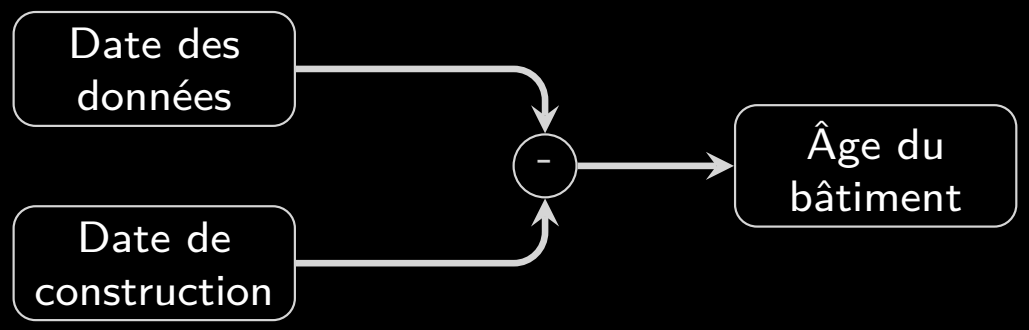

Variables liées à l'équation de **transferts thermiques**:

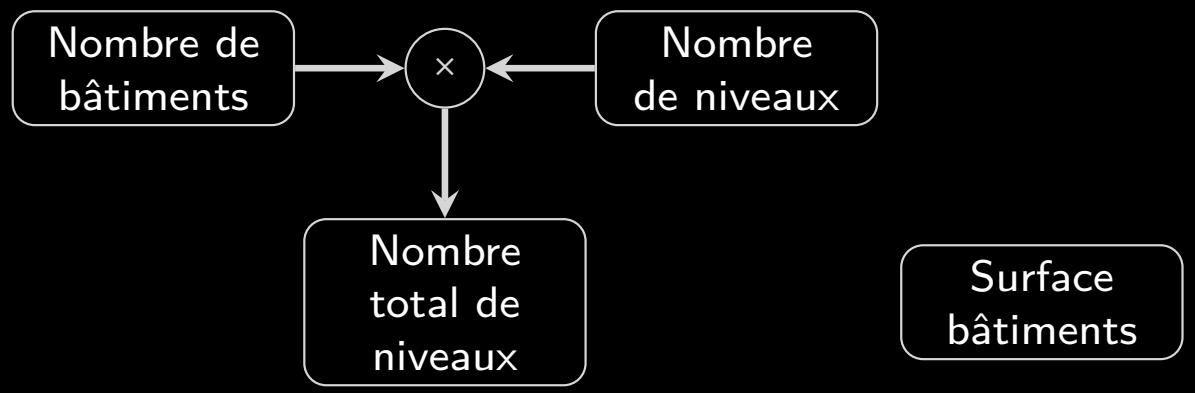

Données **temporelles**:

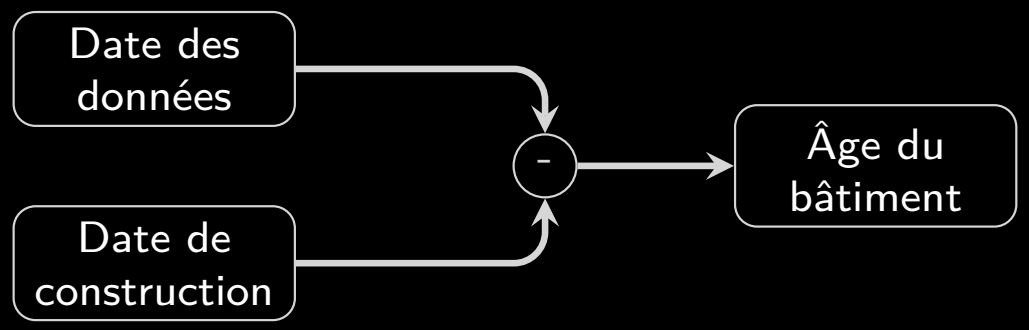

Variables liées à l'équation de **transferts thermiques**:

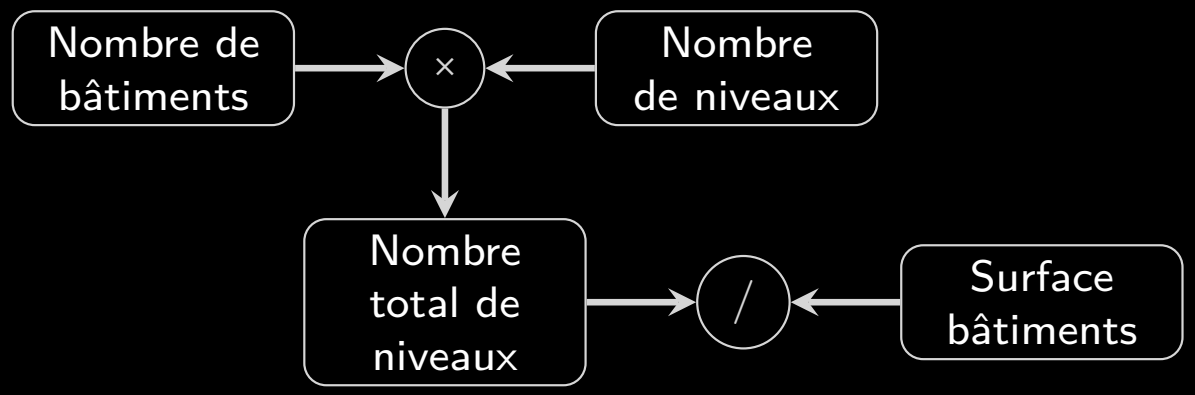

Données **temporelles**:

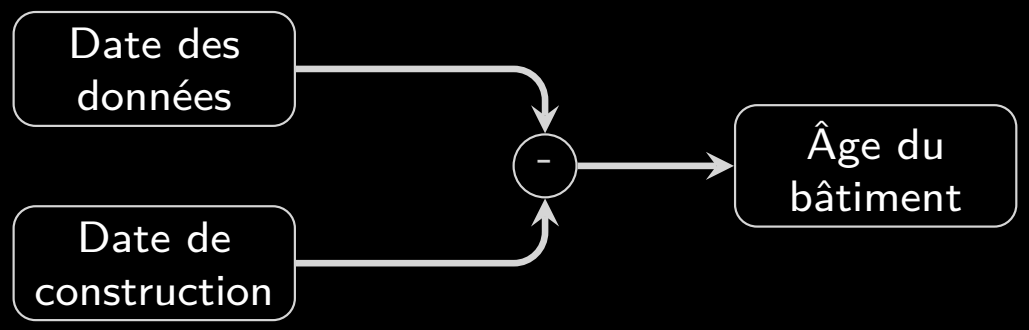

Variables liées à l'équation de **transferts thermiques**:

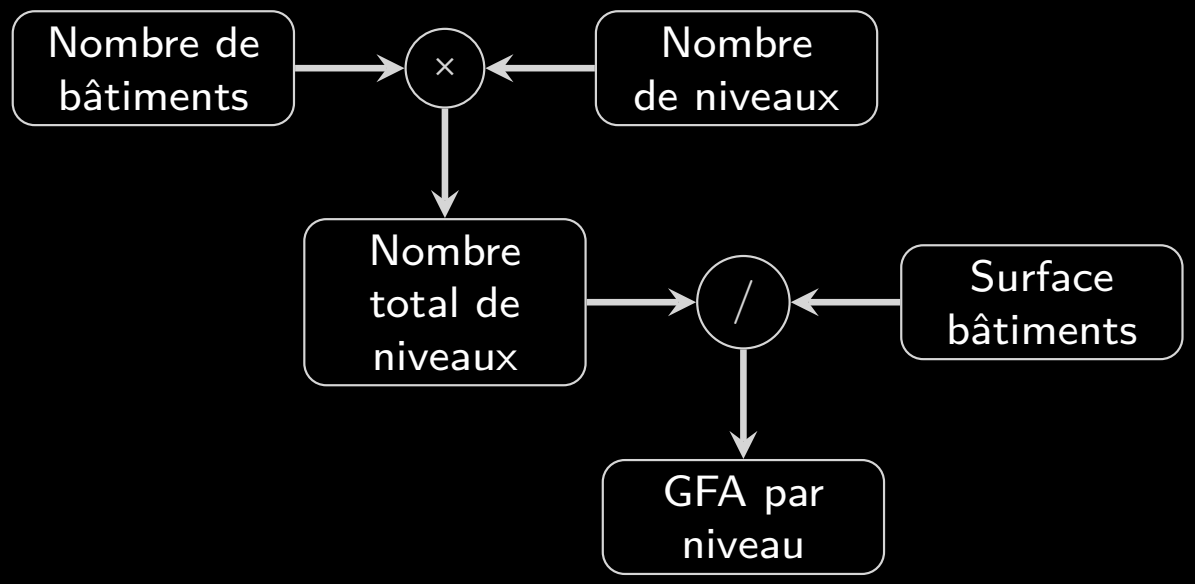

Données **temporelles**:

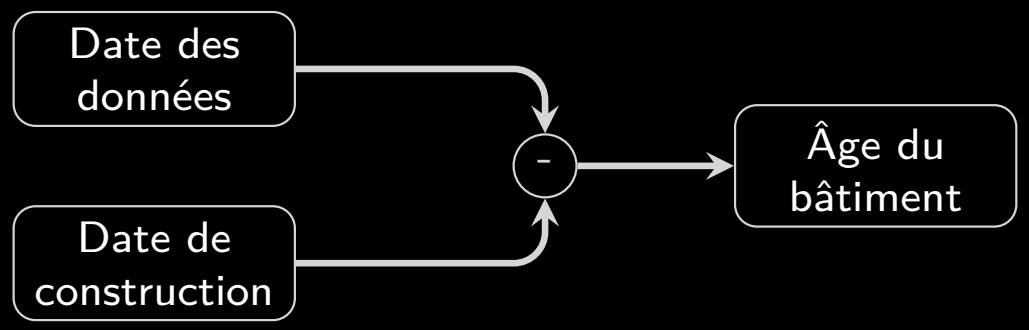

Variables liées à l'équation de **transferts thermiques**:

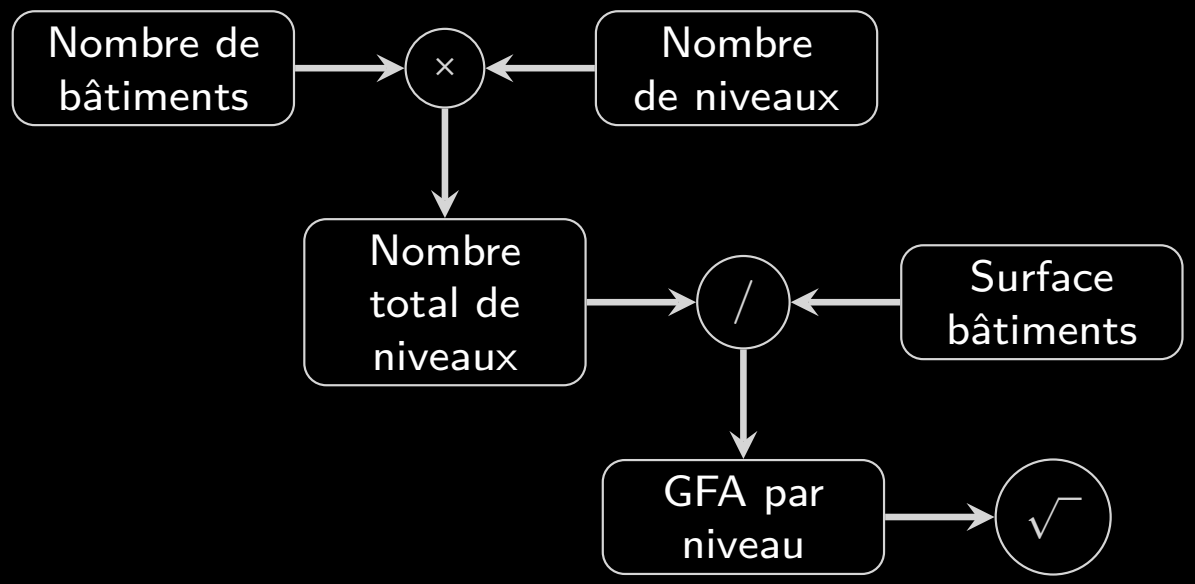

Données **temporelles**:

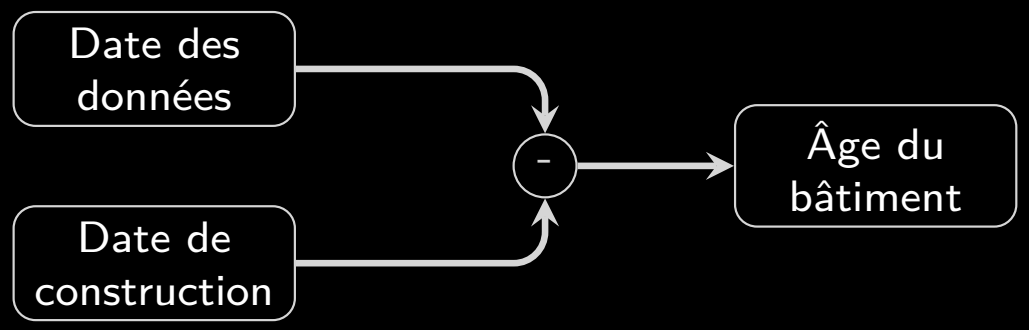

Variables liées à l'équation de **transferts thermiques**:

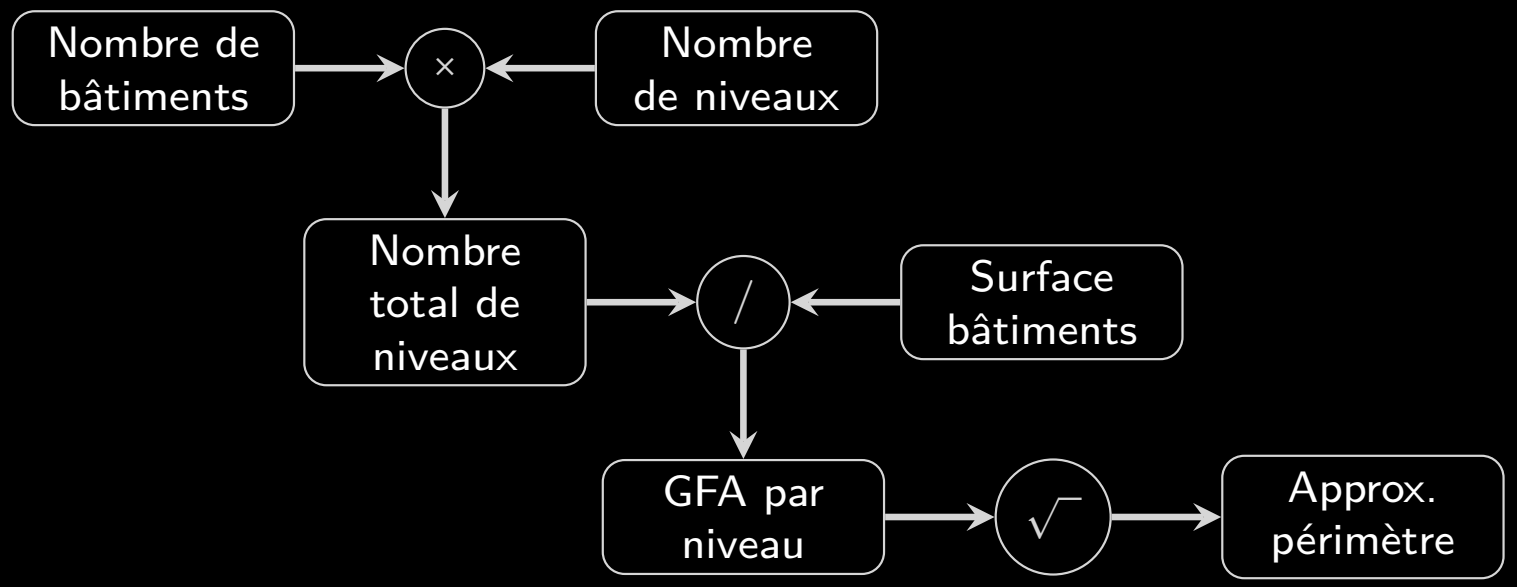

Données **temporelles**:

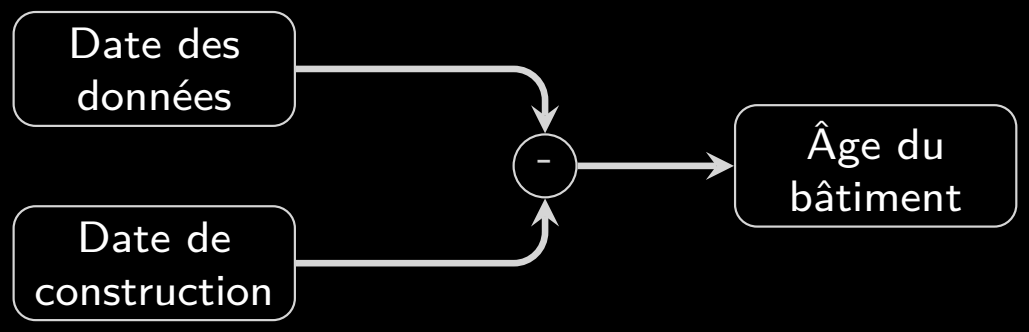

Variables liées à l'équation de **transferts thermiques**:

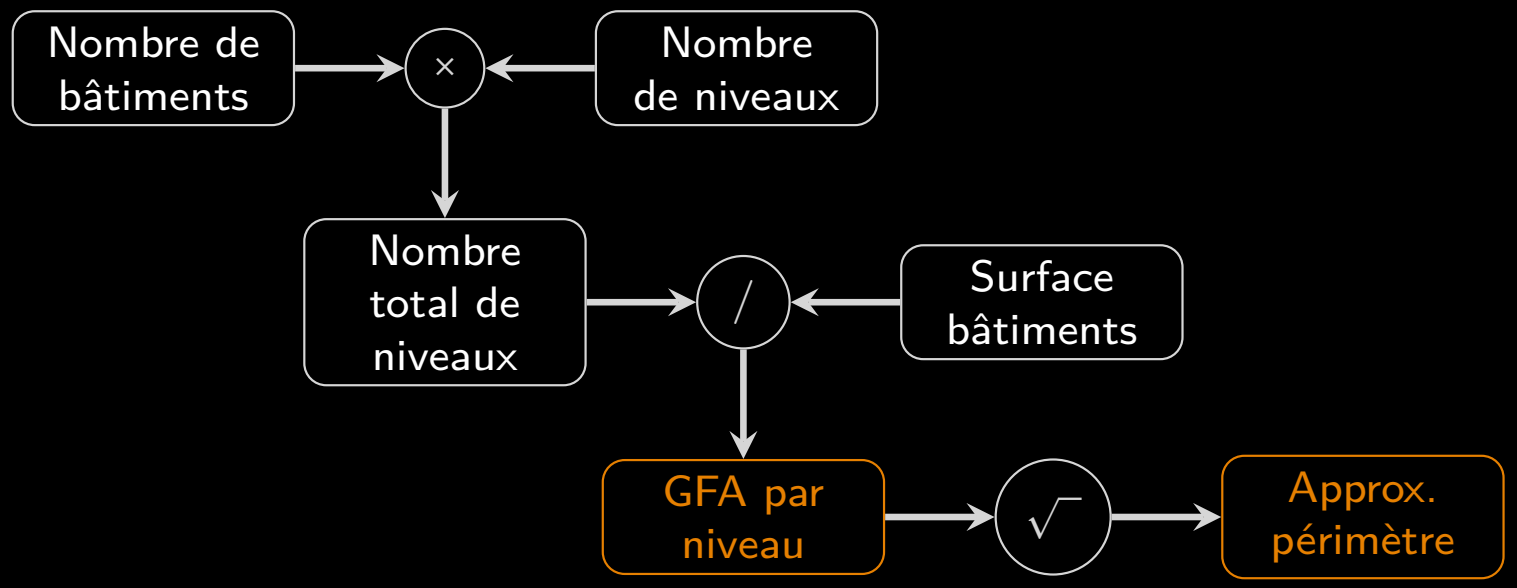

FEATURE ENGINEERING

Corrélation des nouvelles variables

Heatmap des corrélations linéaires

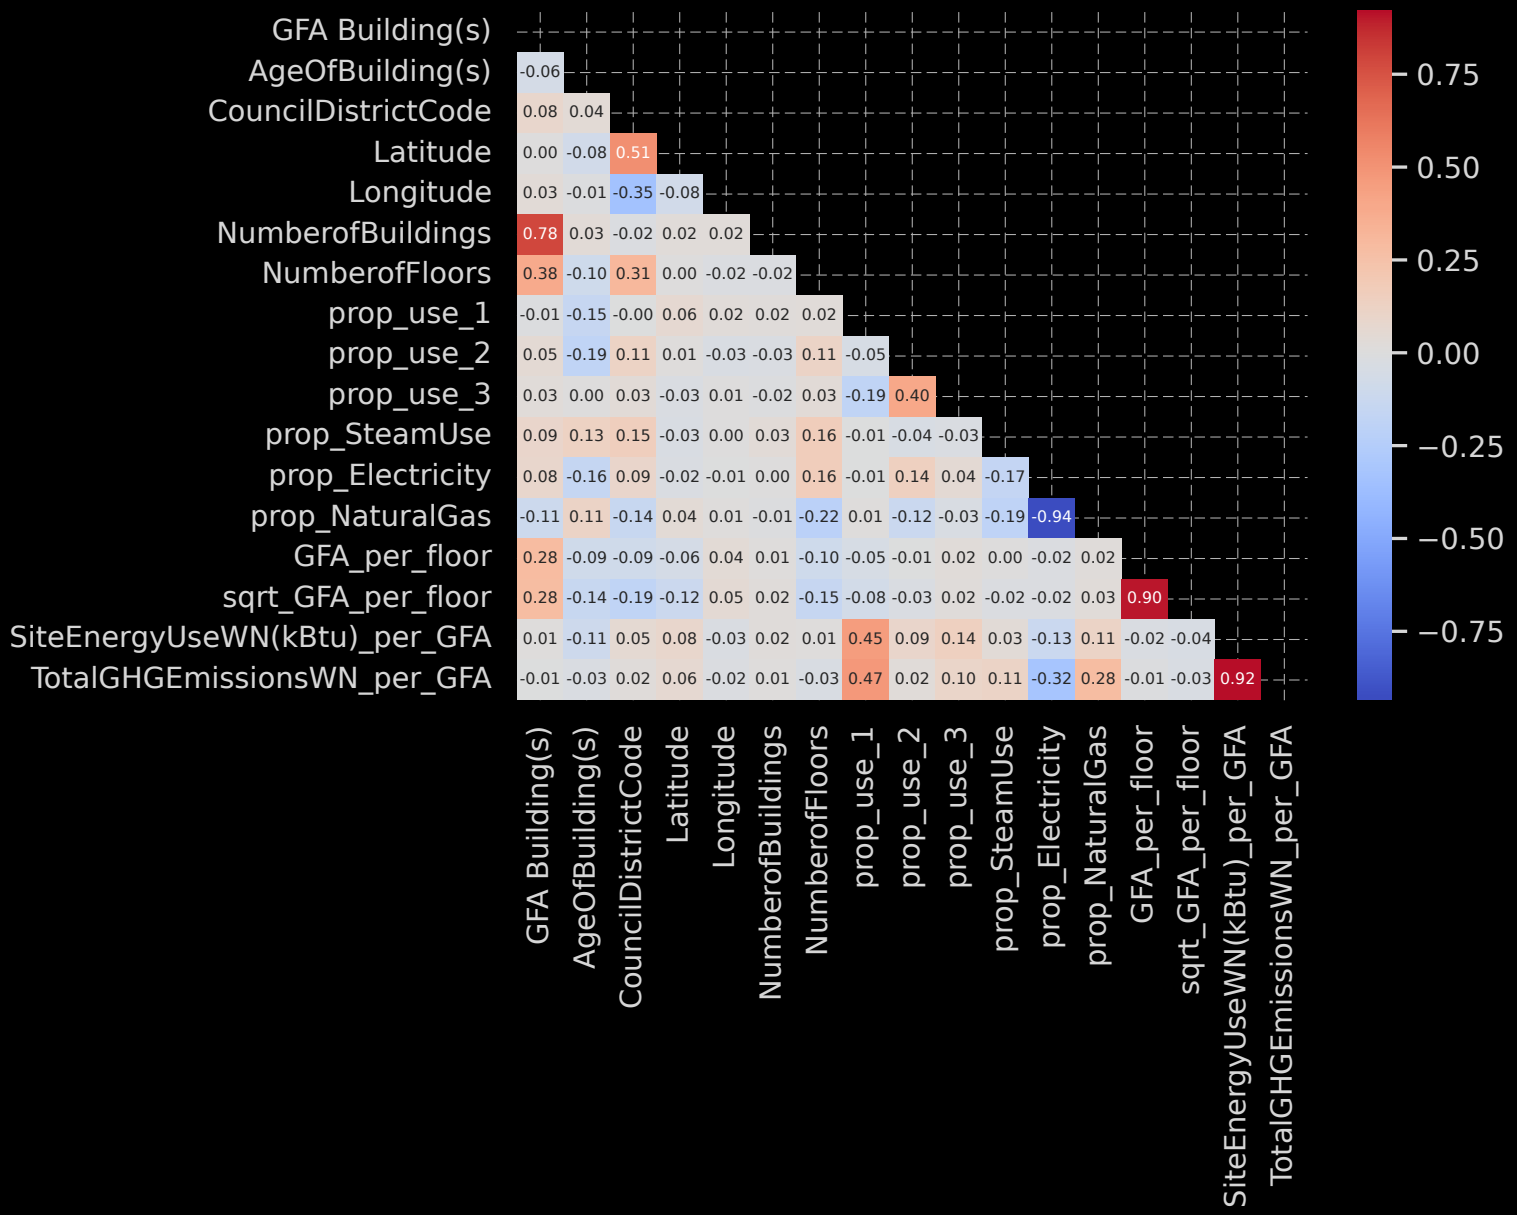

Multi-colinéarité (Variance Inflation Factor)

	feature	VIF
1	CouncilDistrictCode	7.73
2	Latitude	1375267.78
3	Longitude	1374688.07
6	prop use 1	6.12
10	prop Electricity	164.76
11	prop NaturalGas	43.07
12	GFA per floor	7.12
13	sqrt GFA per floor	27.53

Multi-colinéarité (Variance Inflation Factor)

	feature	VIF
1	CouncilDistrictCode	7.73
2	Latitude	1375267.78
3	Longitude	1374688.07
6	prop use 1	6.12
10	prop Electricity	164.76
11	prop NaturalGas	43.07
12	GFA per floor	7.12
13	sqrt GFA per floor	27.53

Diminution des **multi-colinéarités**

MODÉLISATION

MODÉLISATION

Consommation d'énergie

$\boxed{X_{train}}$

X_{train} → Mise à l'échelle

X_{train} → Mise à l'échelle

y_{train}

GFA_{train}

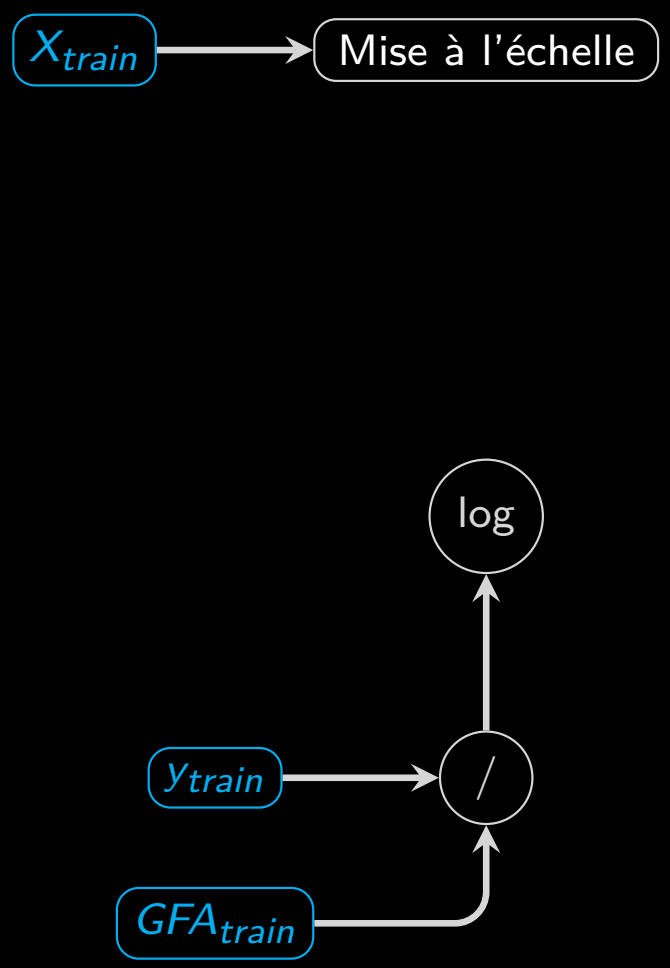
X_{train}
Mise à l'échelle
log
y_{train}
/
GFA_{train}

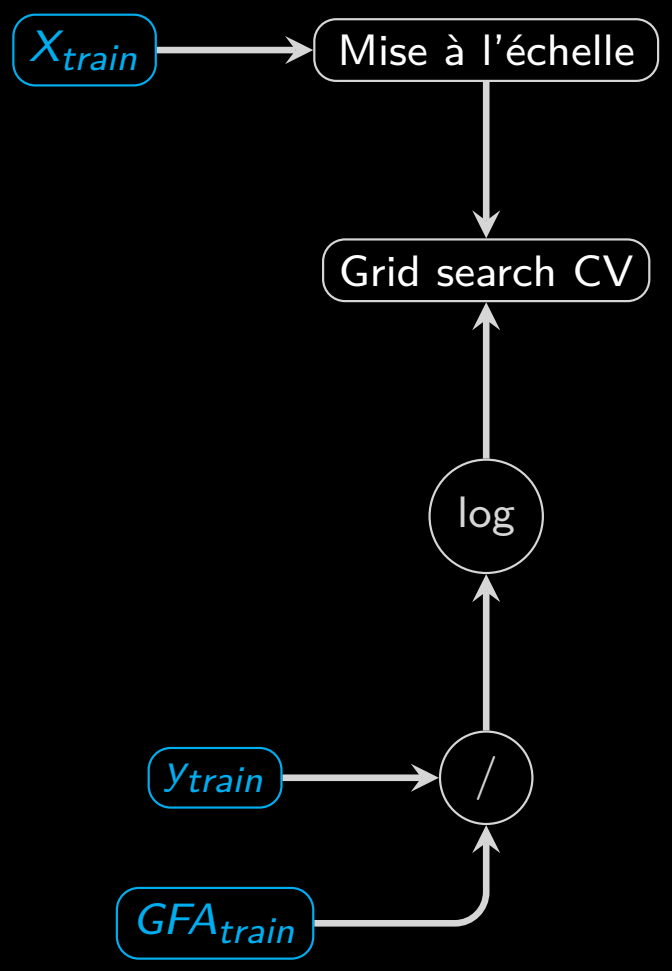
X_{train}
Mise à l'échelle
Grid search CV
log
y_{train}
/
GFA_{train}

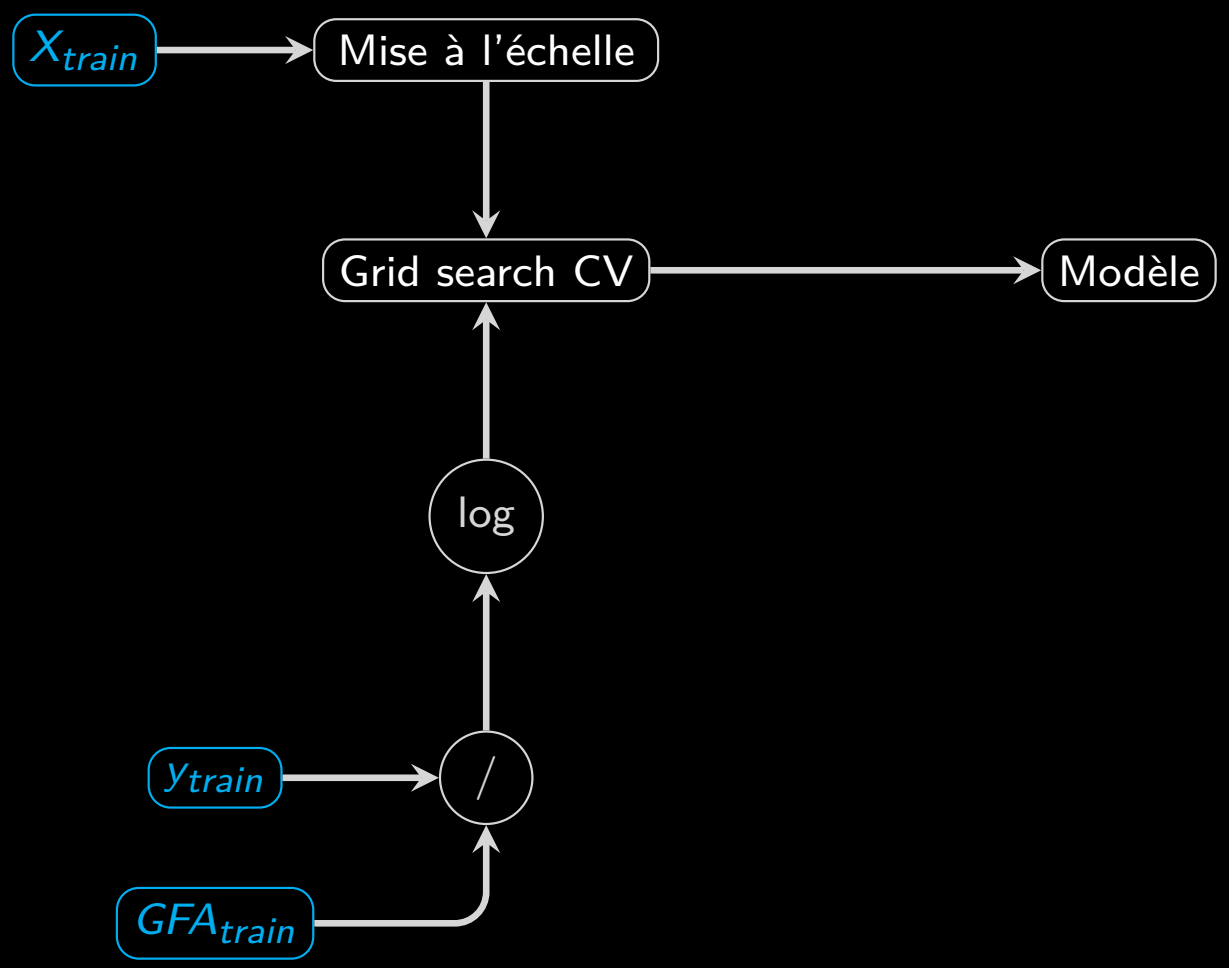
X_{train}
Mise à l'échelle
Grid search CV
Modèle
log
y_{train}
/
GFA_{train}

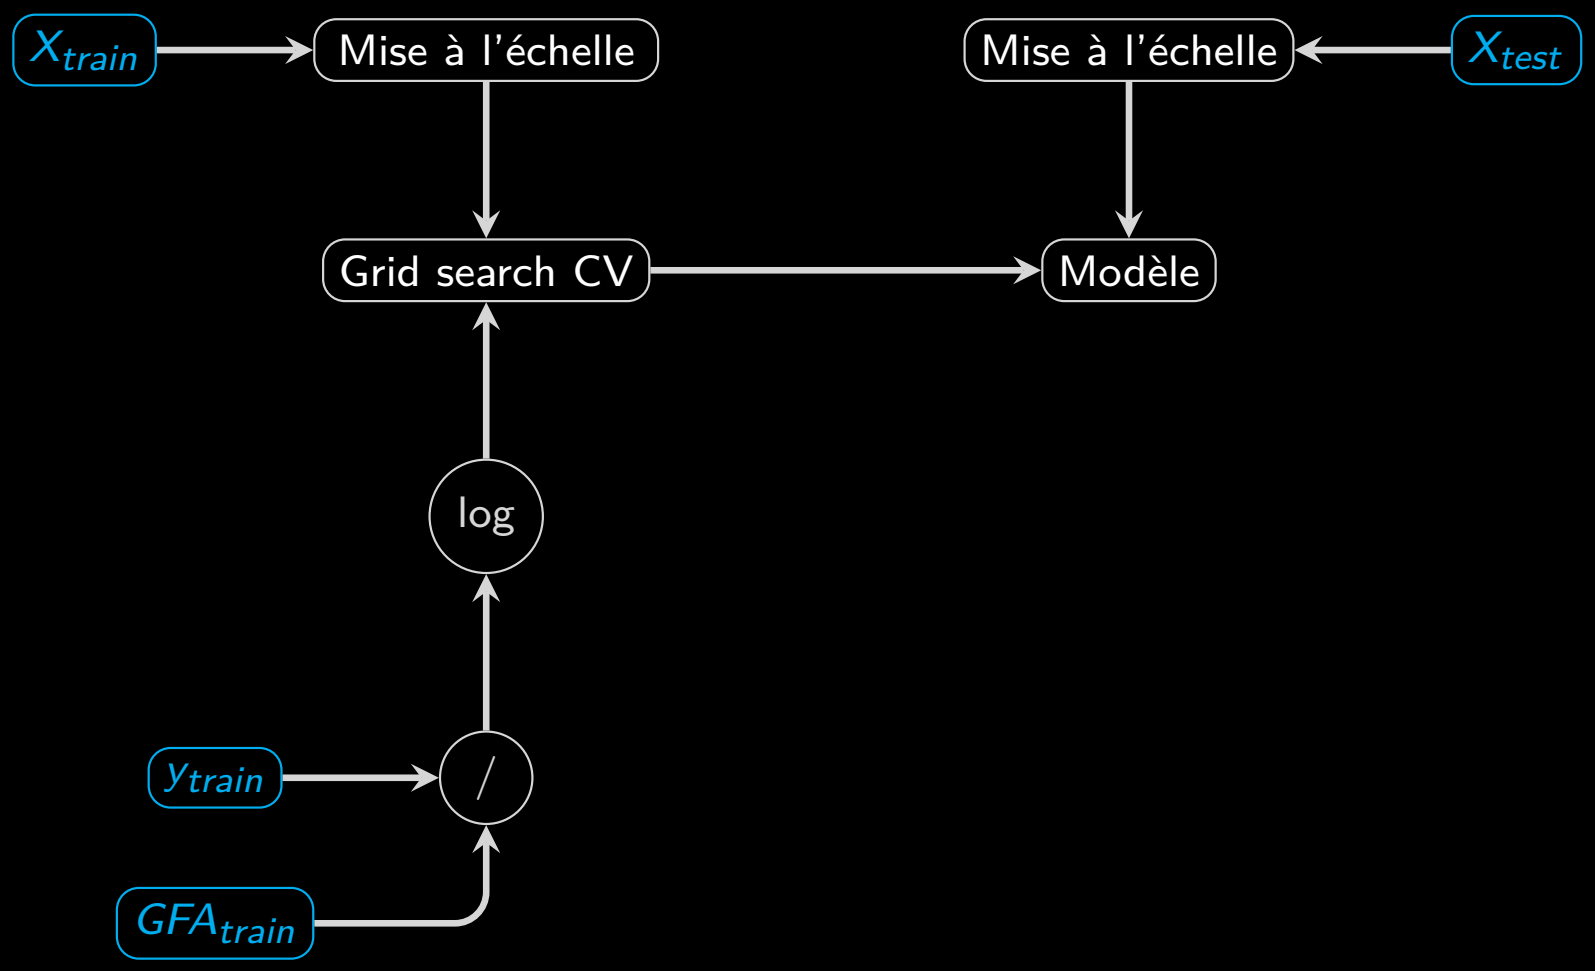
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
log
y_{train}
/
GFA_{train}

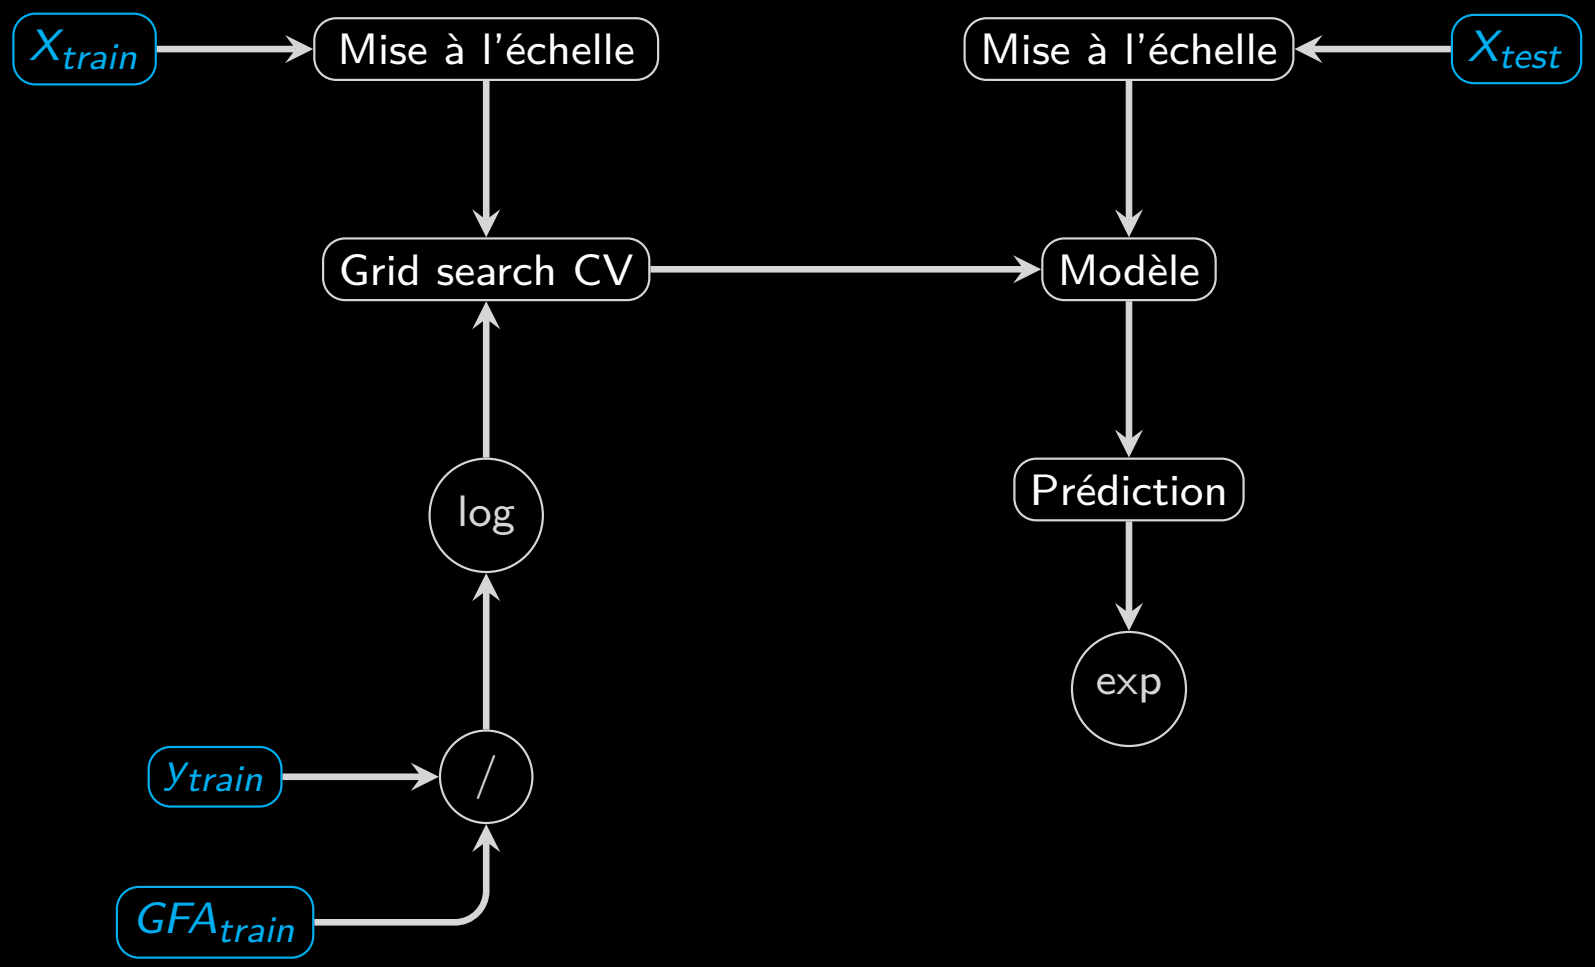
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
log
Prédiction
exp
y_{train}
/
GFA_{train}

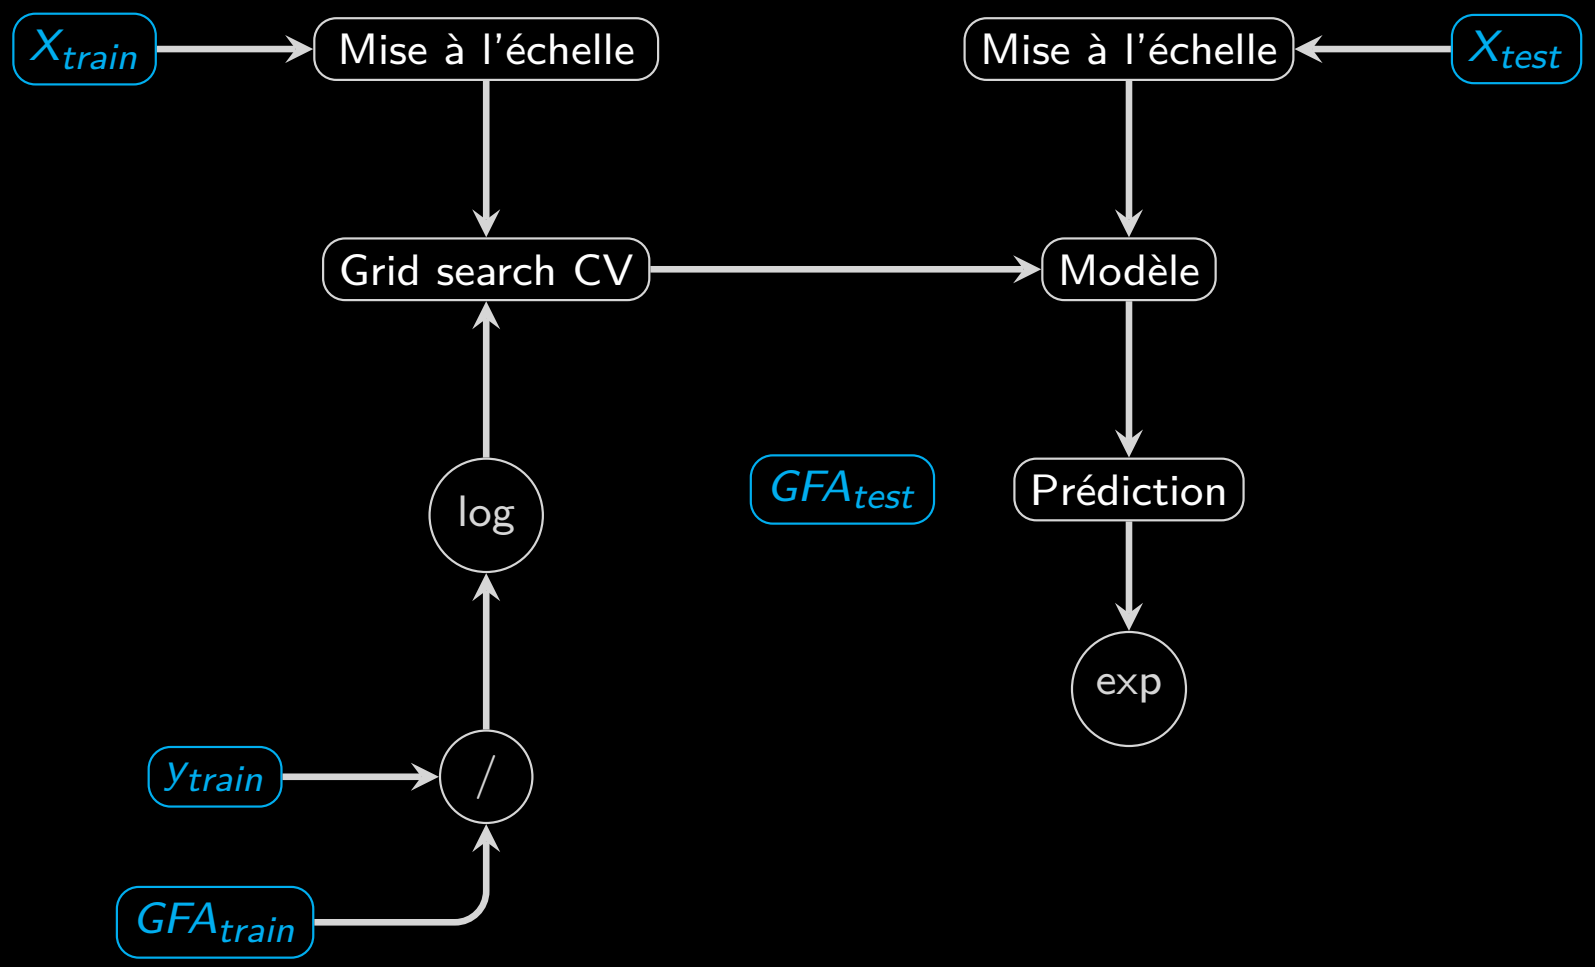
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
log
GFA_{test}
Prédiction
exp
y_{train}
/
GFA_{train}

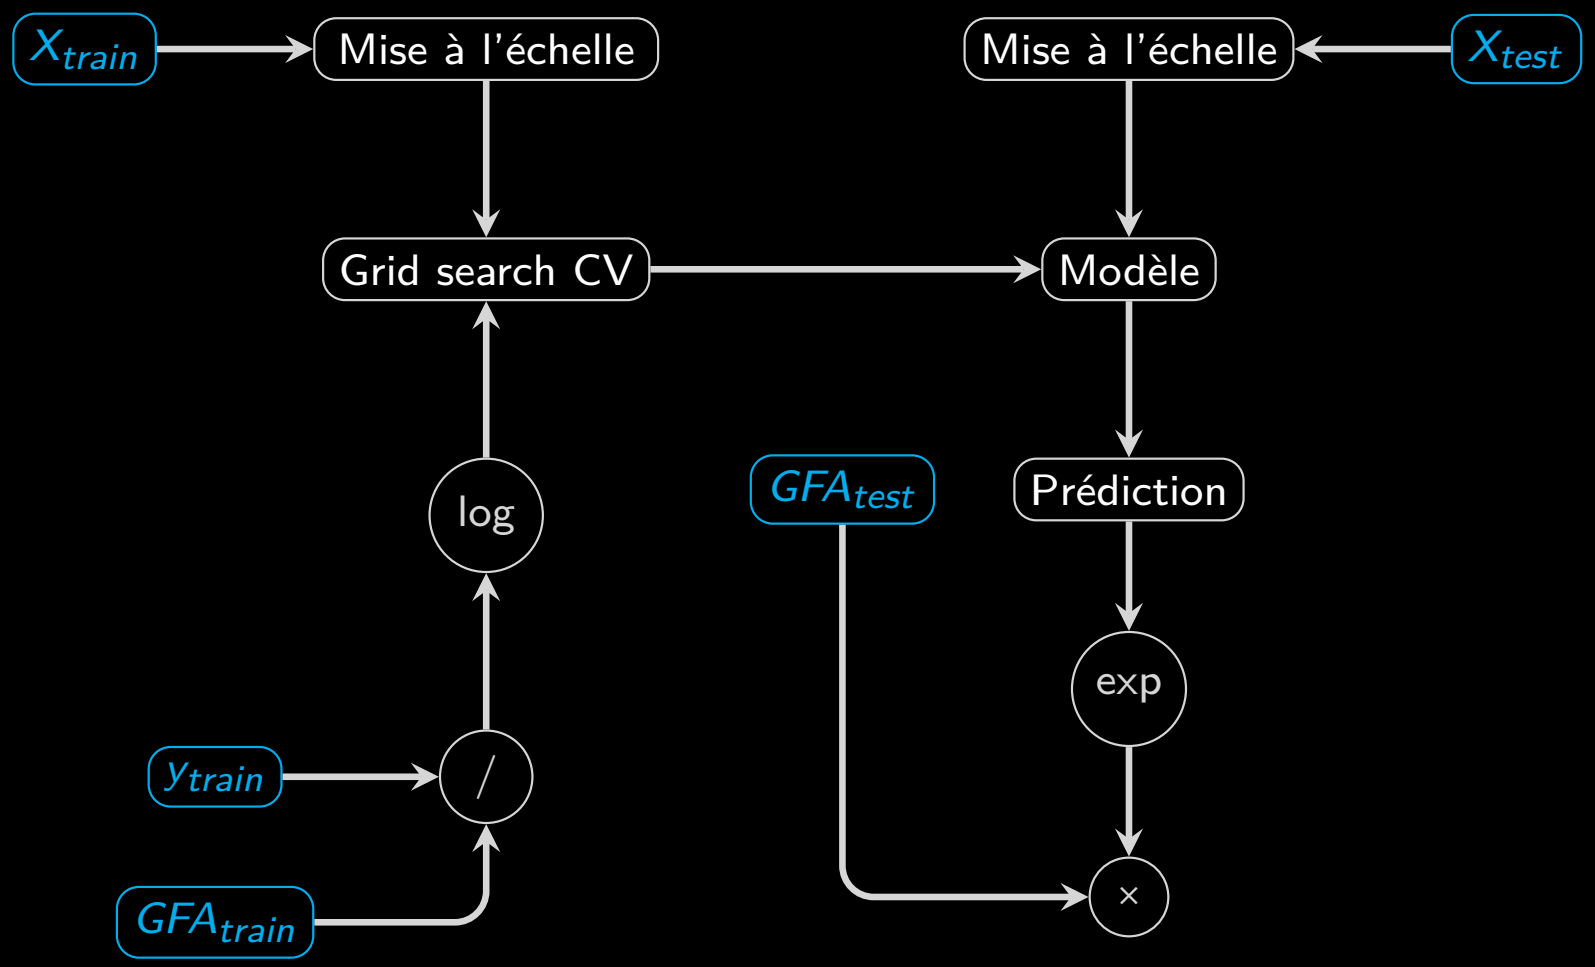
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
log
GFA_{test}
Prédiction
exp
y_{train}
/
×
GFA_{train}

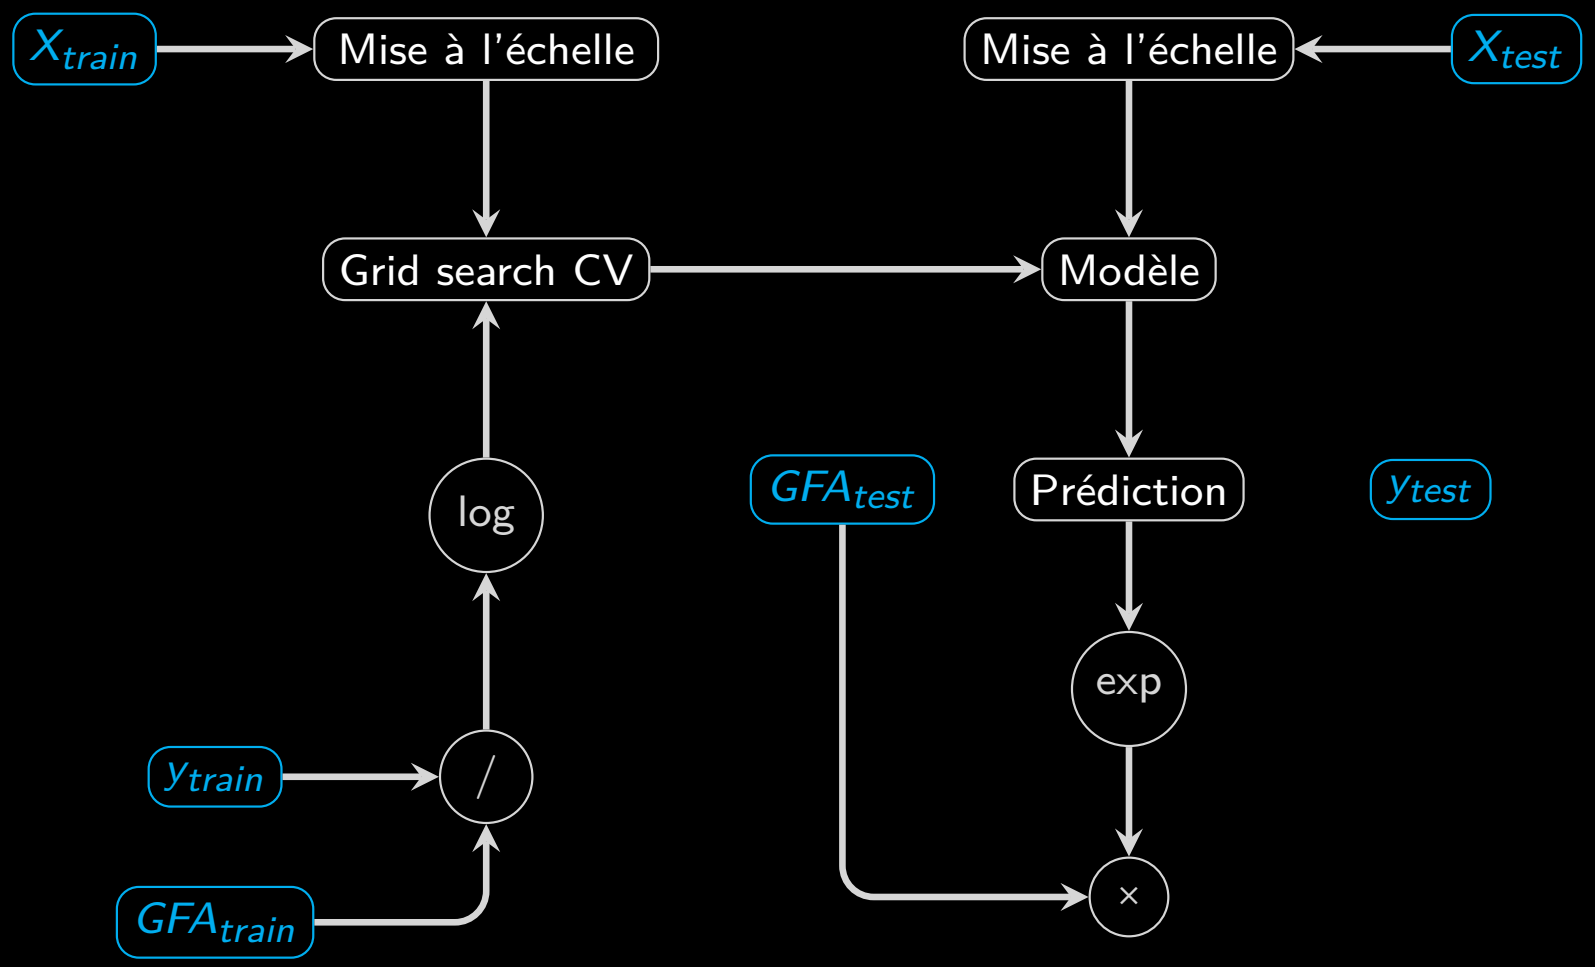
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
log
GFA_{test}
Prédiction
y_{test}
exp
y_{train}
/
×
GFA_{train}

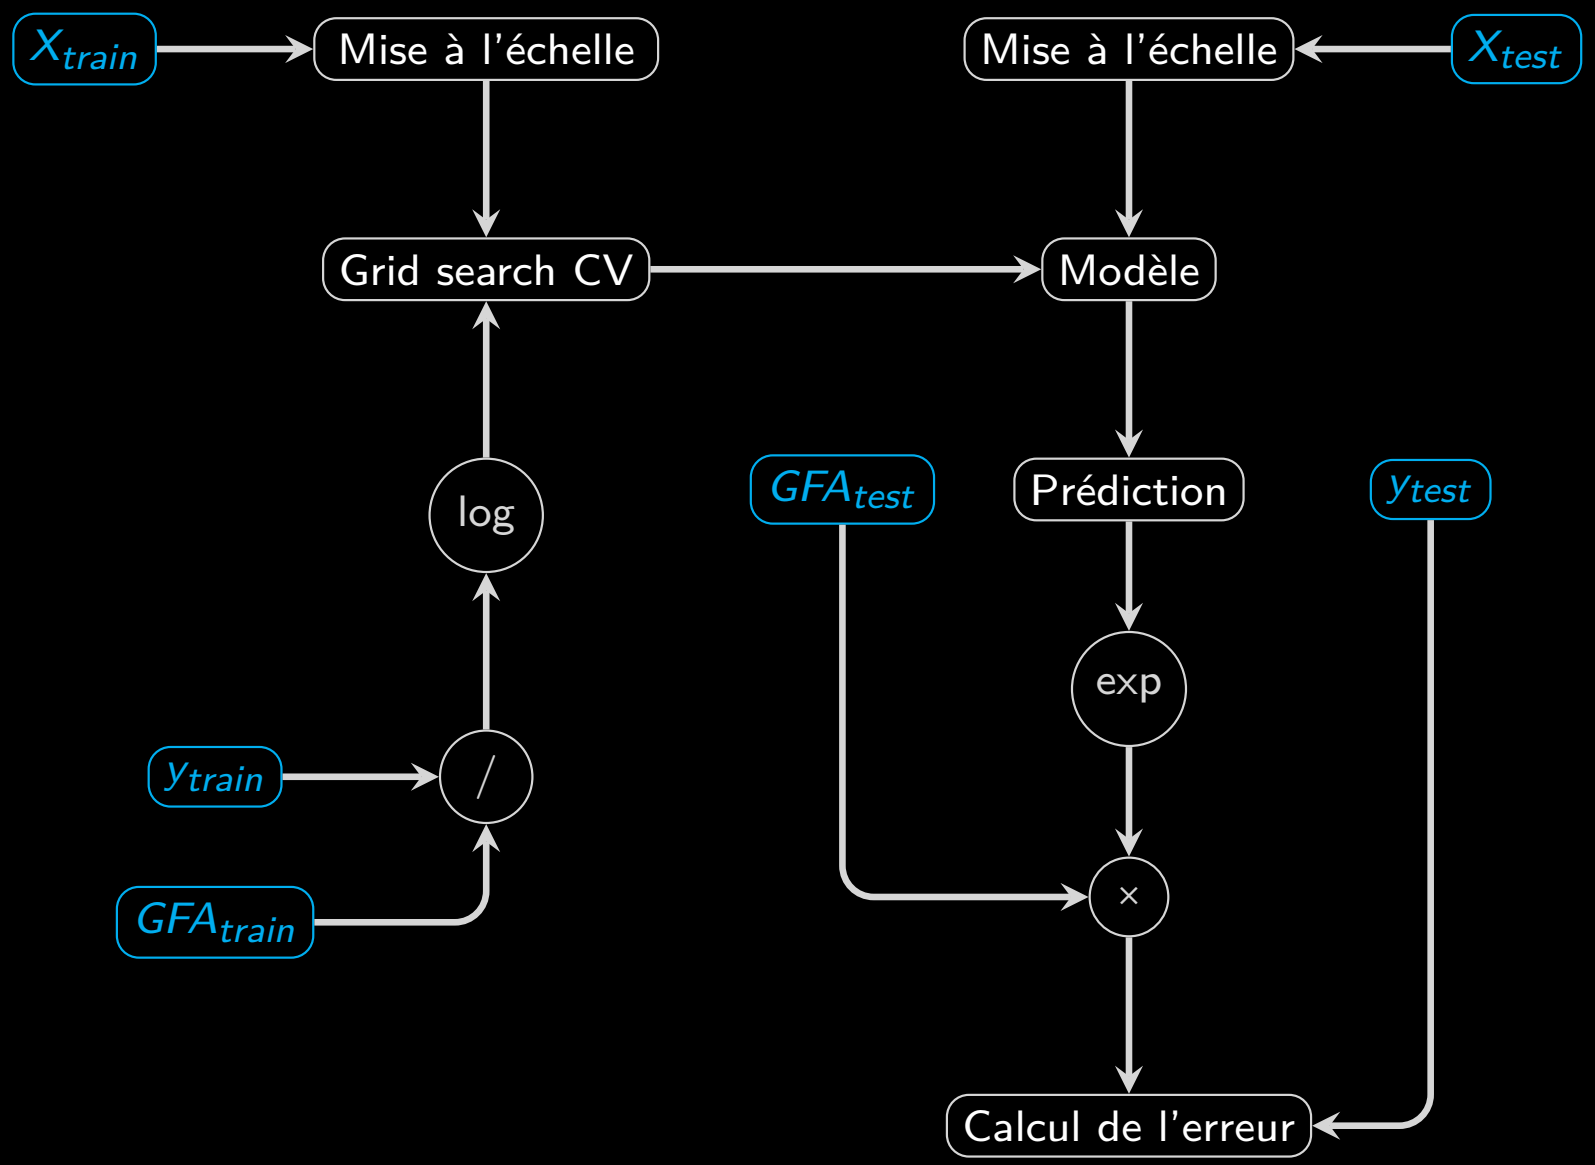
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
log
GFA_{test}
Prédiction
y_{test}
exp
y_{train}
/
×
GFA_{train}
Calcul de l'erreur

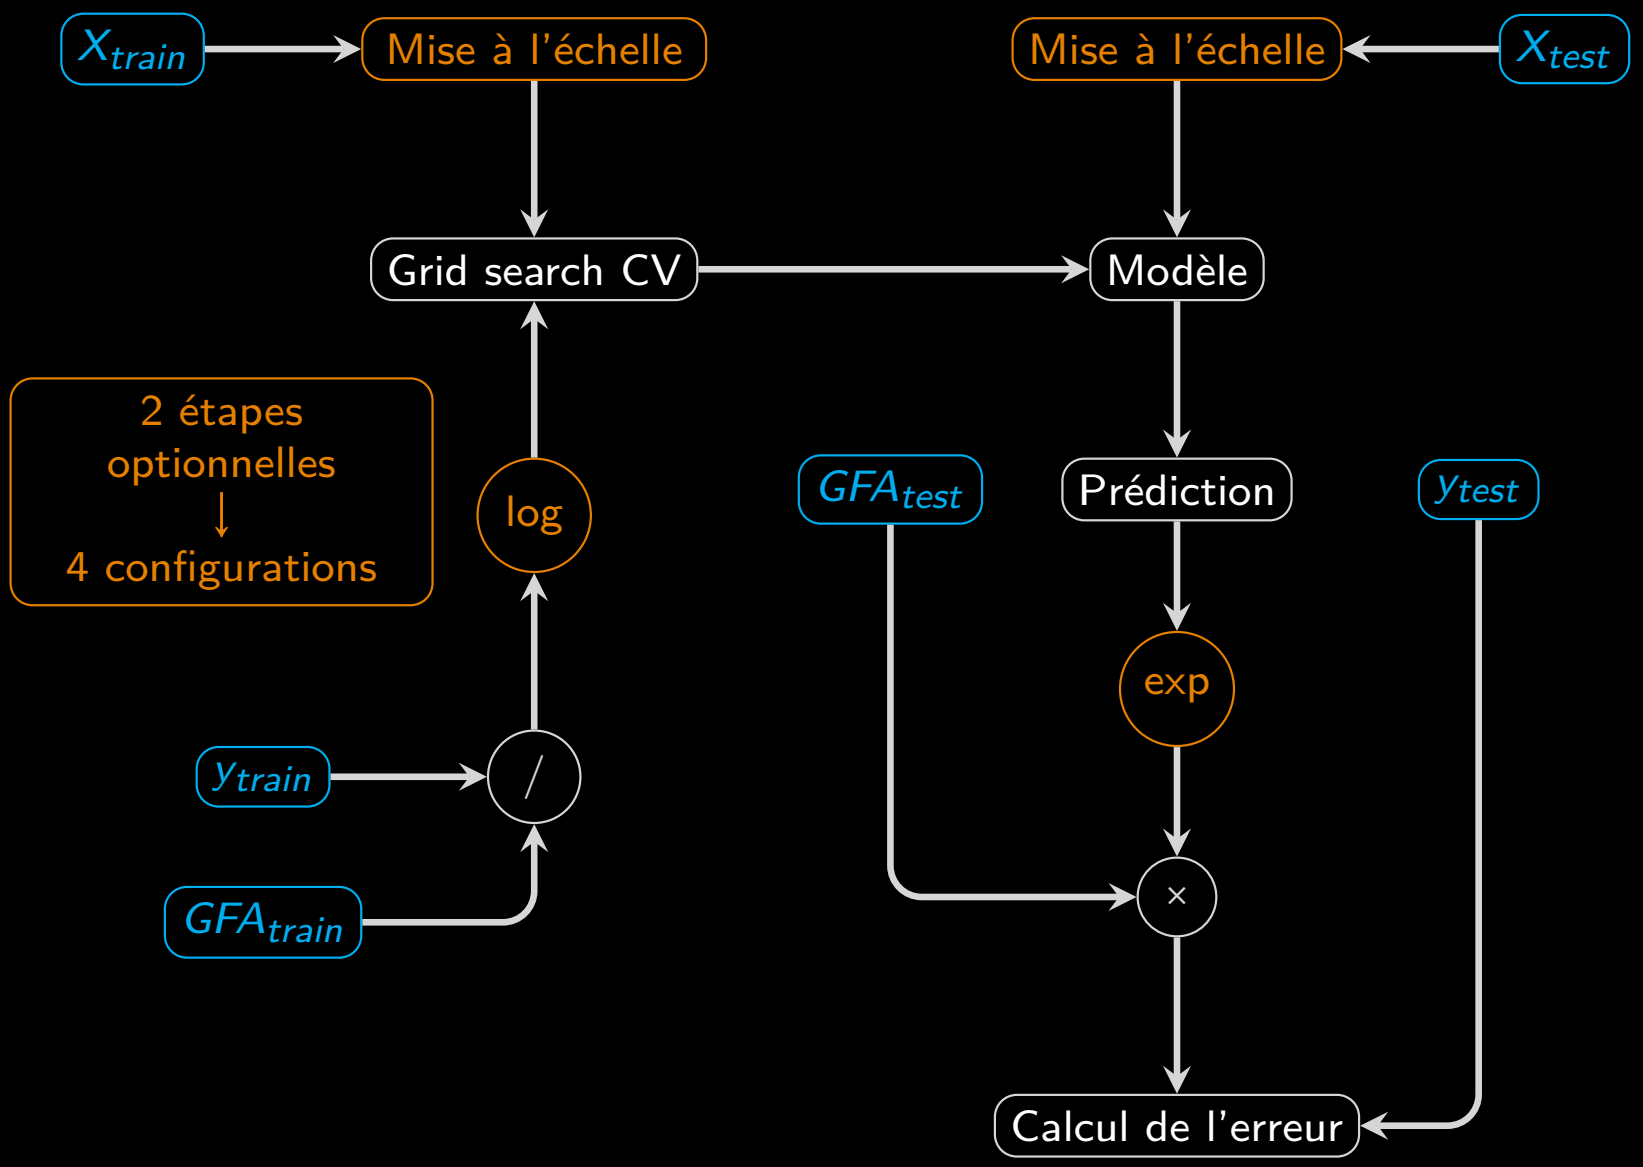
X_{train}
Mise à l'échelle
Mise à l'échelle
X_{test}
Grid search CV
Modèle
2 étapes
optionnelles
↓
4 configurations
log
GFA_{test}
Prédiction
y_{test}
exp
y_{train}
/
×
GFA_{train}
Calcul de l'erreur

8 modèles

dummy
regressor

8 modèles

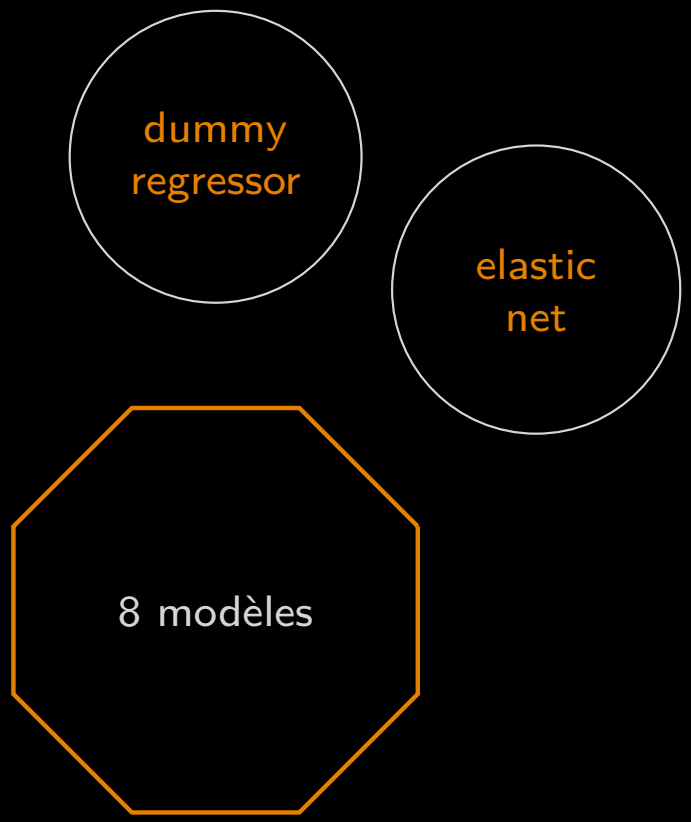
dummy
regressor
elastic
net
8 modèles

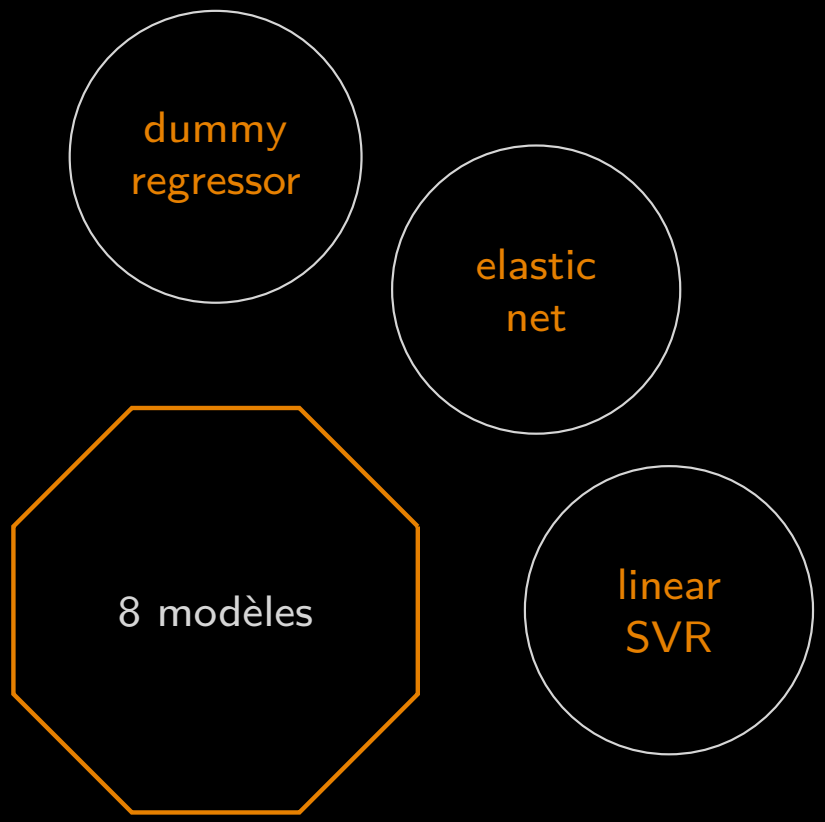
dummy
regressor
elastic
net
8 modèles
linear
SVR

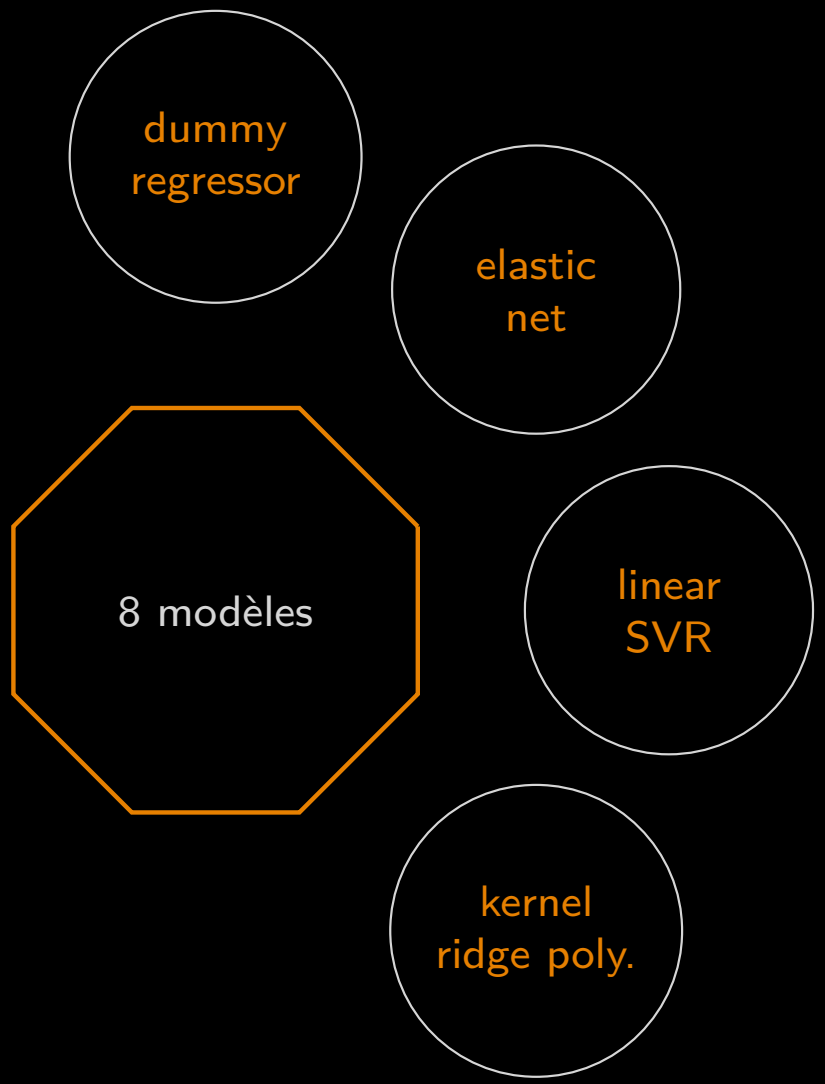
dummy
regressor
elastic
net
8 modèles
linear
SVR
kernel
ridge poly.

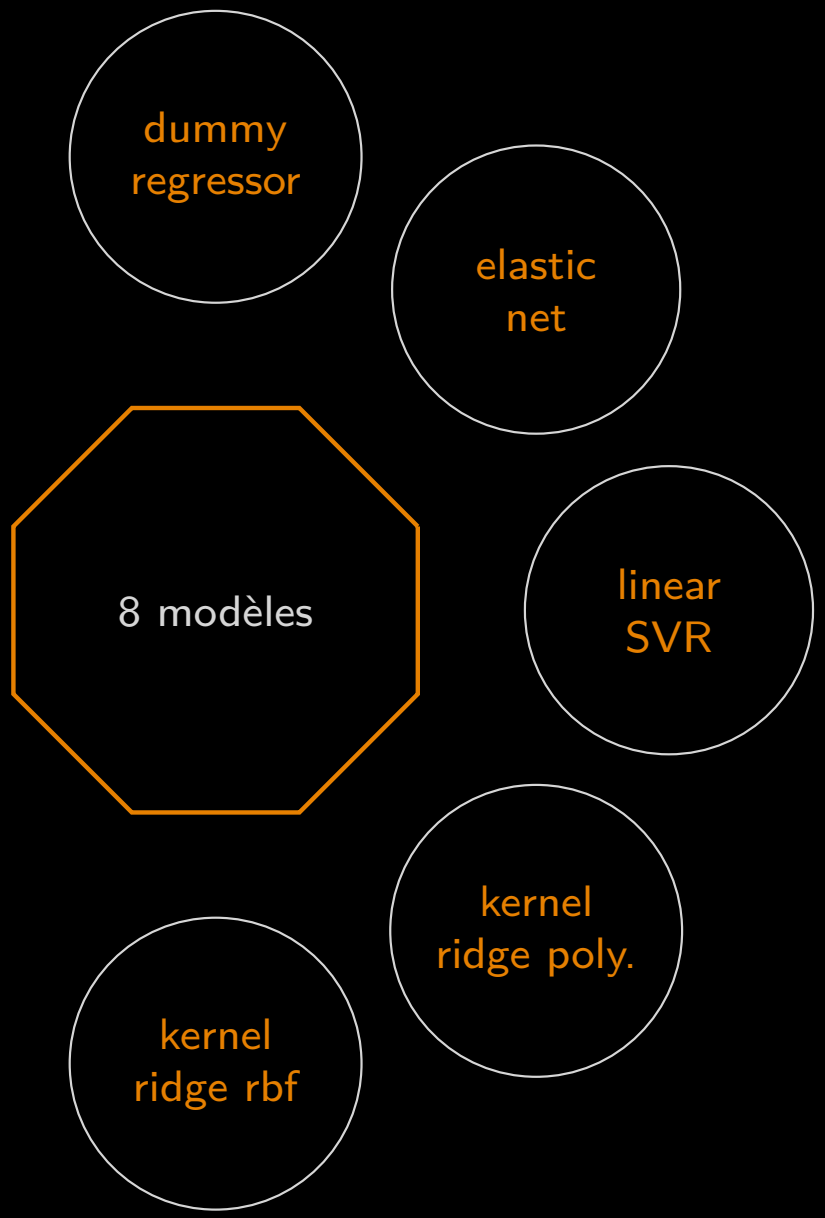
dummy
regressor
elastic
net
8 modèles
linear
SVR
kernel
ridge poly.
kernel
ridge rbf

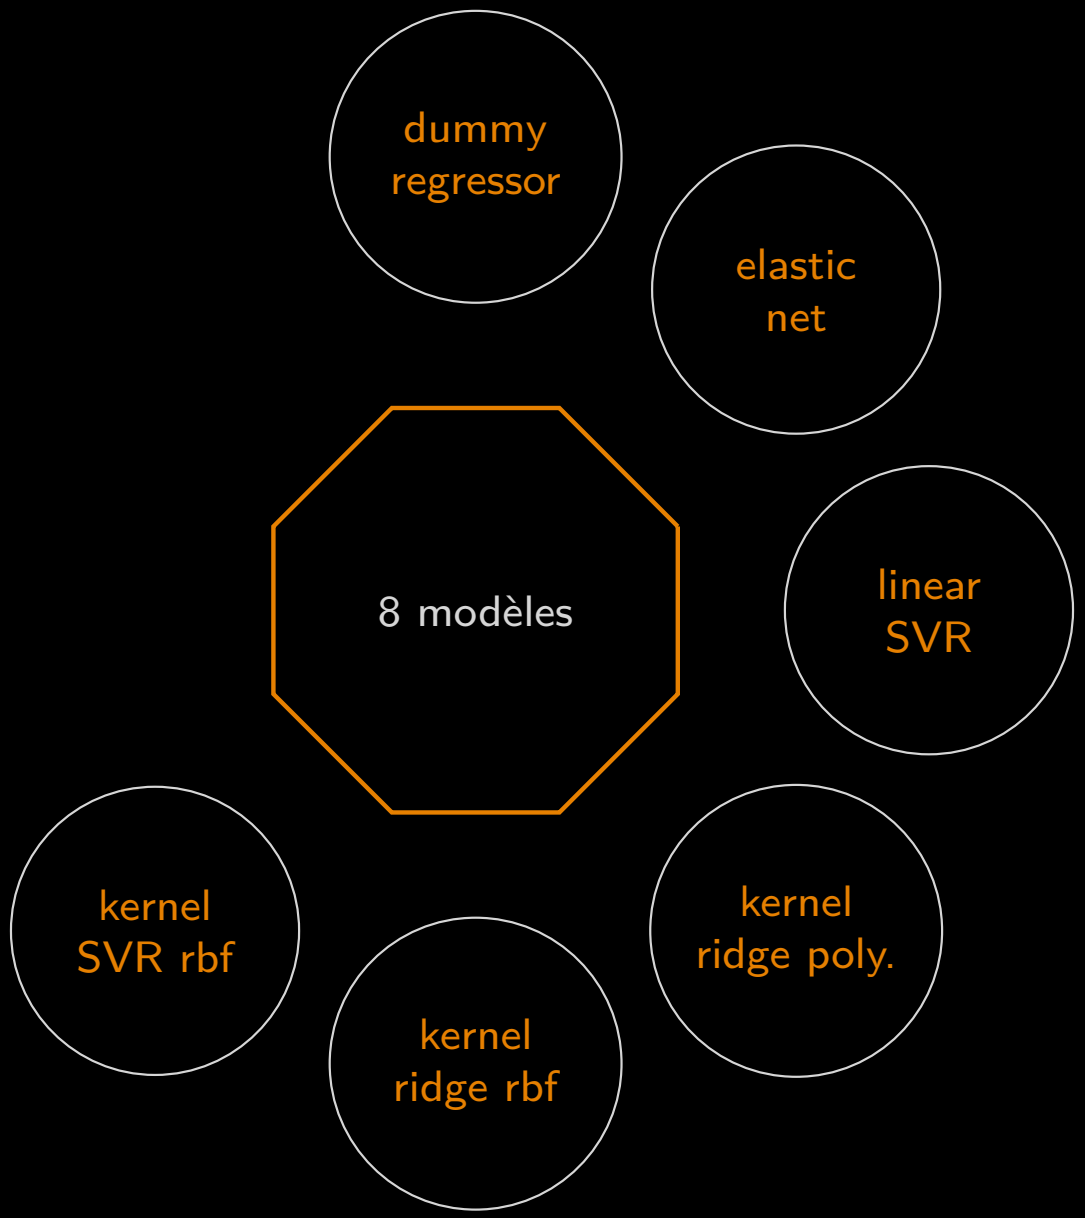
dummy regressor
elastic net
8 modèles
linear SVR
kernel SVR rbf
kernel ridge rbf
kernel ridge poly.

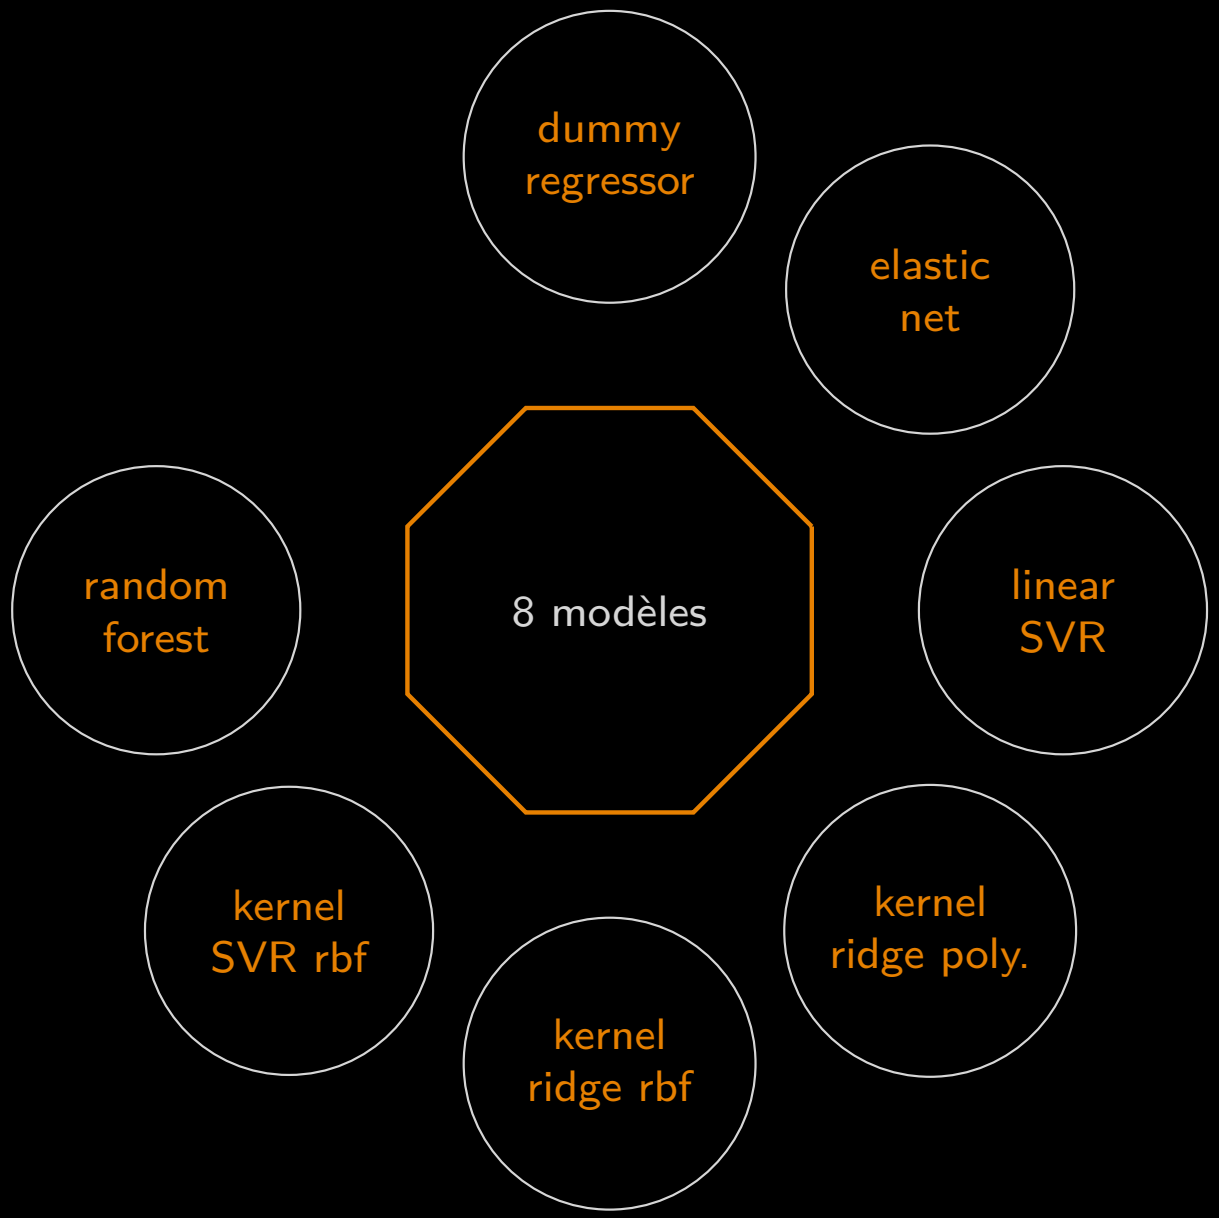
dummy regressor
elastic net
random forest
8 modèles
linear SVR
kernel SVR rbf
kernel ridge poly.
kernel ridge rbf

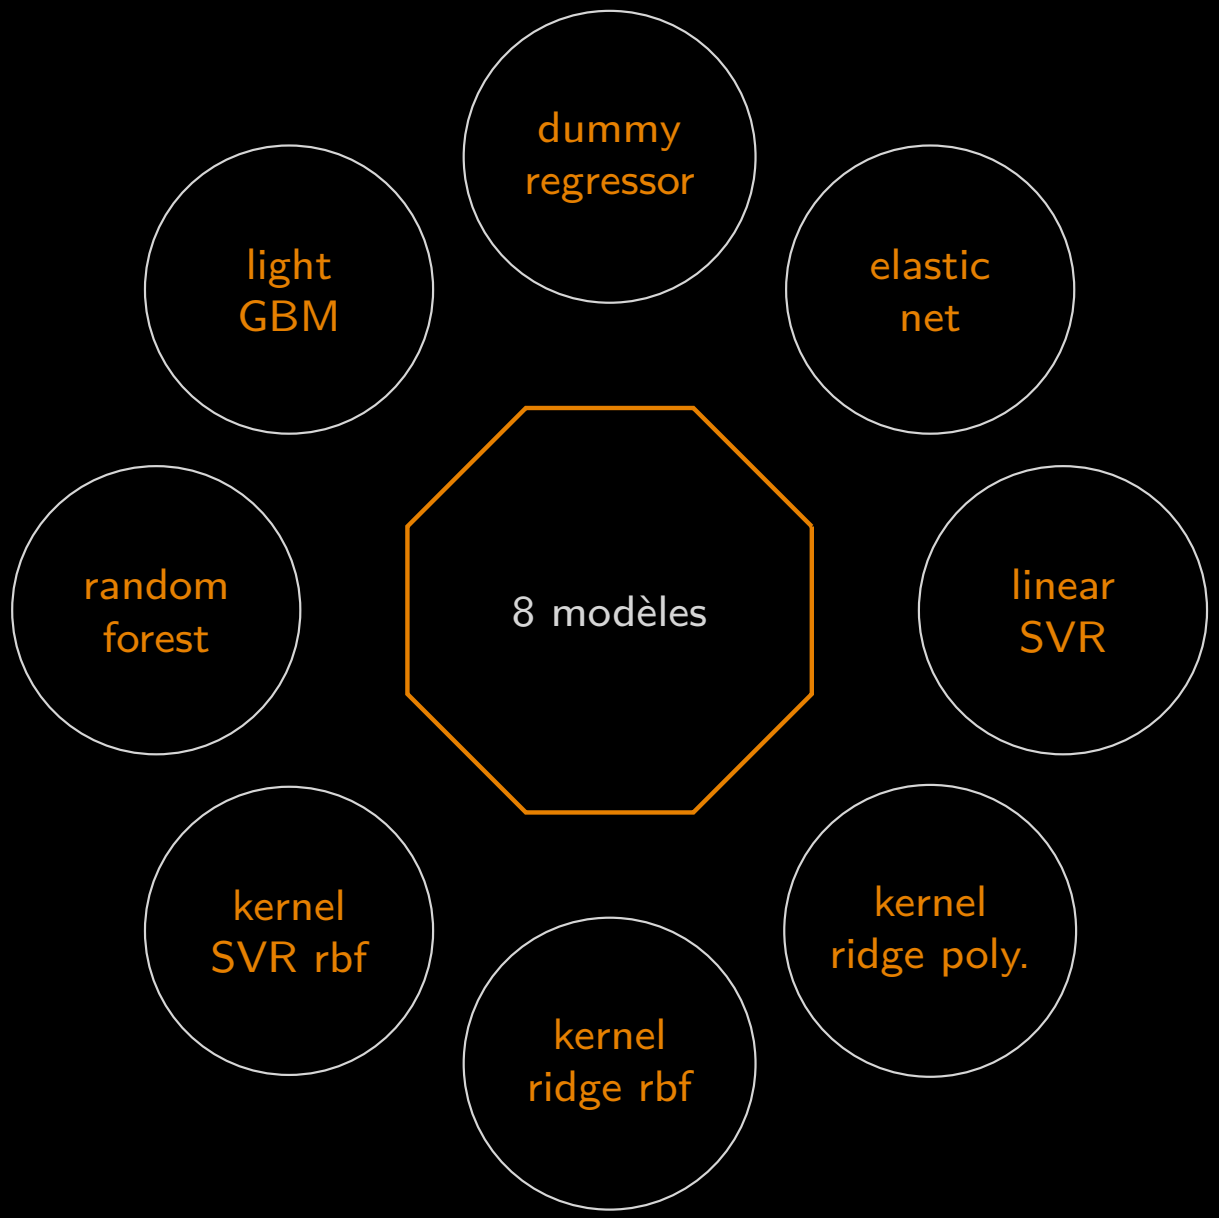
dummy regressor
light GBM
elastic net
random forest
8 modèles
linear SVR
kernel SVR rbf
kernel ridge poly.
kernel ridge rbf

strategy

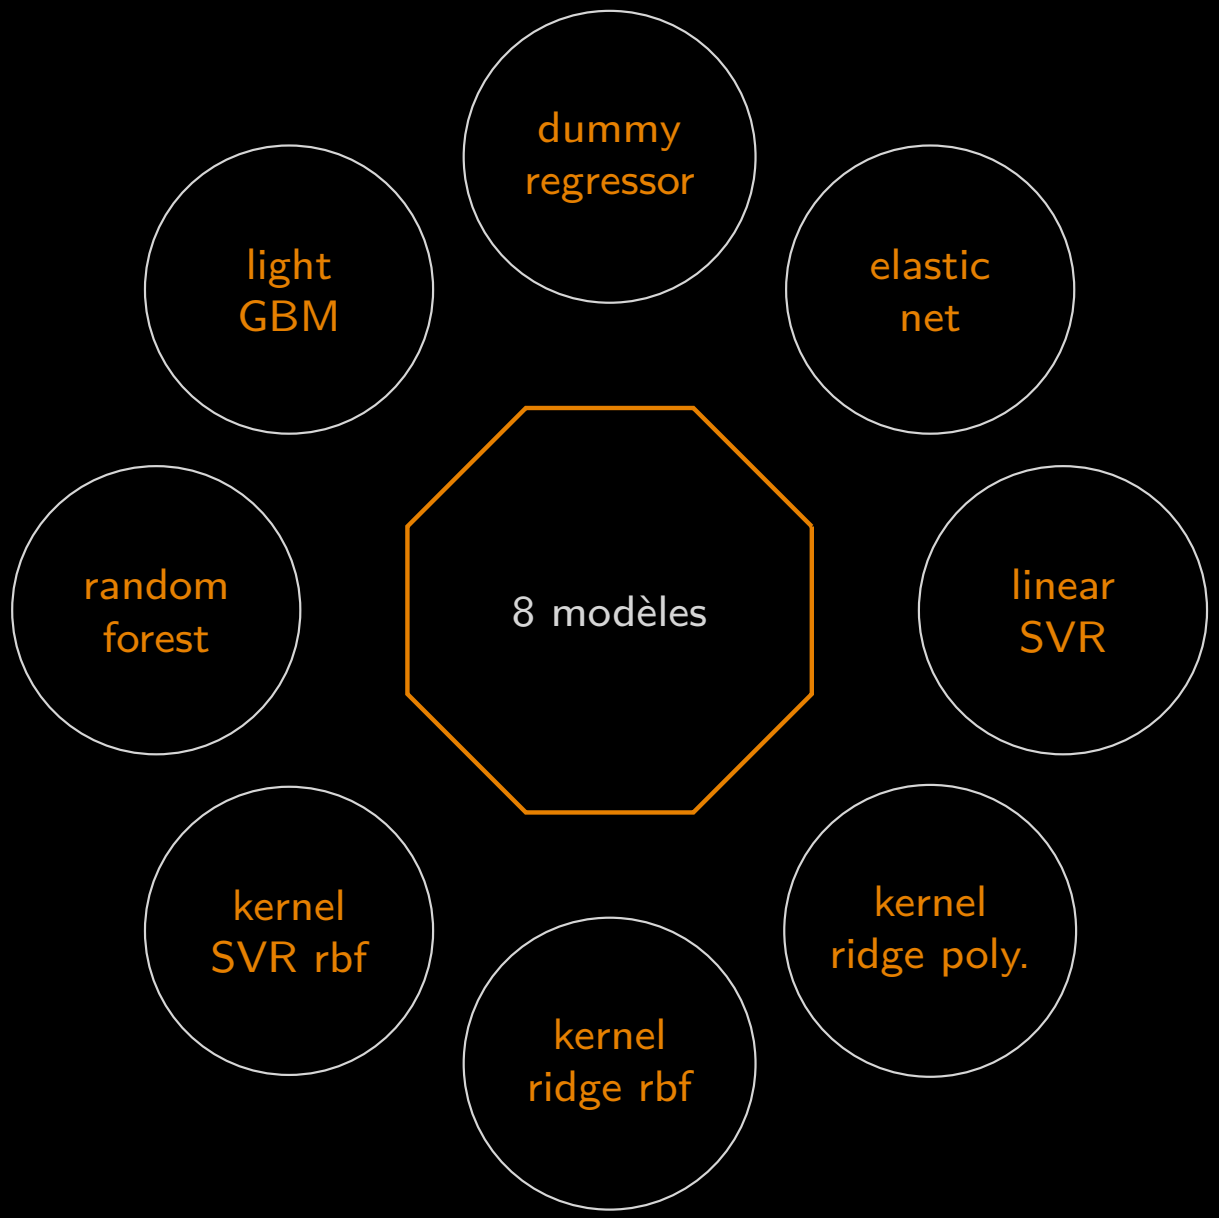
dummy regressor
elastic net
linear SVR
kernel ridge poly.
kernel ridge rbf
kernel SVR rbf
random forest
light GBM
8 modèles

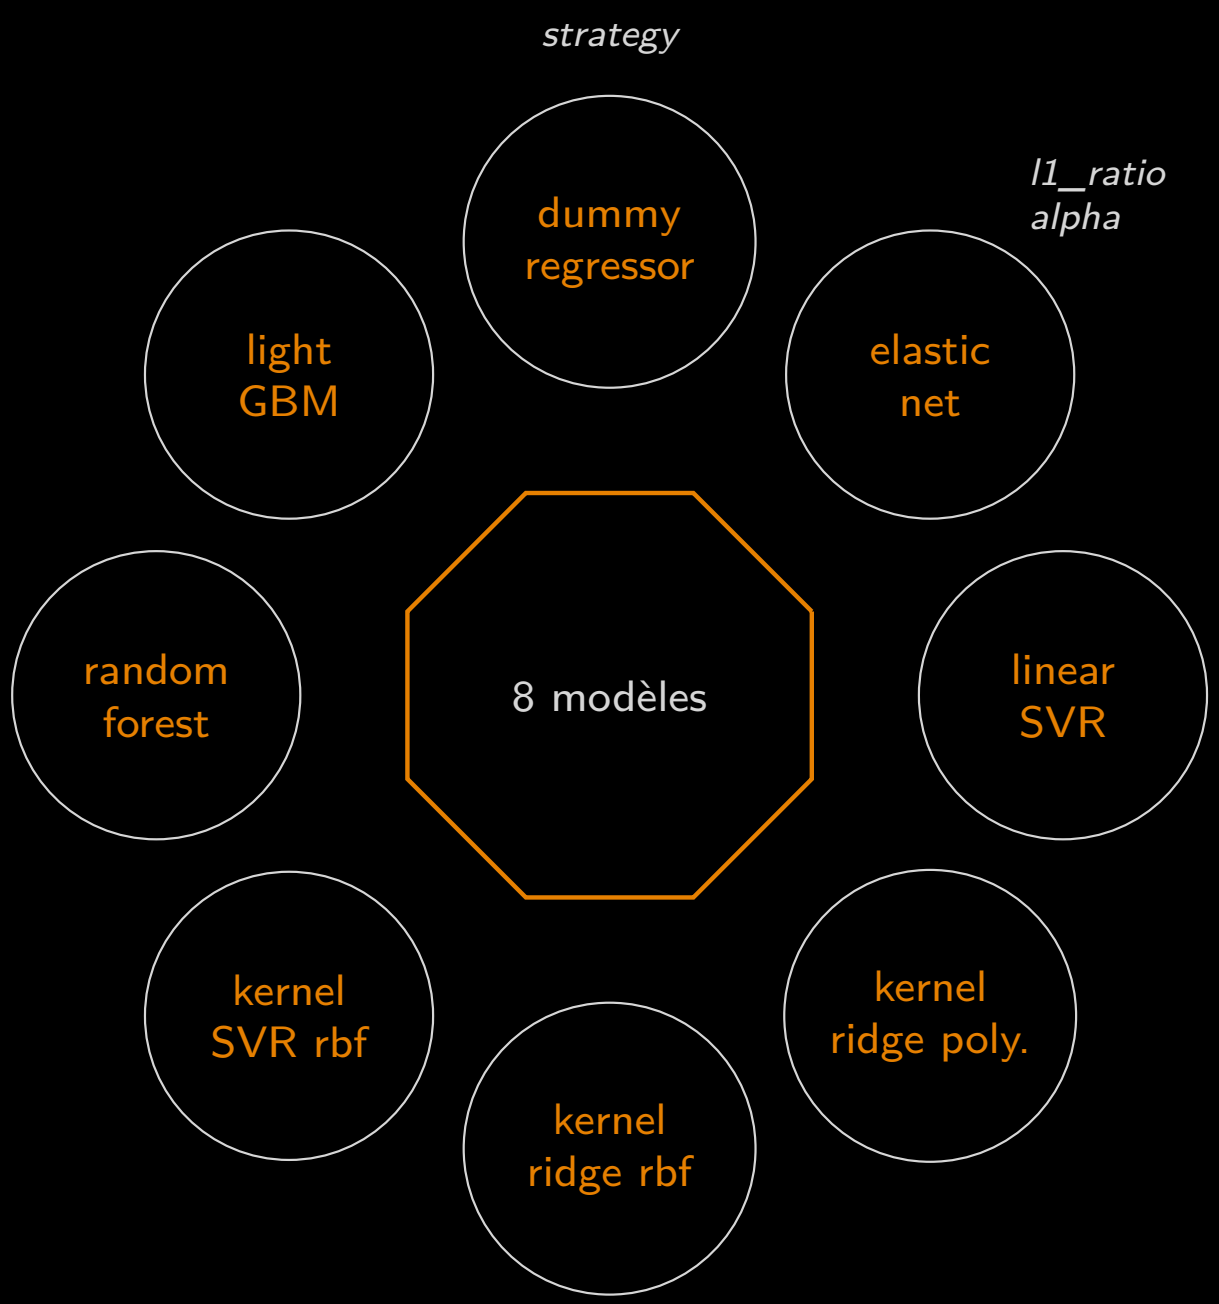
strategy
dummy regressor
l1_ratio
alpha
light GBM
elastic net
random forest
8 modèles
linear SVR
kernel SVR rbf
kernel ridge poly.
kernel ridge rbf

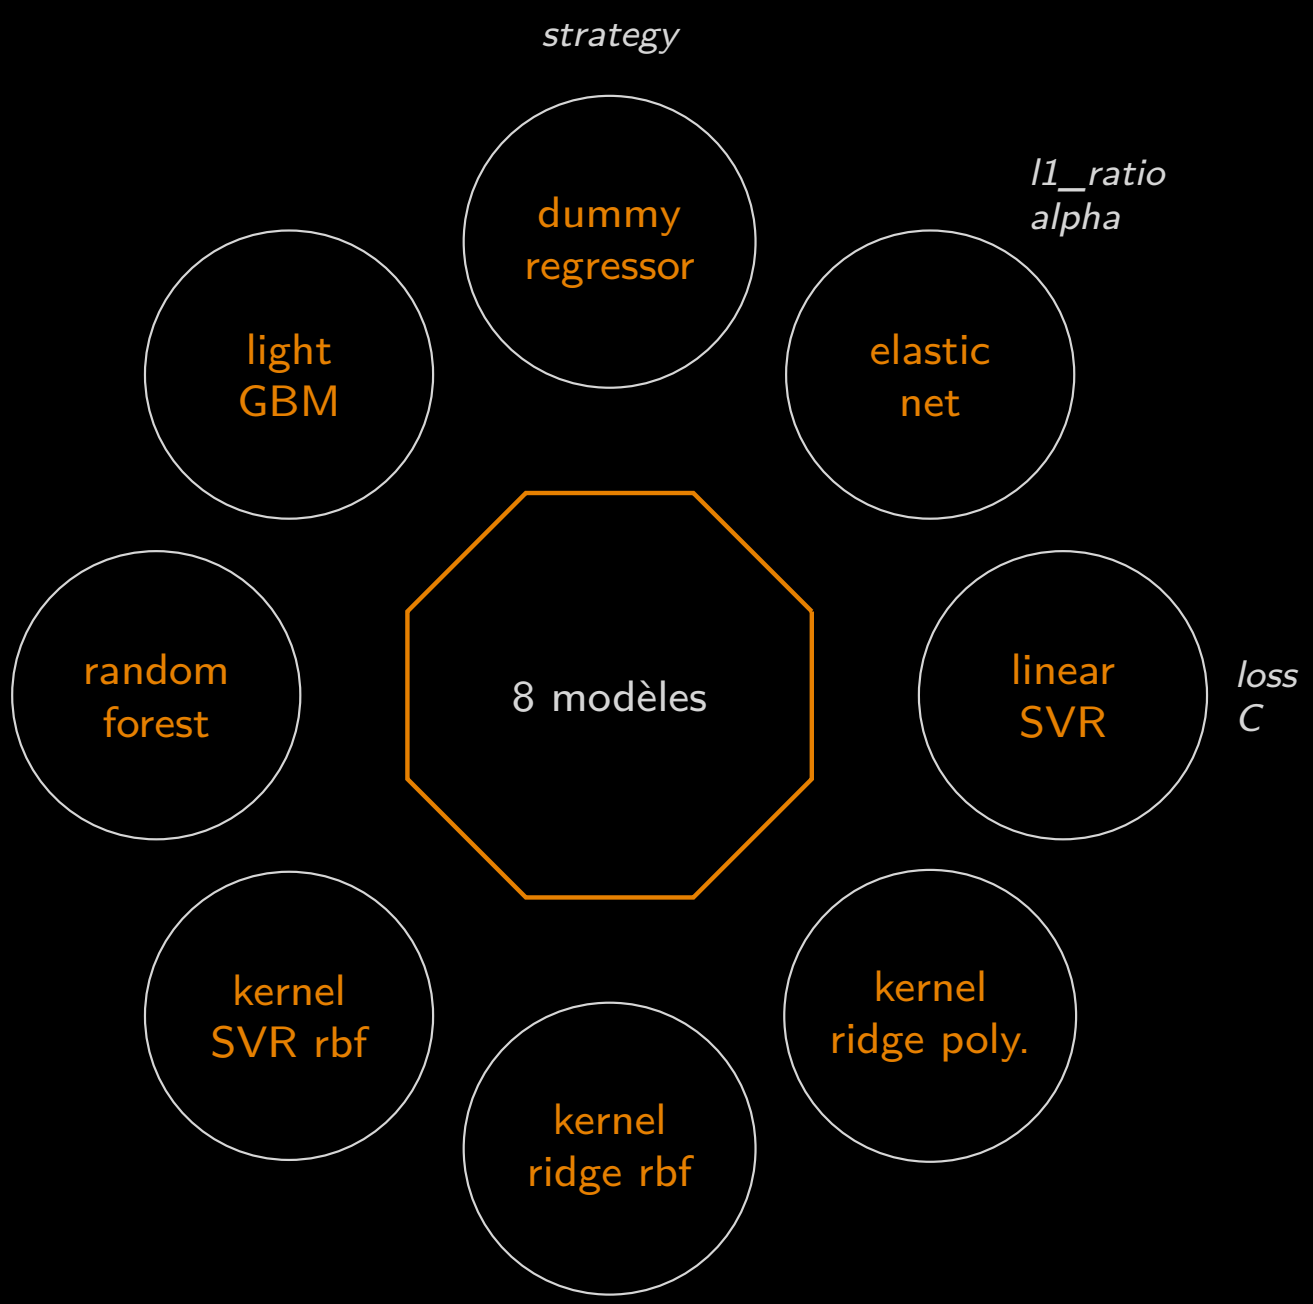
strategy
dummy regressor
l1_ratio
alpha
elastic net
light GBM
8 modèles
random forest
linear SVR
loss
C
kernel SVR rbf
kernel ridge poly.
kernel ridge rbf

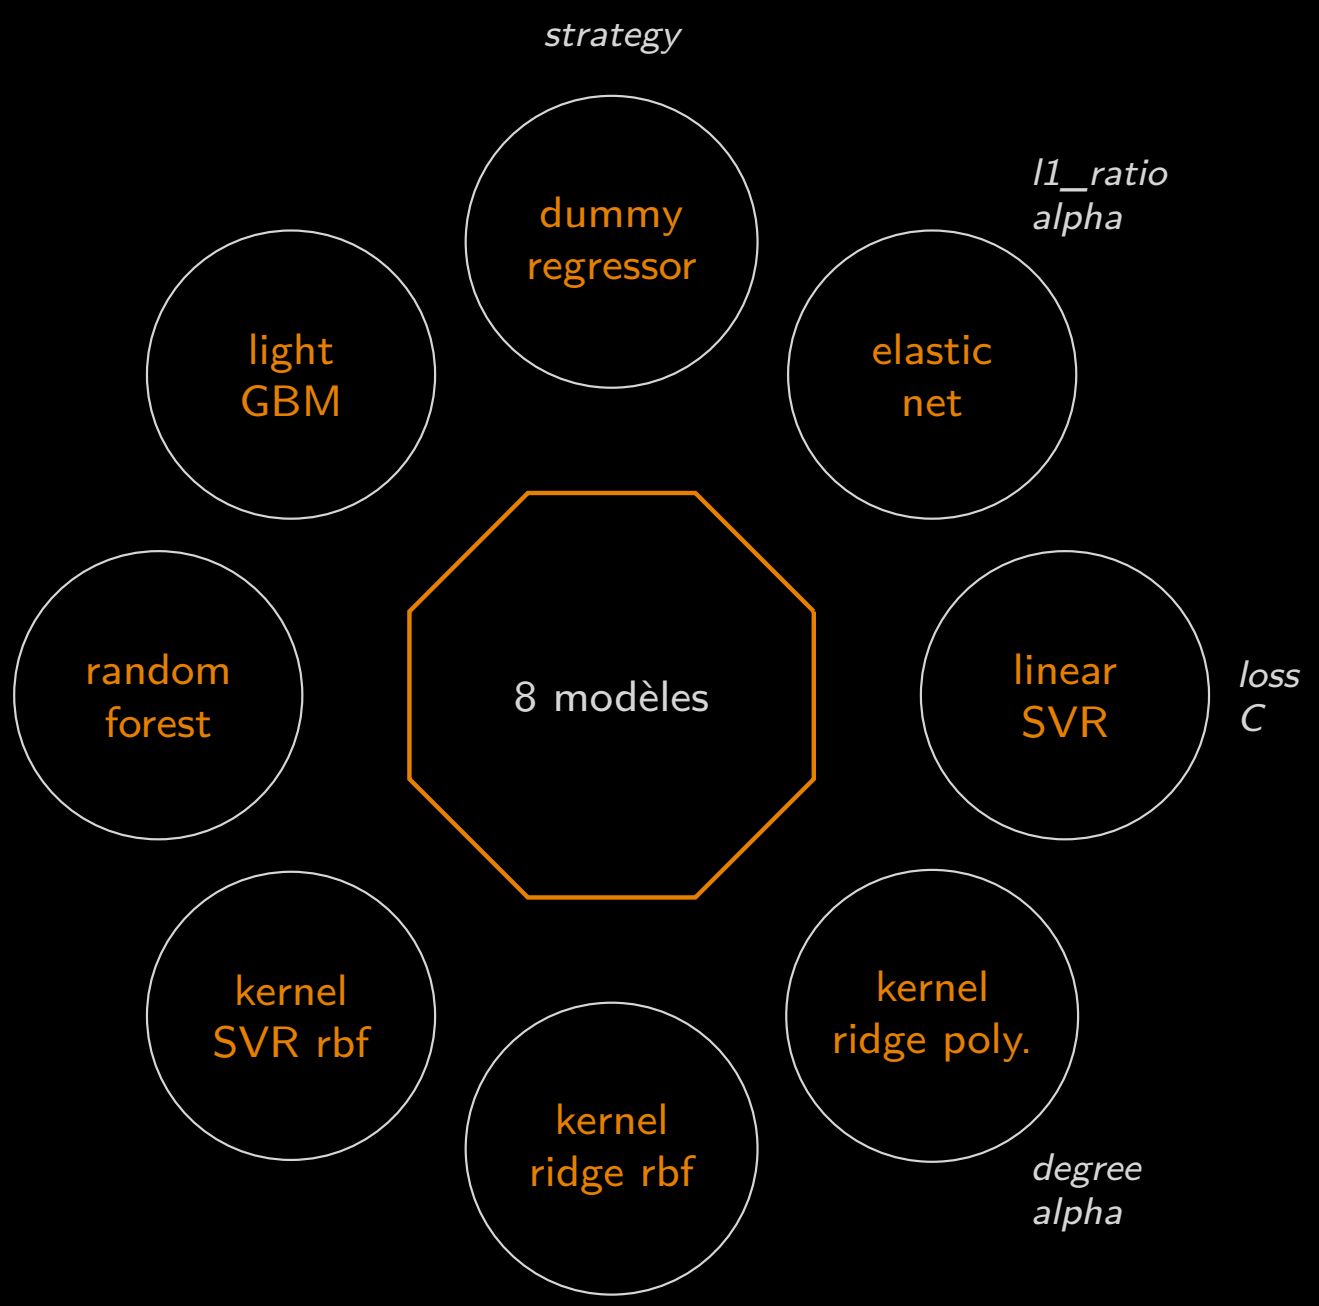
strategy
dummy regressor
l1_ratio
alpha
elastic net
light GBM
8 modèles
random forest
linear SVR
loss
C
kernel SVR rbf
kernel ridge rbf
kernel ridge poly.
degree
alpha

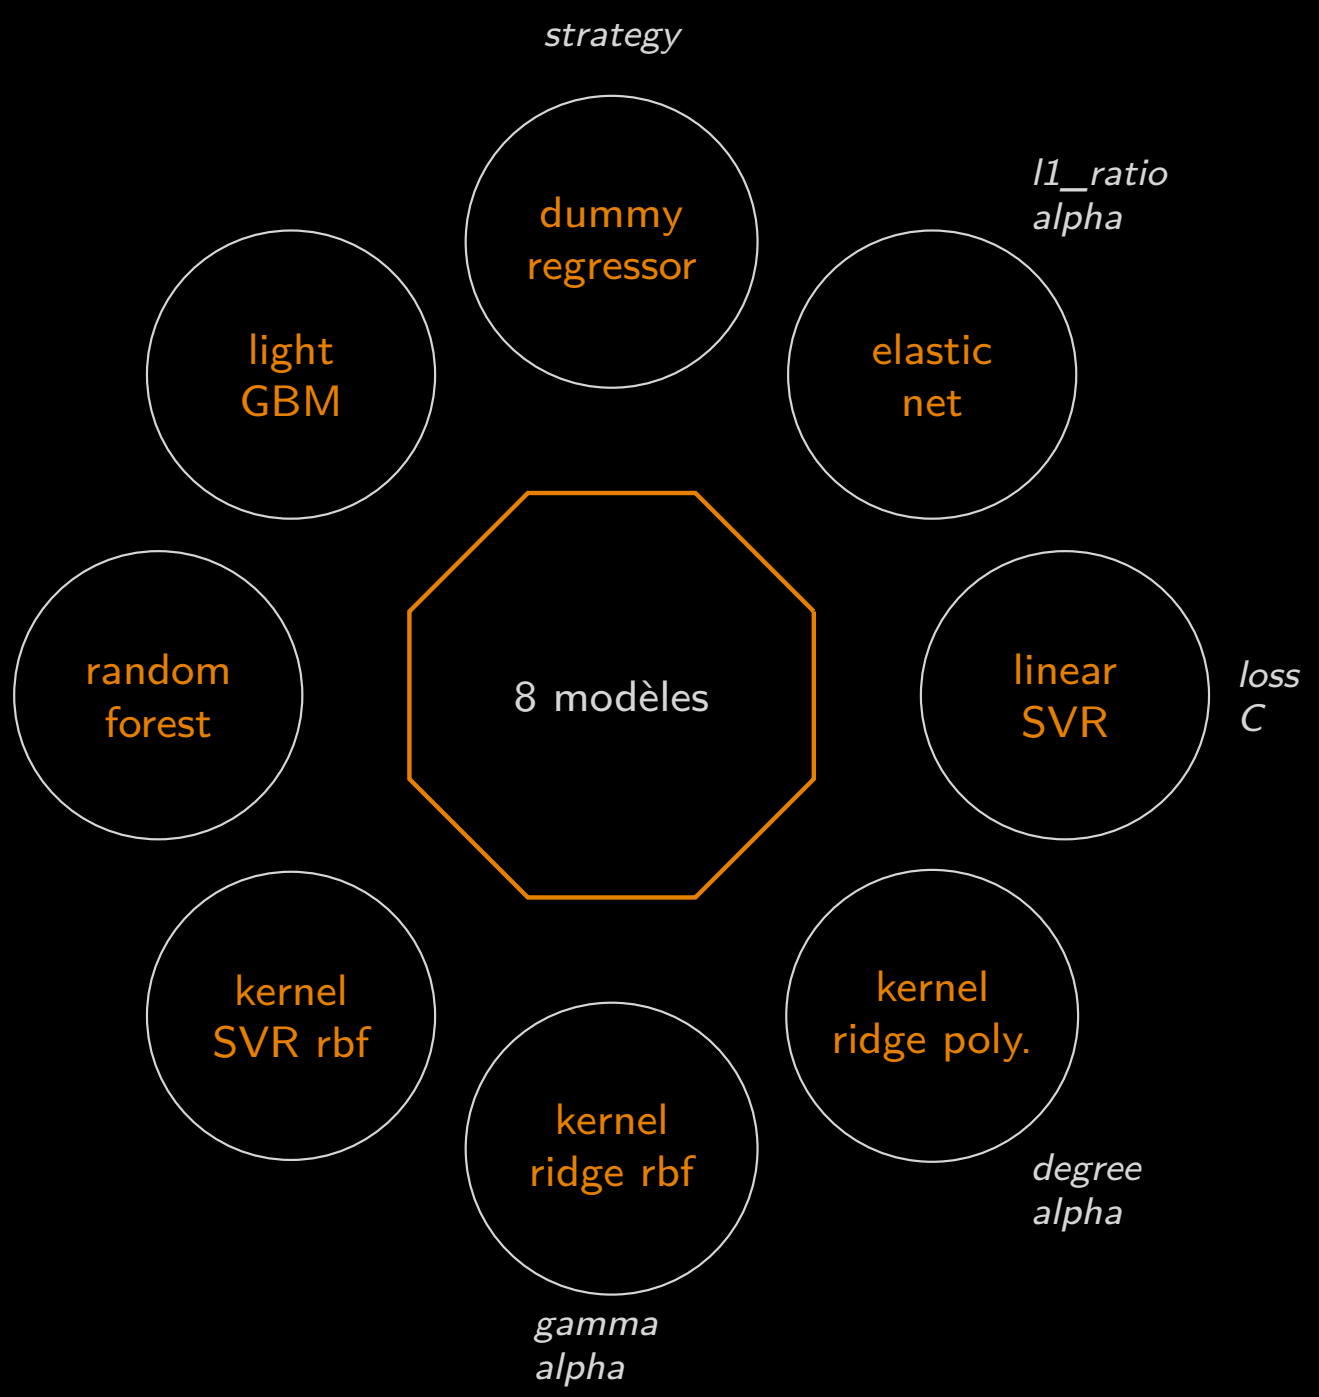
strategy
dummy regressor
l1_ratio
alpha
elastic net
light GBM
8 modèles
random forest
linear SVR
loss
C
kernel SVR rbf
kernel ridge poly.
kernel ridge rbf
degree
alpha
gamma
alpha

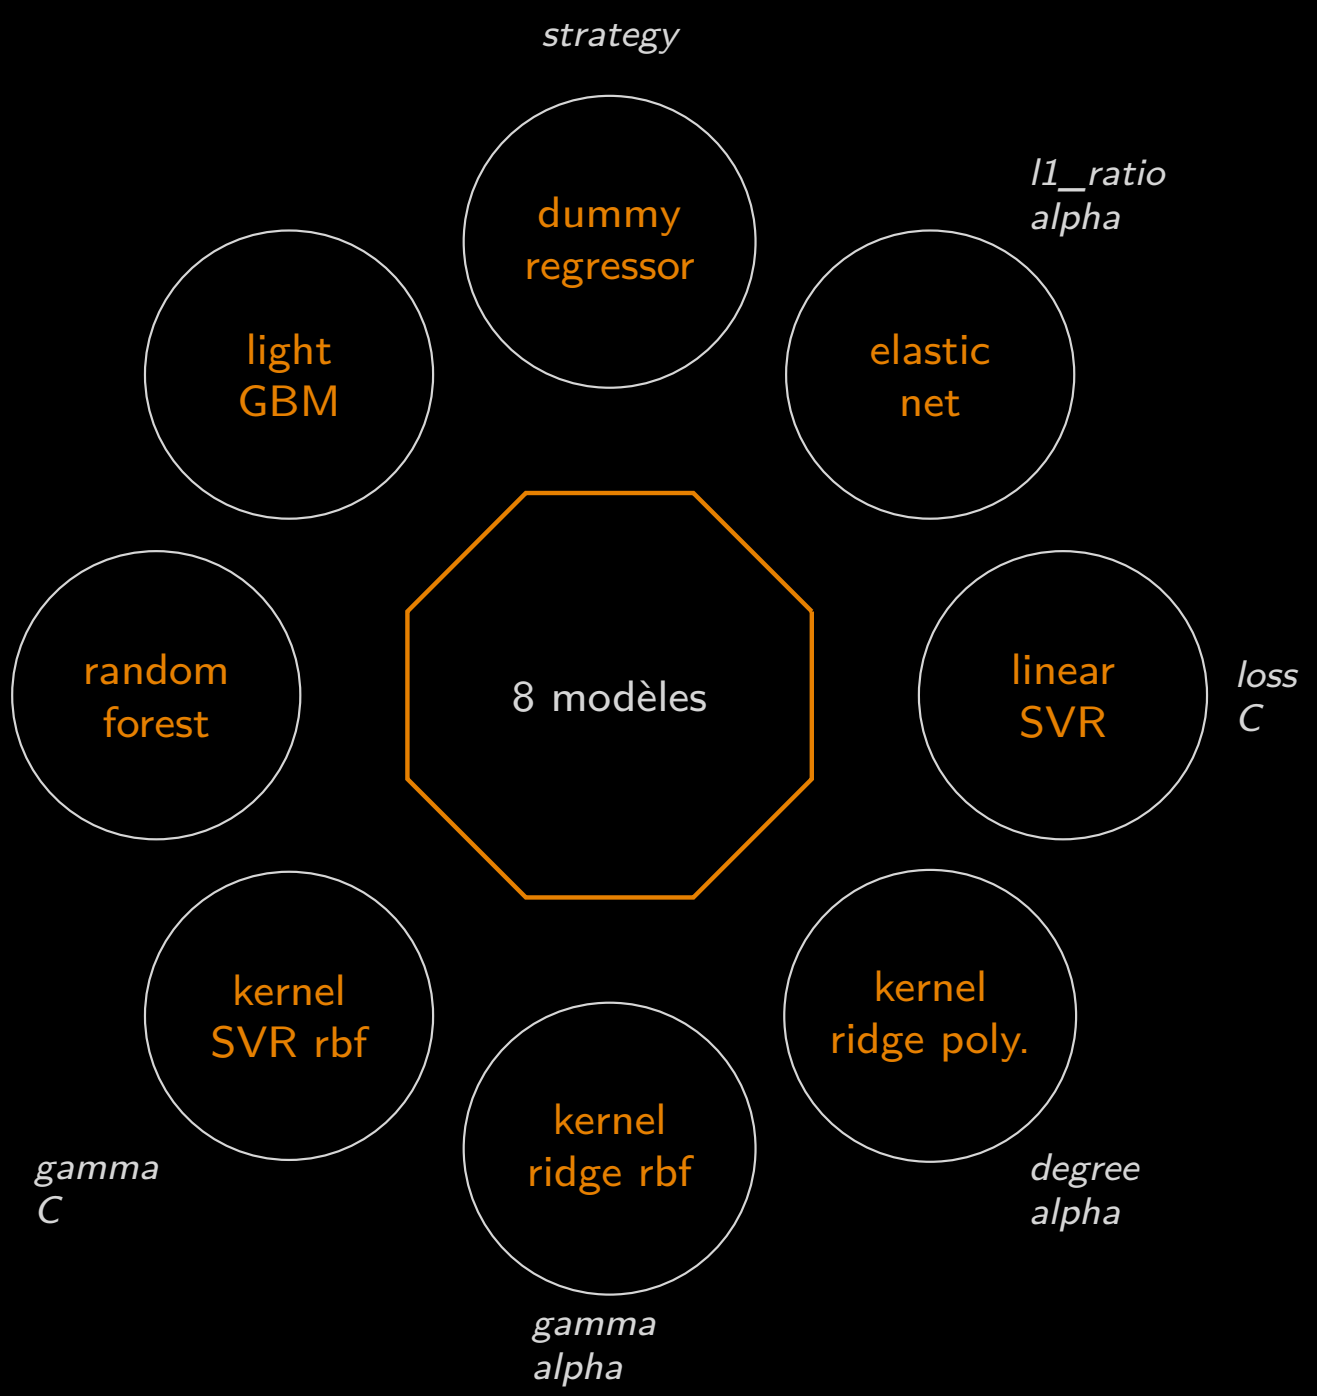
strategy
dummy regressor
l1_ratio
alpha
elastic net
light GBM
8 modèles
random forest
linear SVR
loss
C
kernel SVR rbf
kernel ridge poly.
gamma
C
kernel ridge rbf
degree
alpha
gamma
alpha

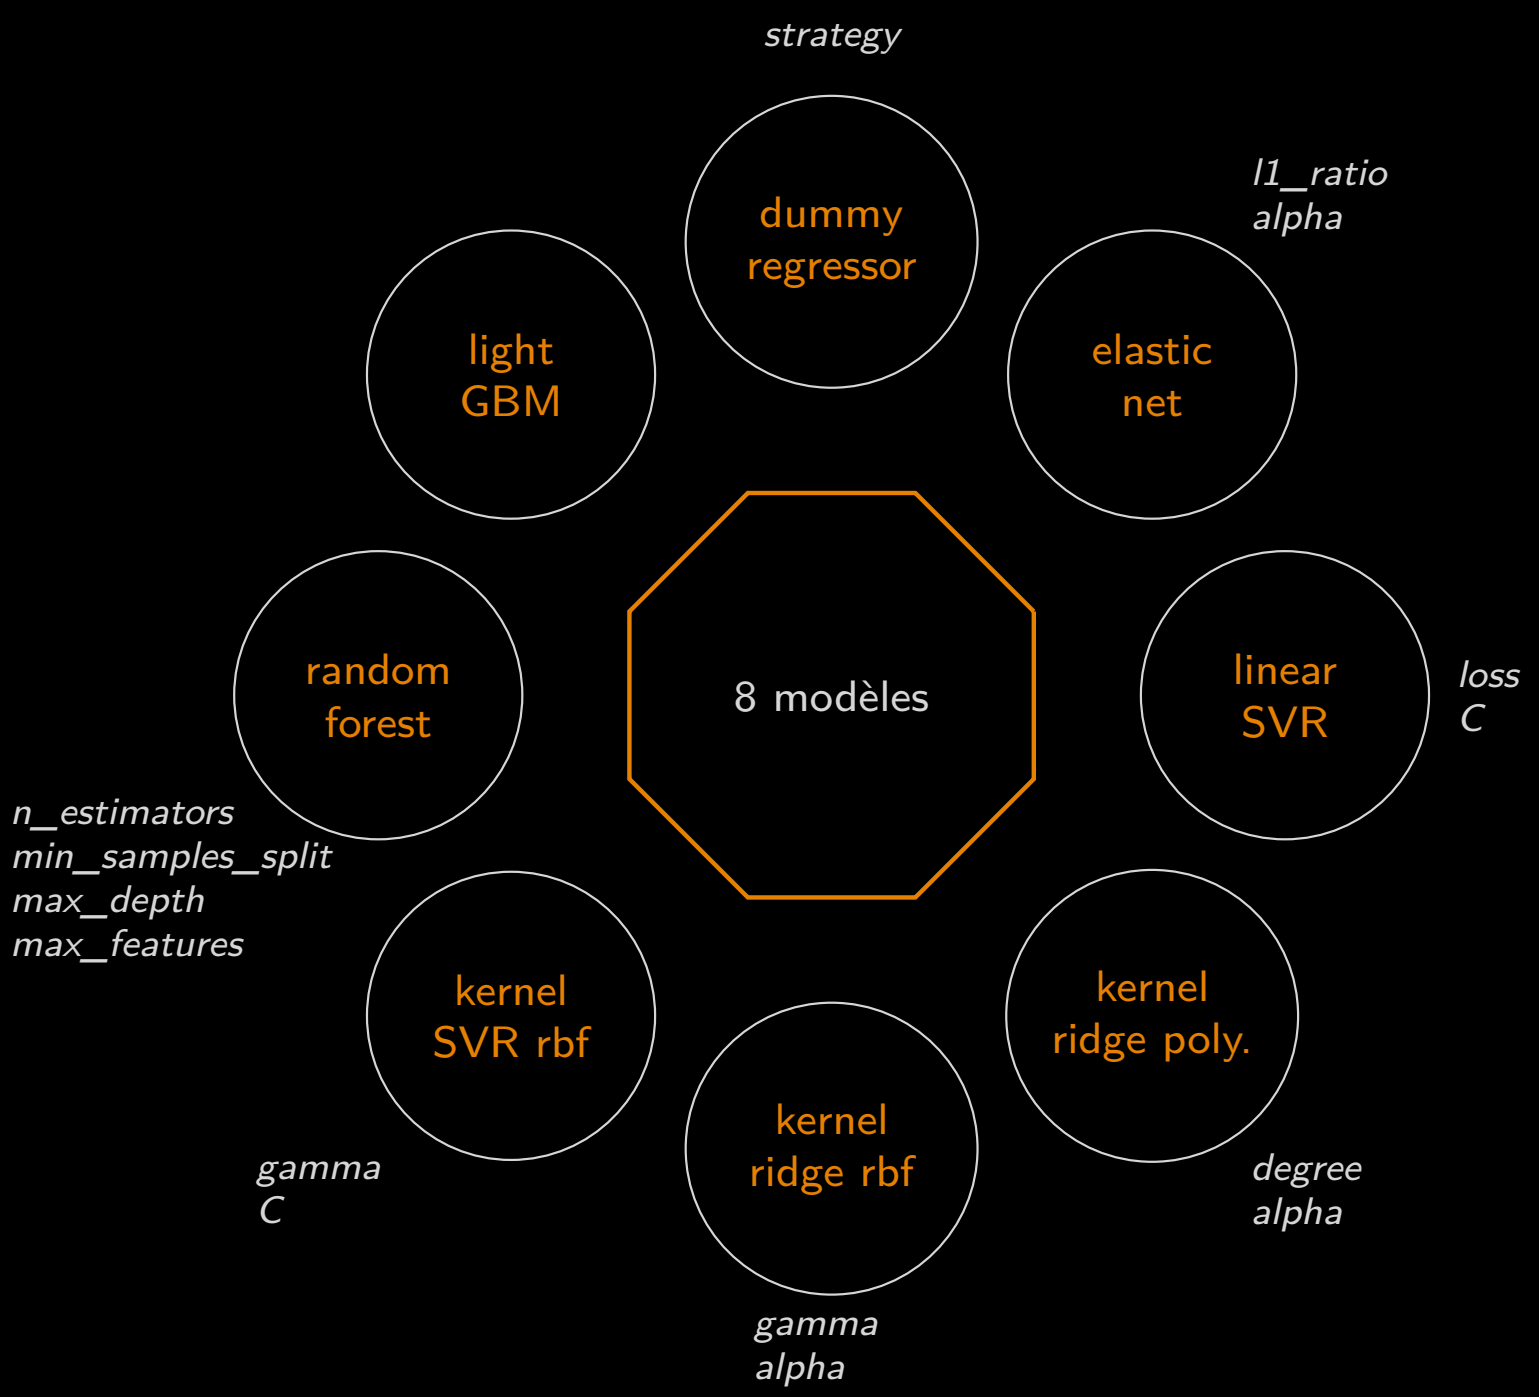
strategy
dummy regressor
l1_ratio
alpha
elastic net
light GBM
8 modèles
random forest
linear SVR
loss
C
n_estimators
min_samples_split
max_depth
max_features
kernel SVR rbf
kernel ridge poly.
gamma
C
kernel ridge rbf
degree
alpha
gamma
alpha

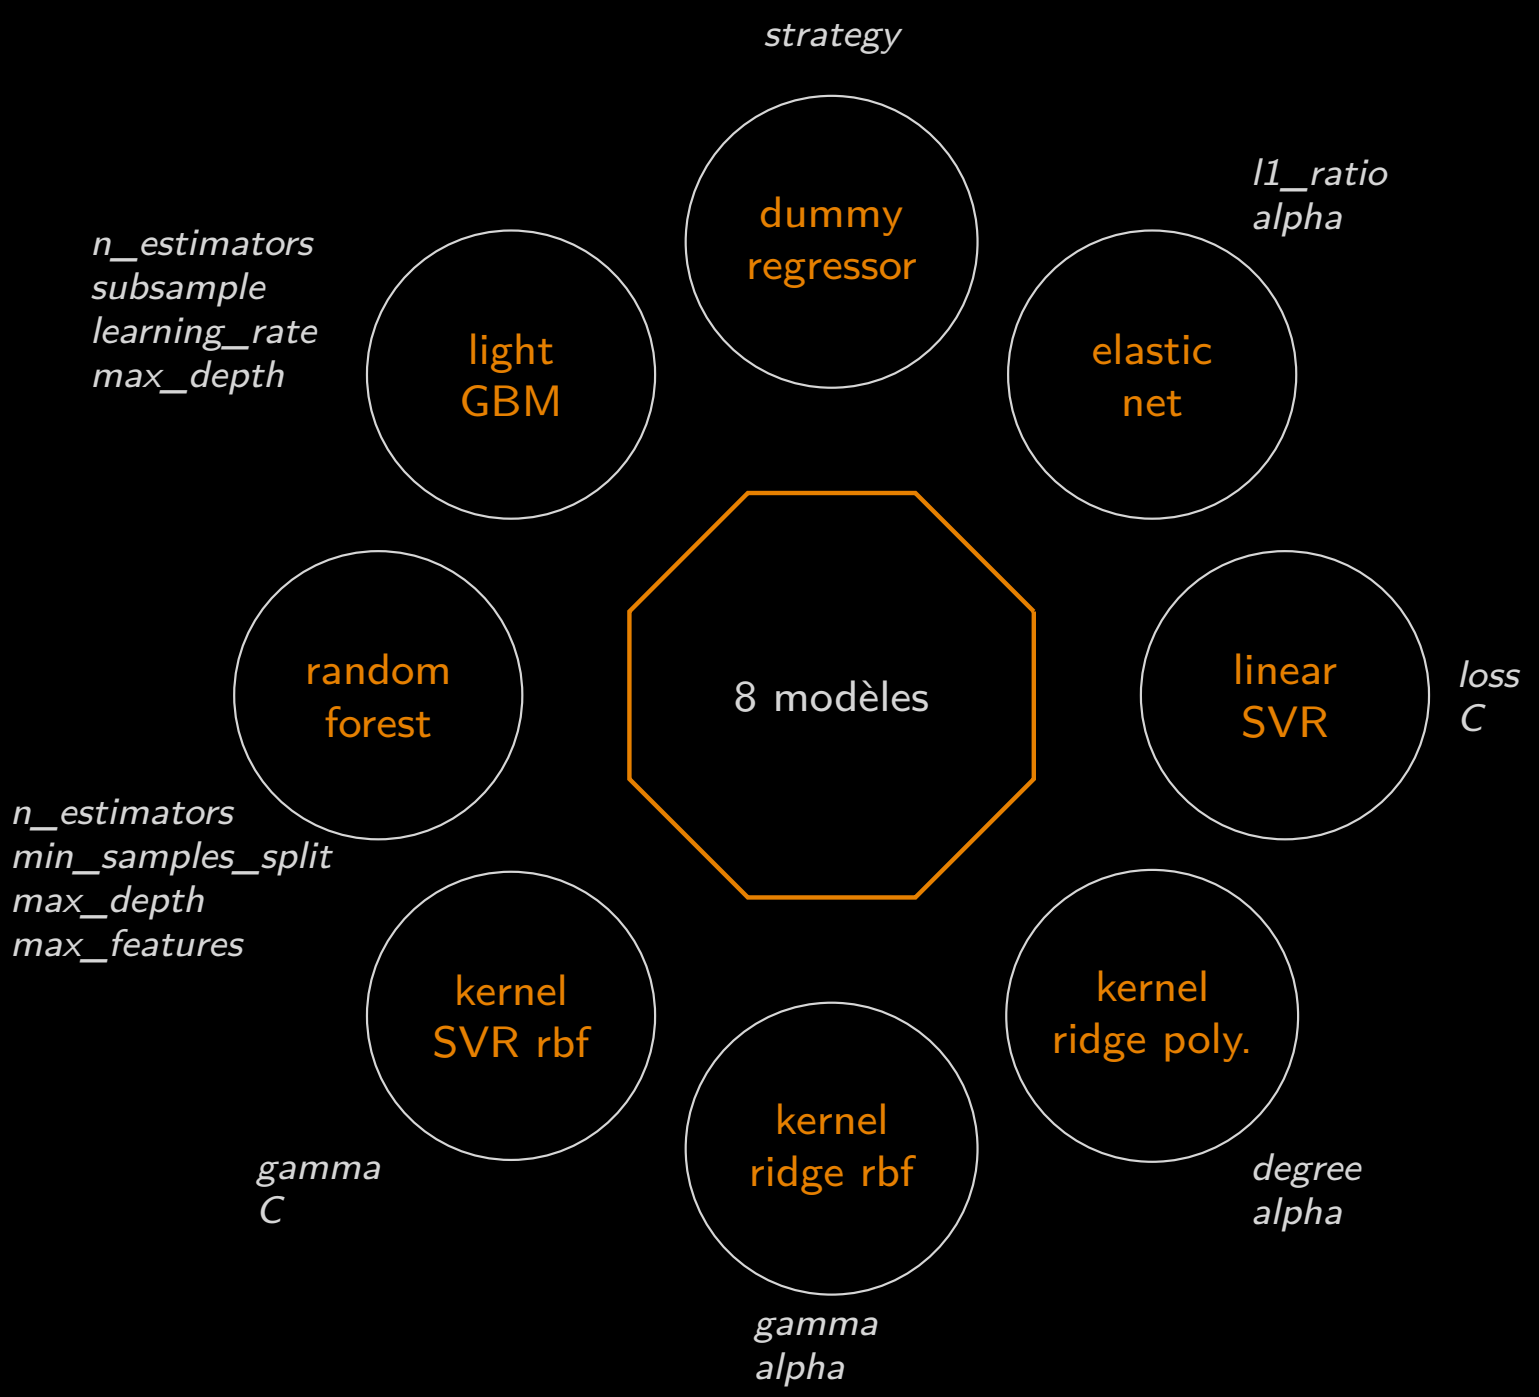
strategy
dummy regressor
l1_ratio
alpha
elastic net
n_estimators
subsample
learning_rate
max_depth
light GBM
8 modèles
random forest
linear SVR
loss
C
n_estimators
min_samples_split
max_depth
max_features
kernel SVR rbf
kernel ridge poly.
gamma
C
kernel ridge rbf
degree
alpha
gamma
alpha

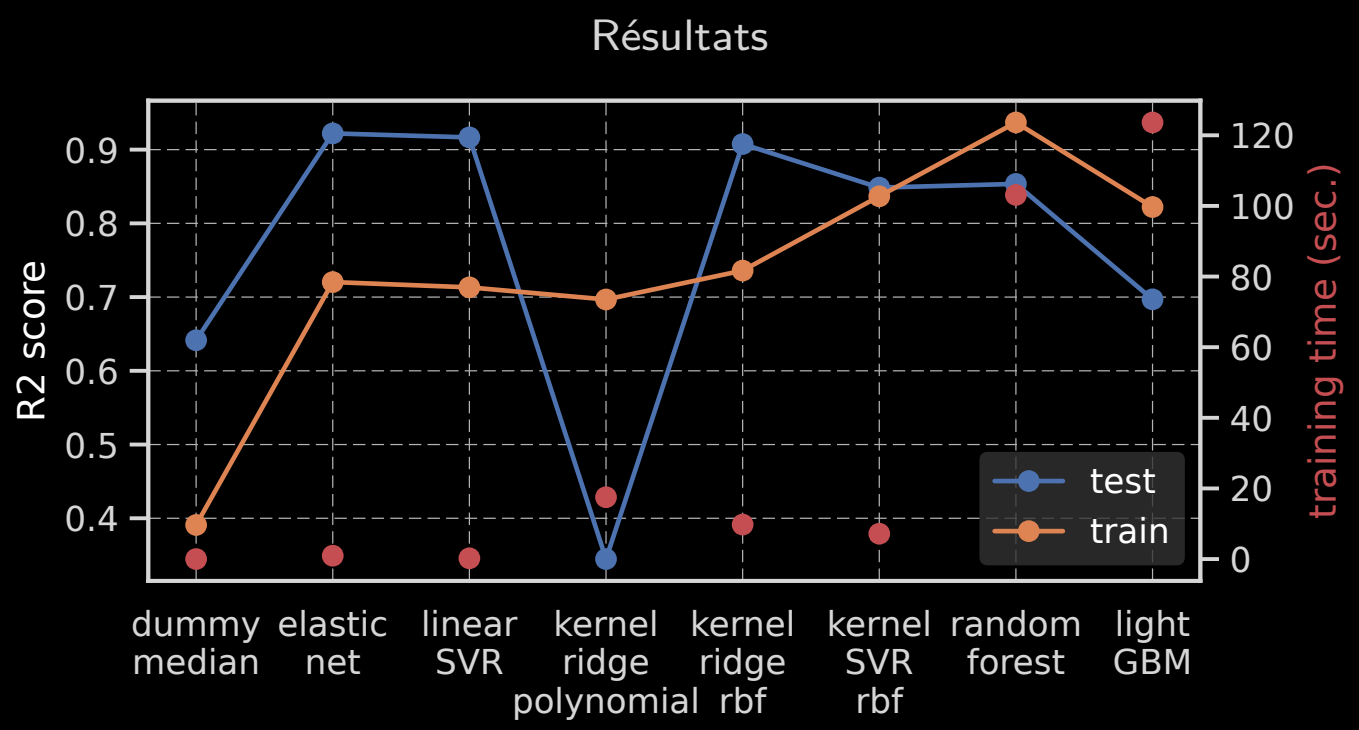
Résultats
R2 score
0.9
0.8
0.7
0.6
0.5
0.4
training time (sec.)
120
100
80
60
40
20
0
test
train
dummy median
elastic net
linear SVR
kernel ridge polynomial
kernel ridge rbf
kernel SVR rbf
random forest
light GBM

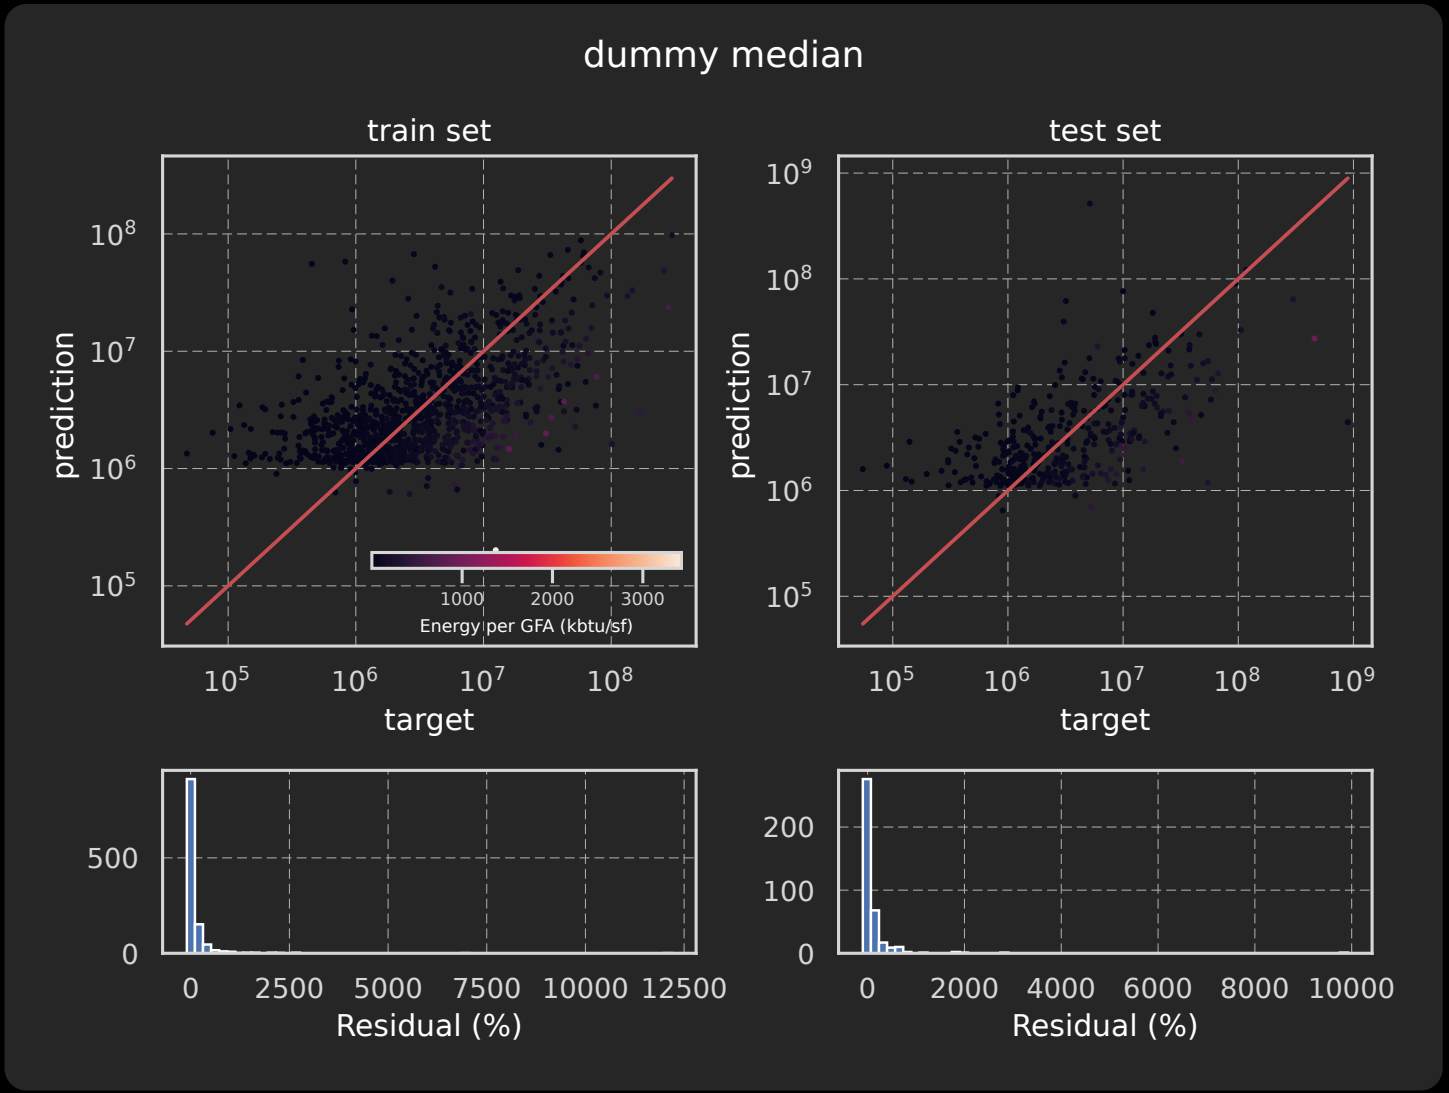
dummy median
train set
test set
prediction
target
Energy per GFA (kbtu/sf)
1000
2000
3000
Residual (%)

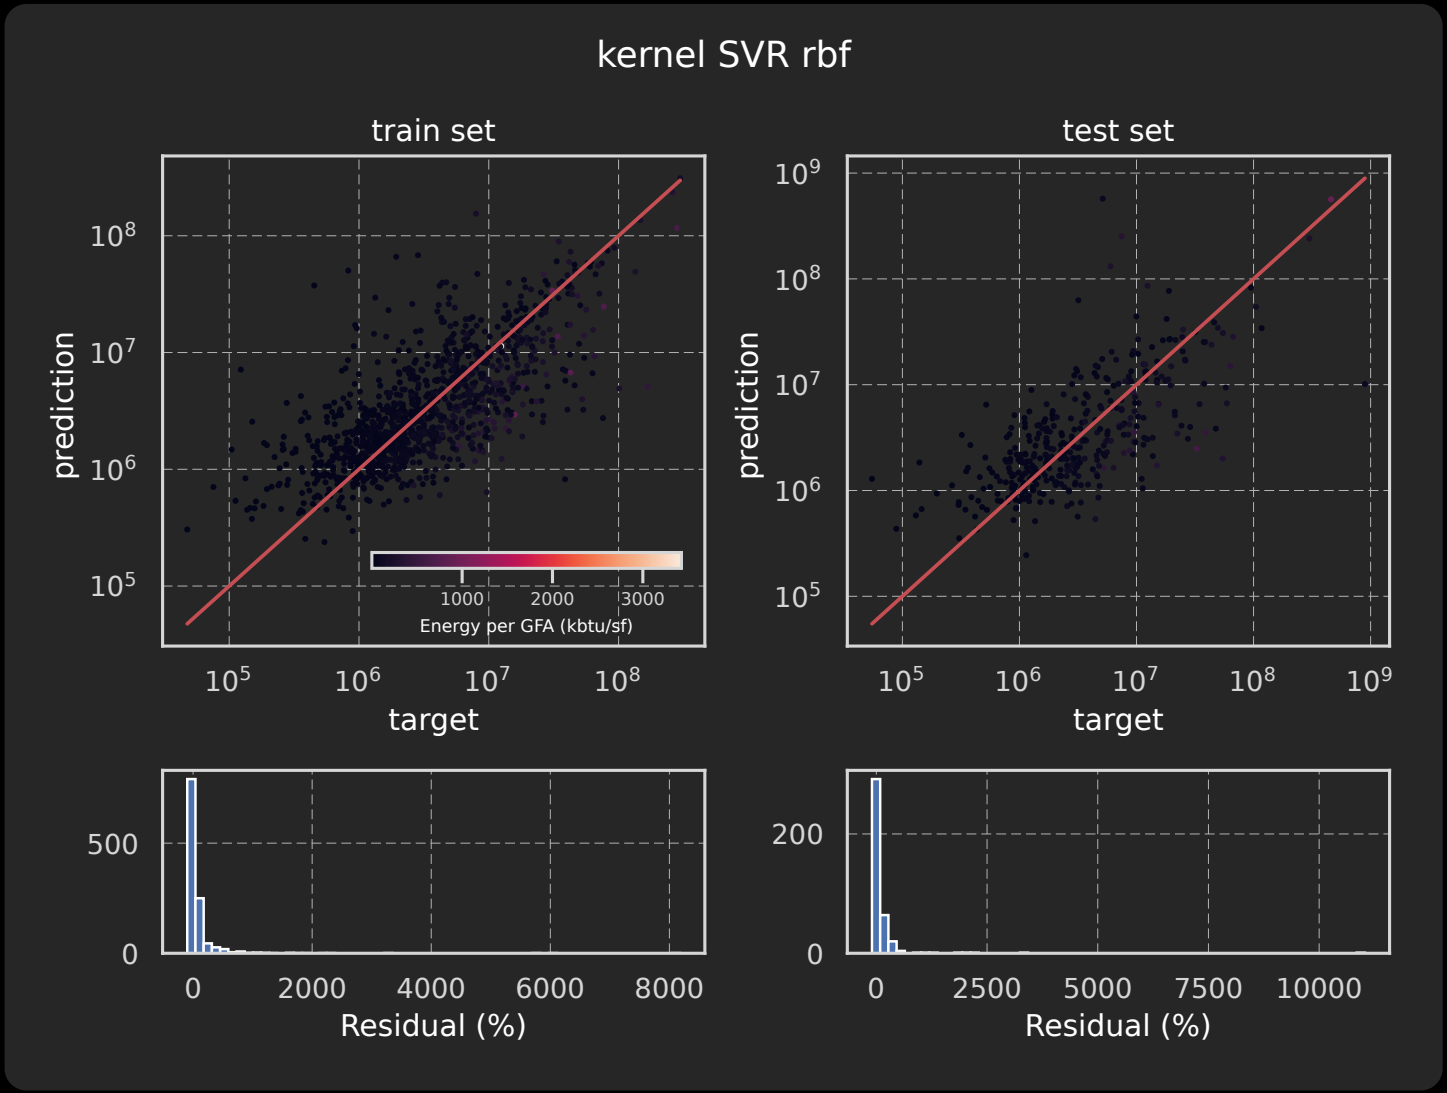
kernel SVR rbf
train set
test set
prediction
target
Energy per GFA (kbtu/sf)
1000
2000
3000
Residual (%)

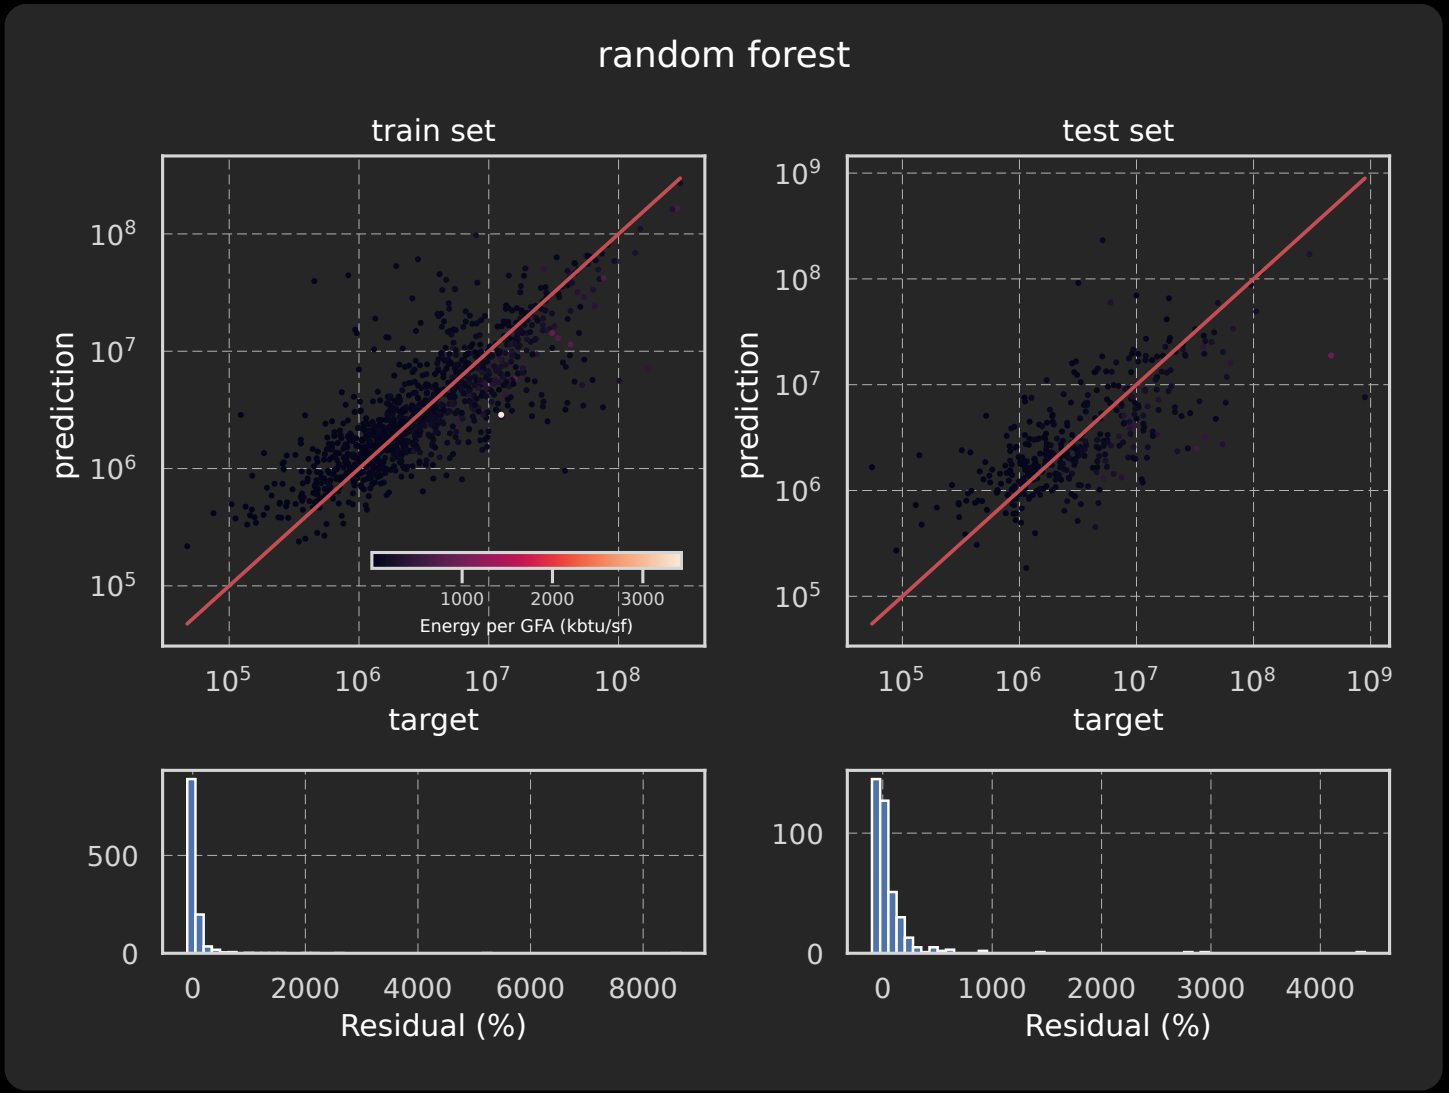
random forest
train set
test set
prediction
target
Energy per GFA (kbtu/sf)
1000
2000
3000
Residual (%)

SHAP pour un outlier (kernel SVR rbf)

SHAP pour un outlier (kernel SVR rbf)

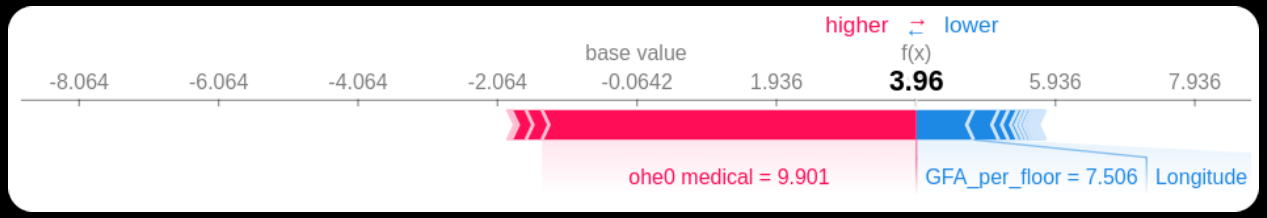

SHAP pour un outlier (kernel SVR rbf)

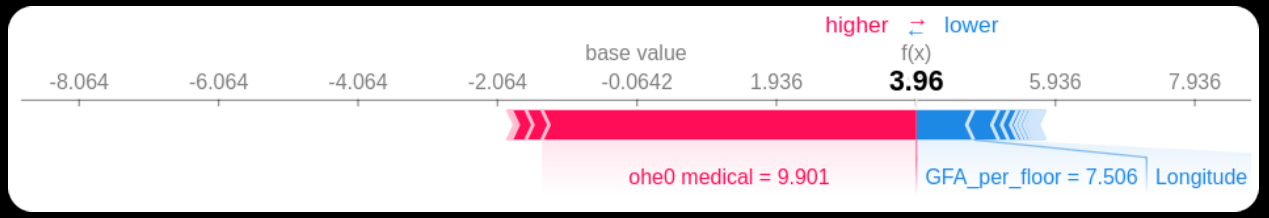

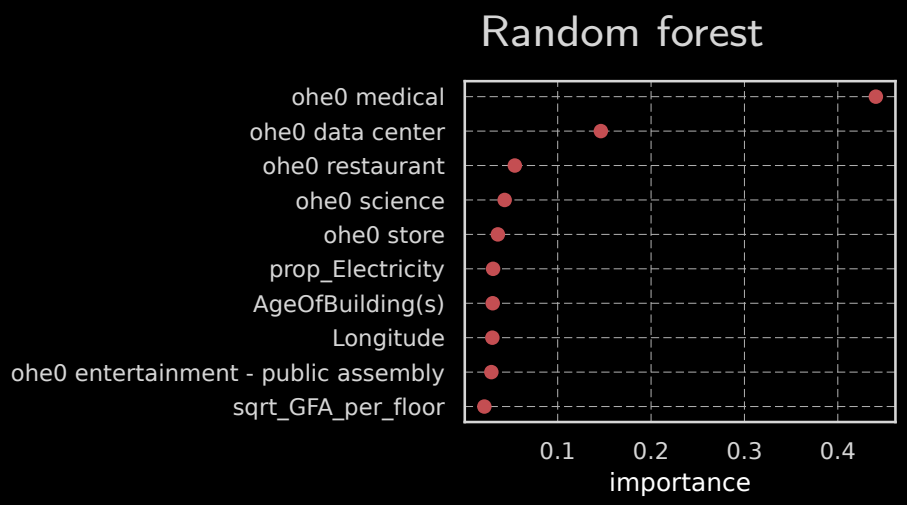

SHAP pour un outlier (kernel SVR rbf)

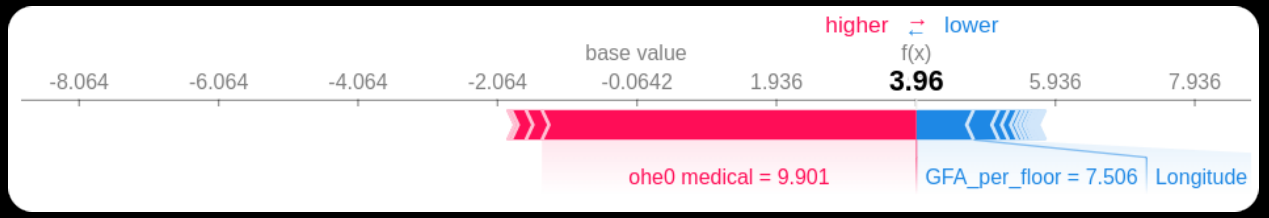

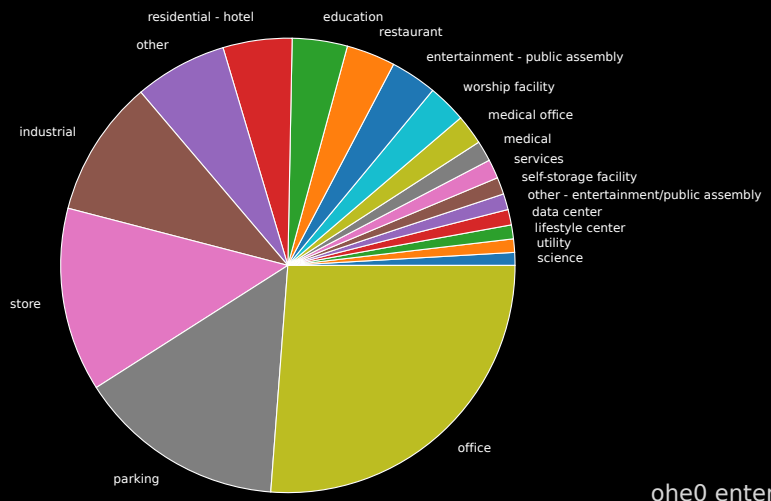

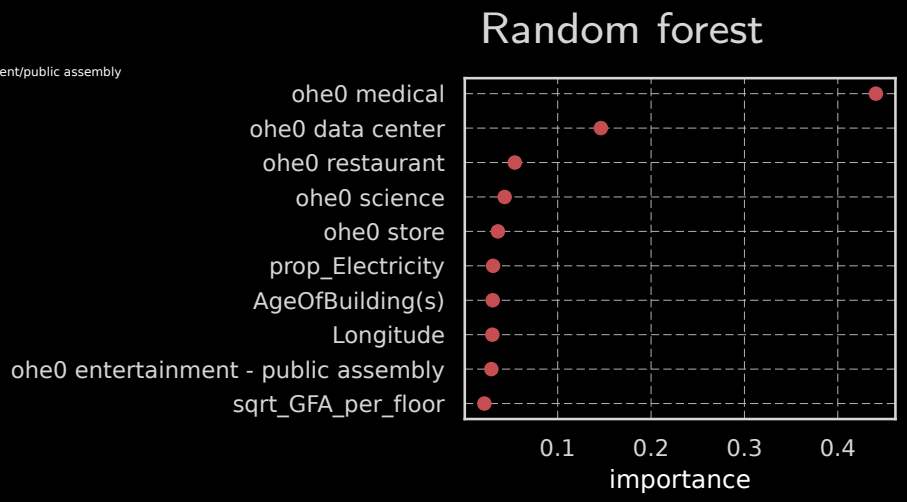

SHAP pour un outlier (kernel SVR rbf)

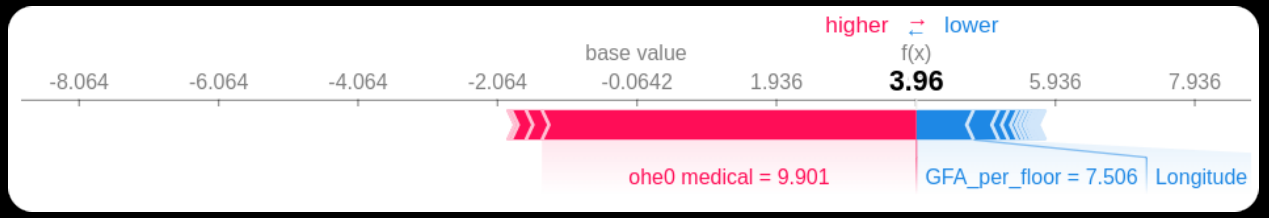

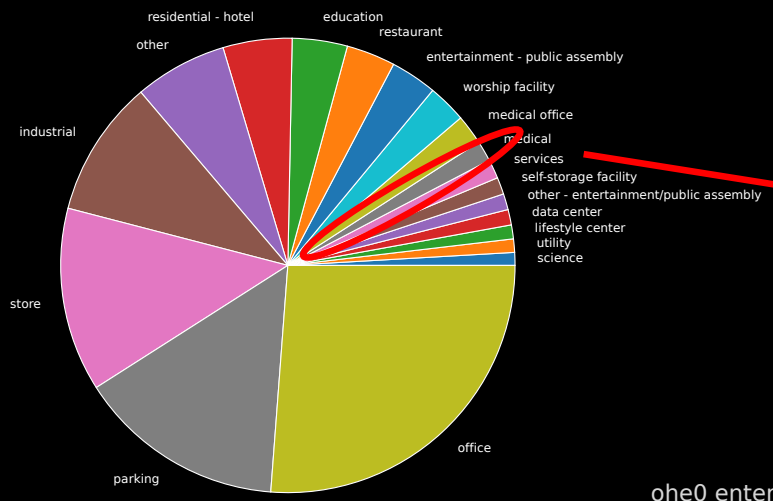

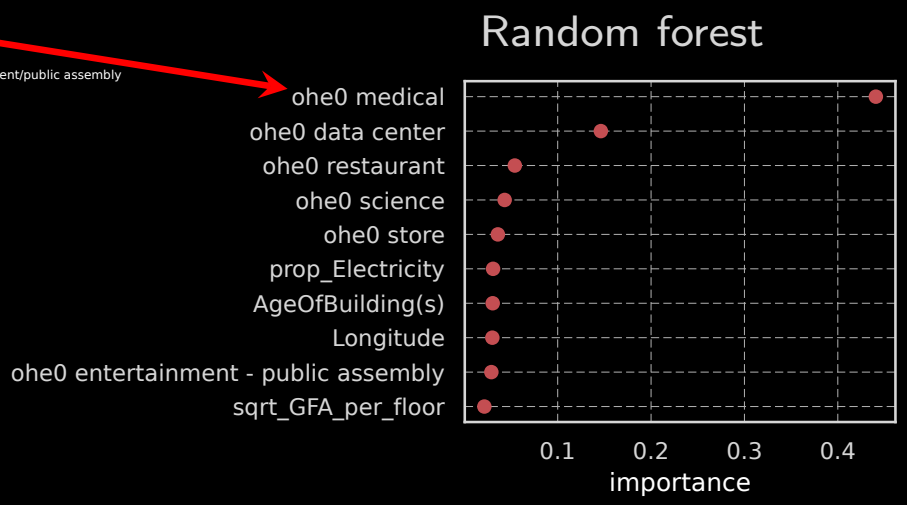

SHAP pour un outlier (kernel SVR rbf)

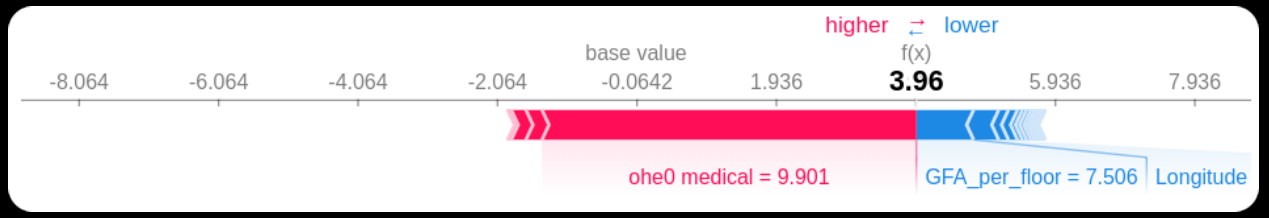

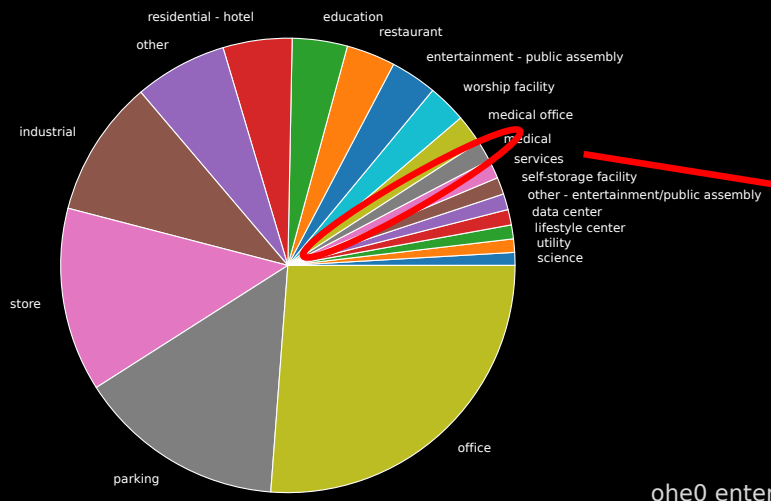

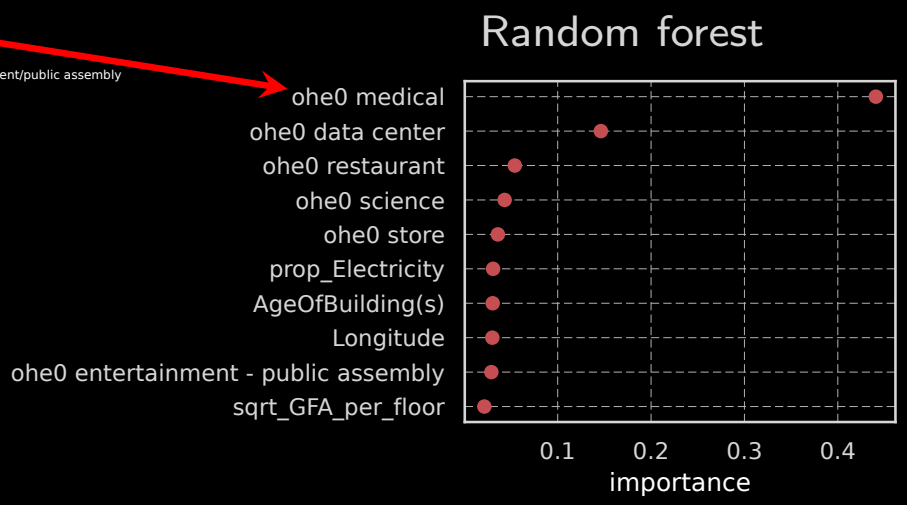

Impact conséquent d'outliers
(consommation surfacique)

MODÉLISATION

Consommation sans outliers

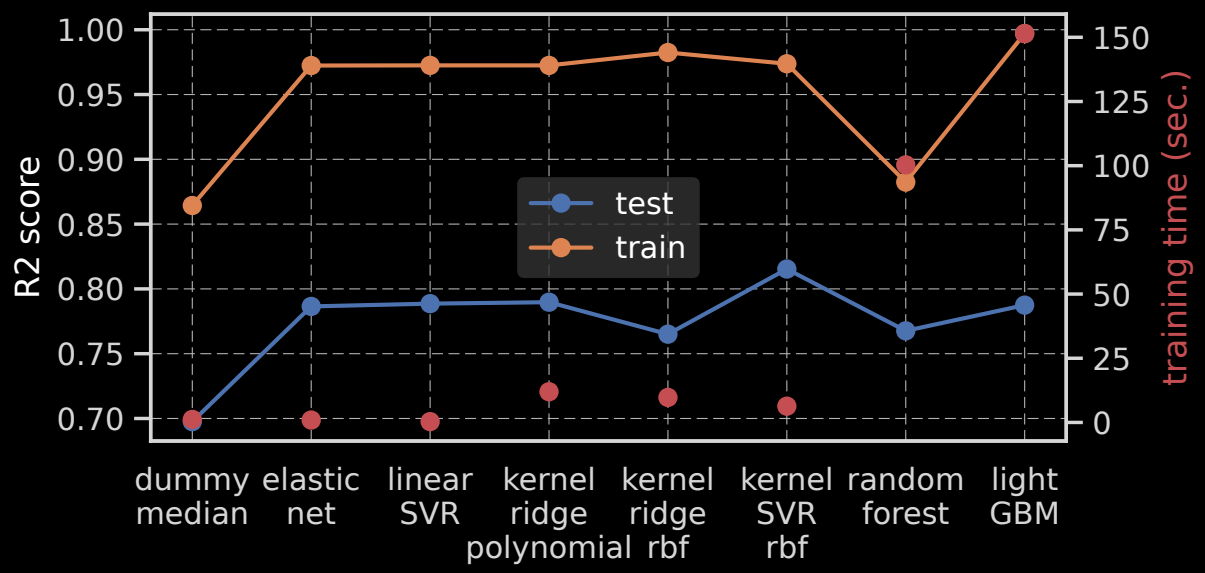
1.00
0.95
0.90
0.85
0.80
0.75
0.70
R2 score
150
125
100
75
50
25
0
training time (sec.)
test
train
dummy median
elastic net
linear SVR
kernel ridge polynomial
kernel ridge rbf
kernel SVR rbf
random forest
light GBM

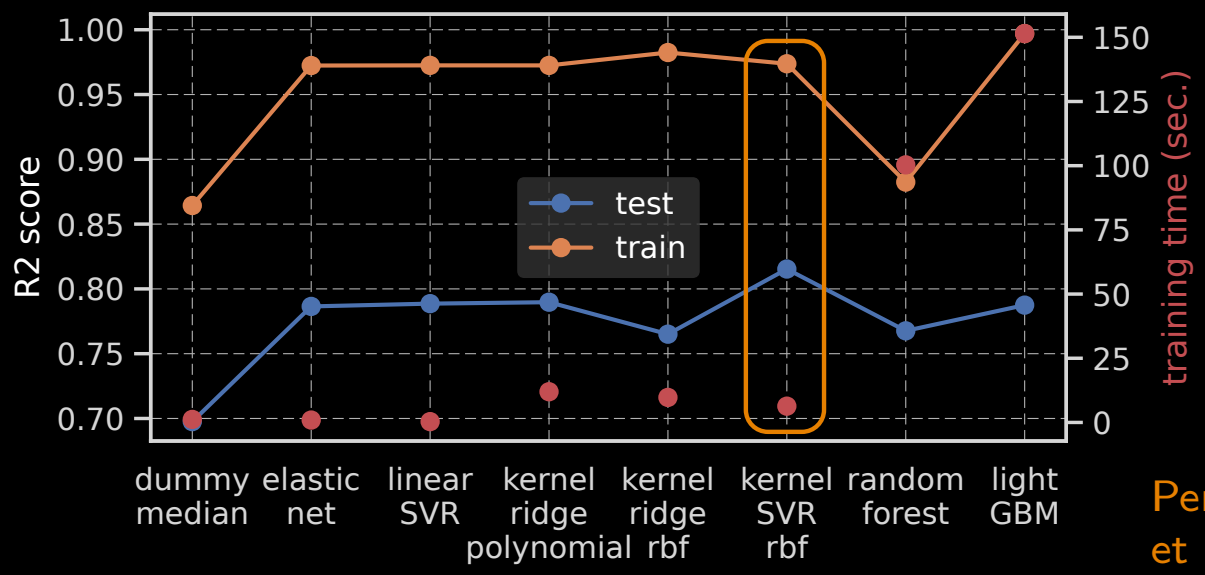

Pertinent et rapide

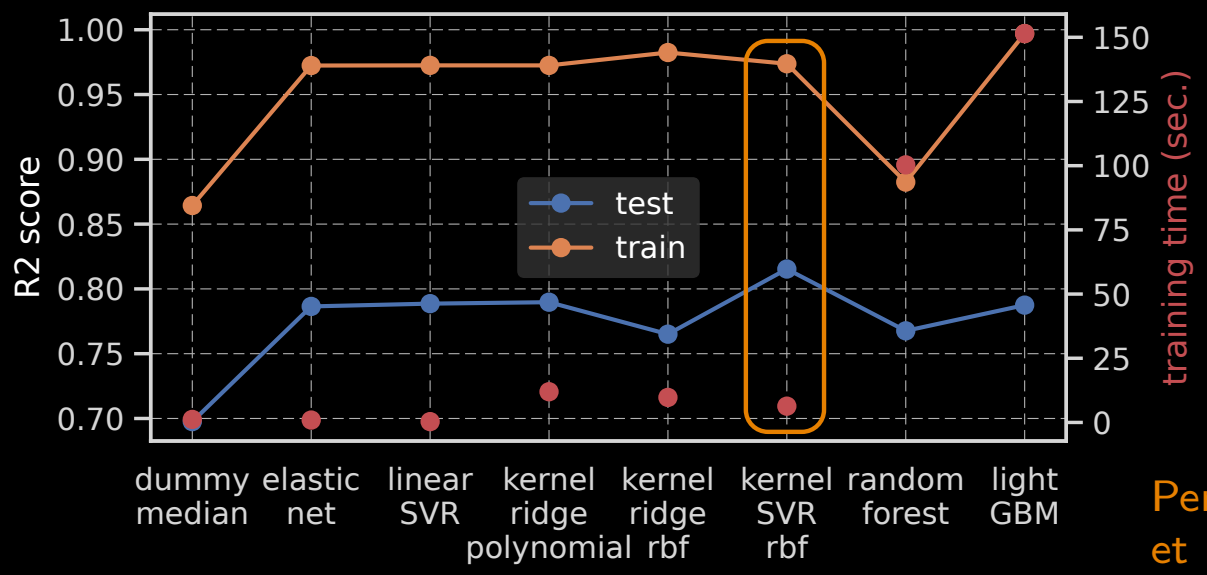

Pertinent et rapide

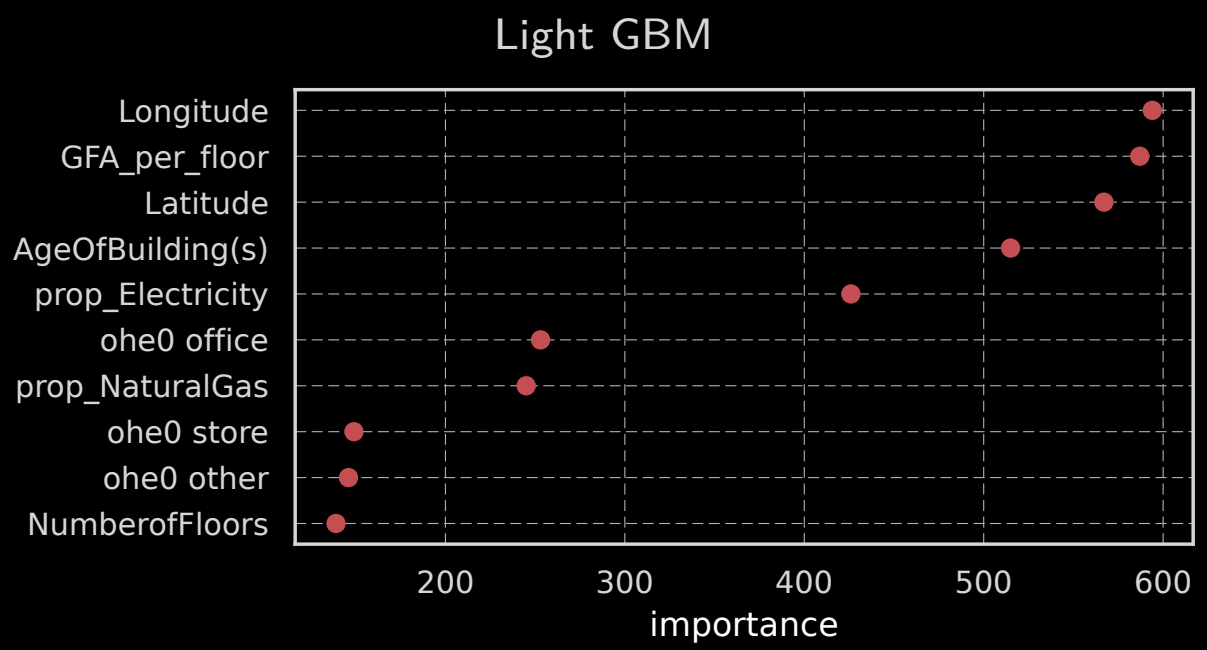

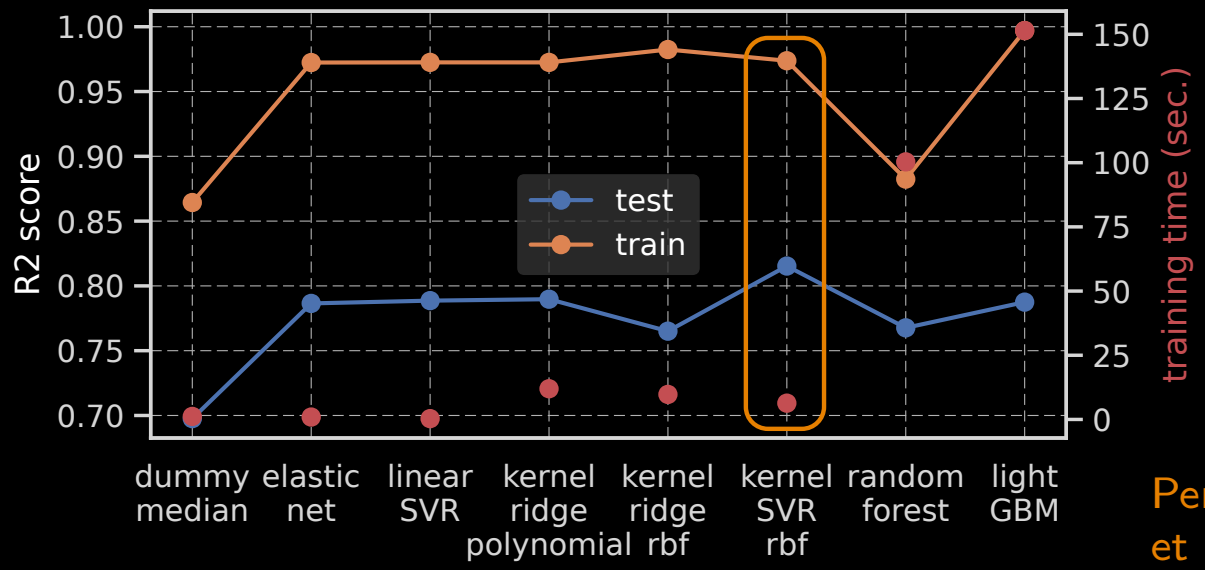

Pertinent et rapide

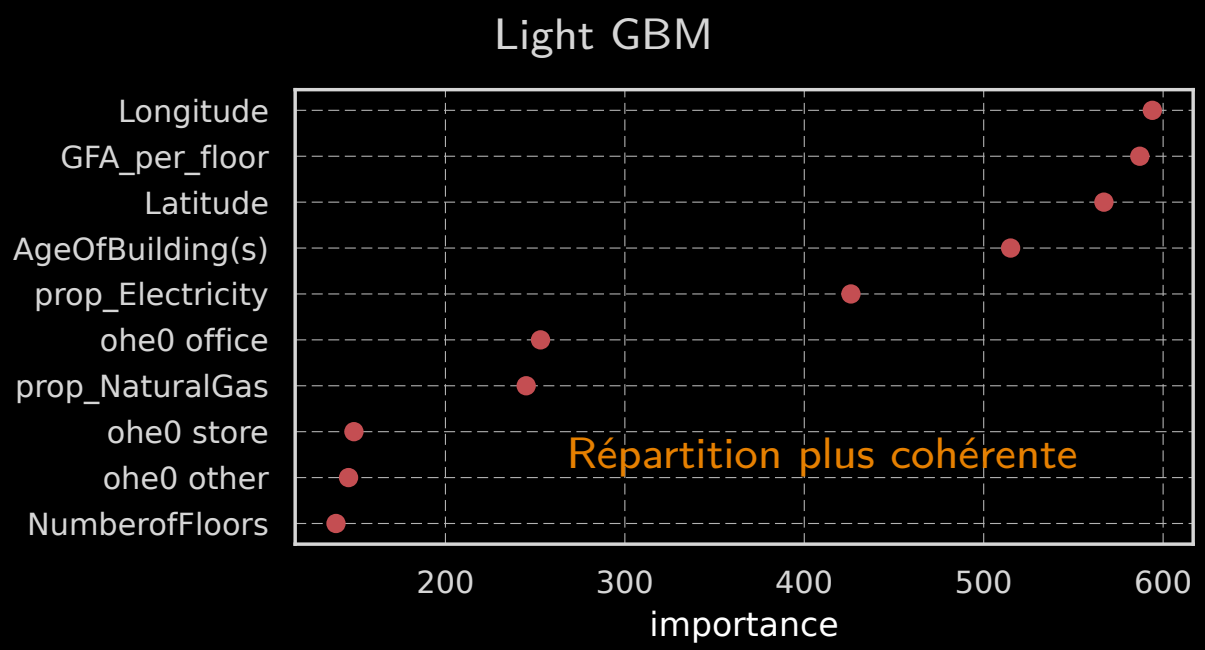

MODÉLISATION

Intérêt de l'EnergySTARSCORE

R2 score kernel SVR rbf

R2 score kernel SVR rbf

EnergySTARSCORE	Sans	Avec
train set	0.91	0.96
test set	0.92	0.94

R2 score kernel SVR rbf

EnergySTARSCORE	Sans	Avec
train set	0.91	0.96
test set	0.92	0.94

L'EnergySTARSCORE est une donnée **pertinente**, mais coûteuse à obtenir.

MODÉLISATION

Émissions

Vérification du calcul des émissions à partir des énergies consommée:

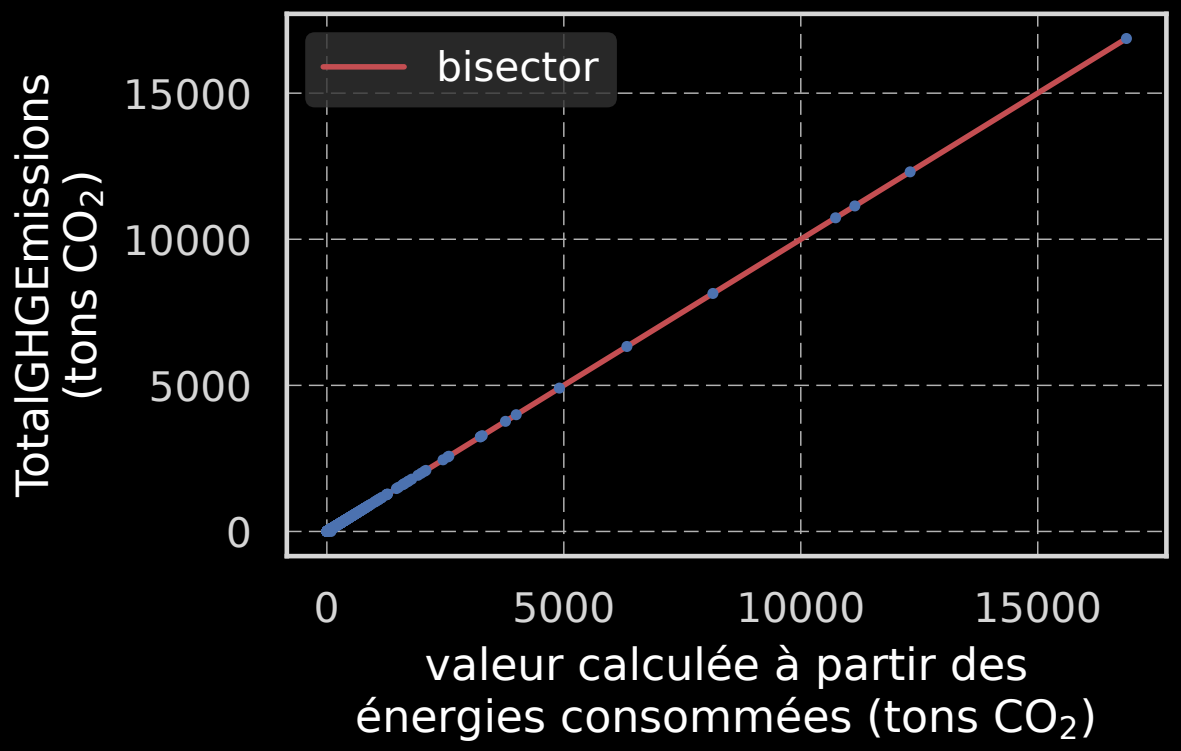

Vérification du calcul des émissions à partir des énergies consommée:

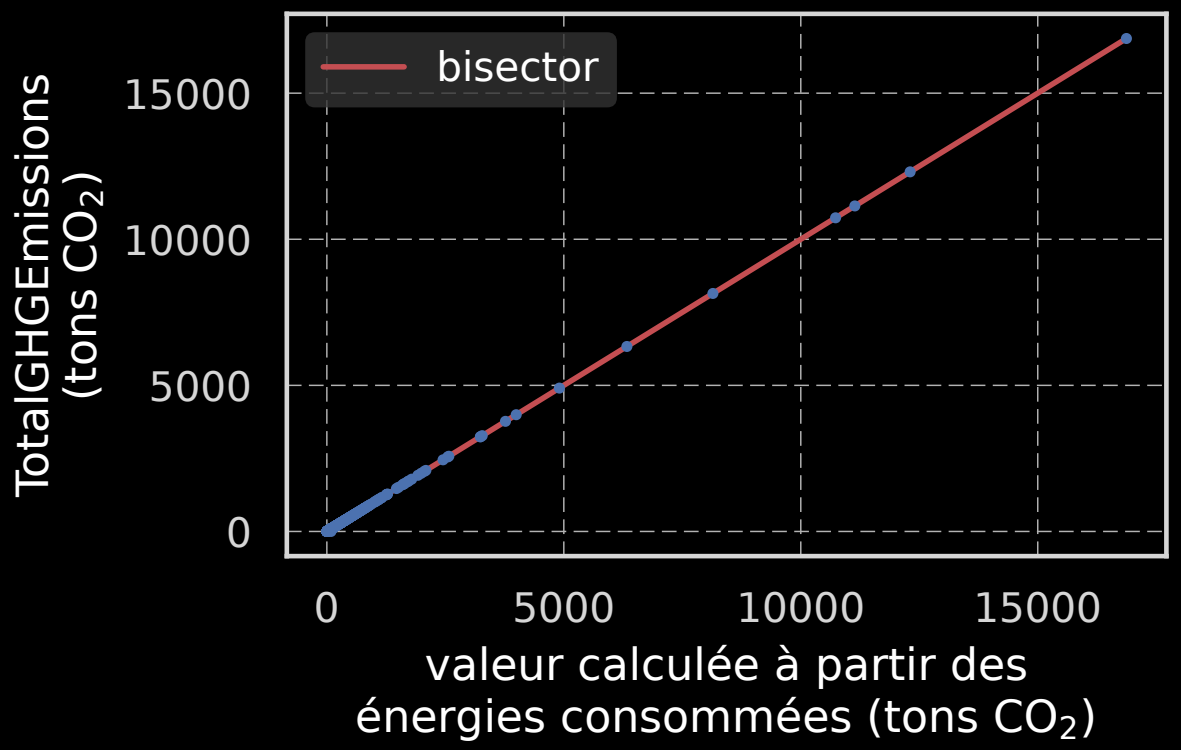

Absence de donnée "**Weather Normalized**"

Vérification du calcul des émissions à partir des énergies consommée:

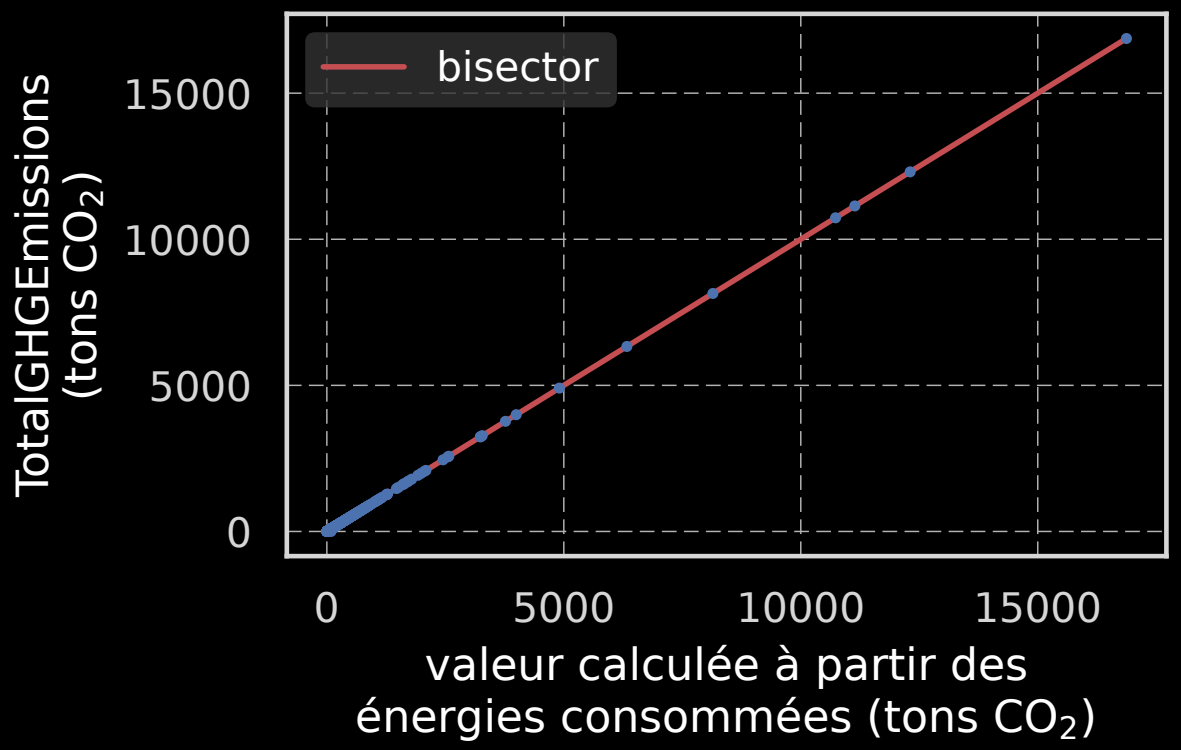

Absence de donnée "**Weather Normalized**"

Possiblité de **calculer** à partir de la **consommation totale** et des **proportions d'énergies** utilisées

$\boxed{X_{train/test}}$

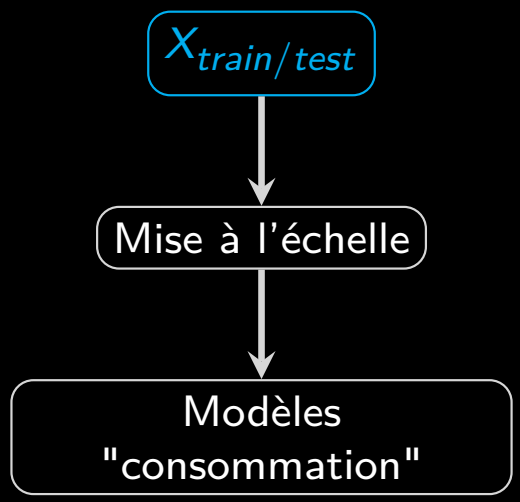
$X_{train/test}$
Mise à l'échelle
Modèles
"consommation"

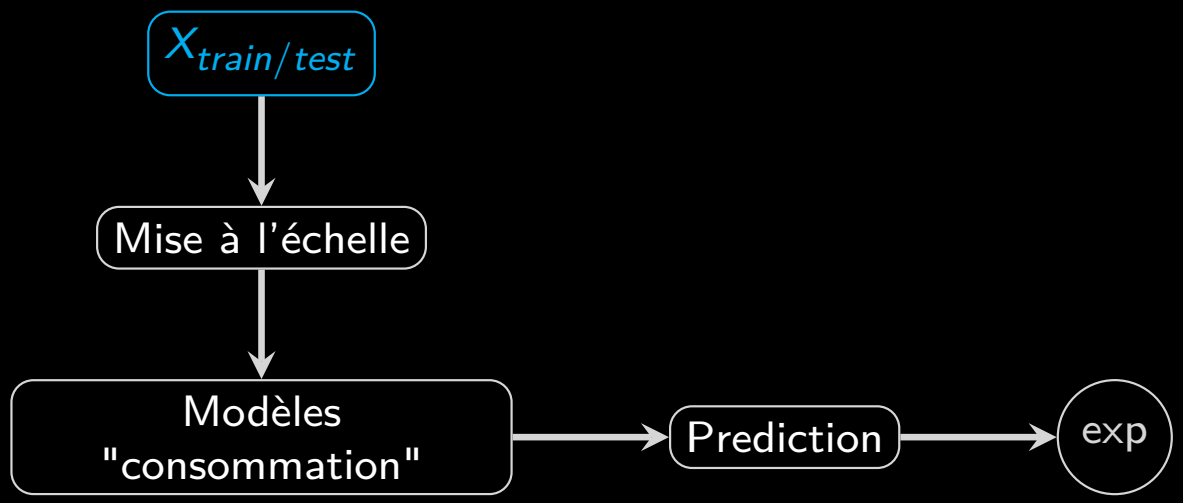
$X_{train/test}$
Mise à l'échelle
Modèles "consommation"
Prediction
exp

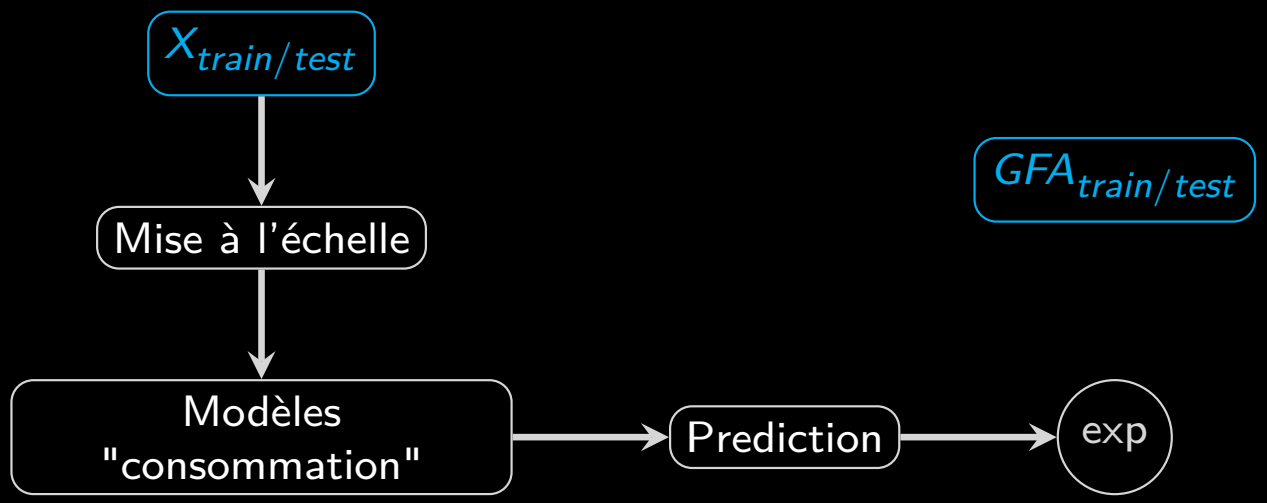
$X_{train/test}$
Mise à l'échelle
Modèles "consommation"
Prediction
exp
$GFA_{train/test}$

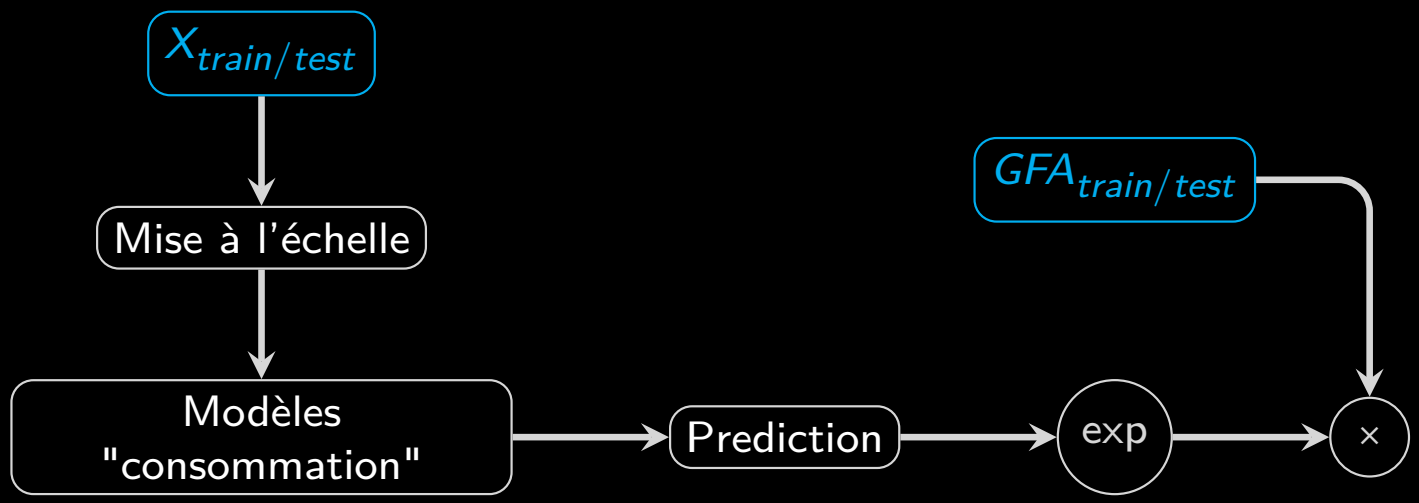
$X_{train/test}$
Mise à l'échelle
Modèles "consommation"
Prediction
exp
$GFA_{train/test}$
×

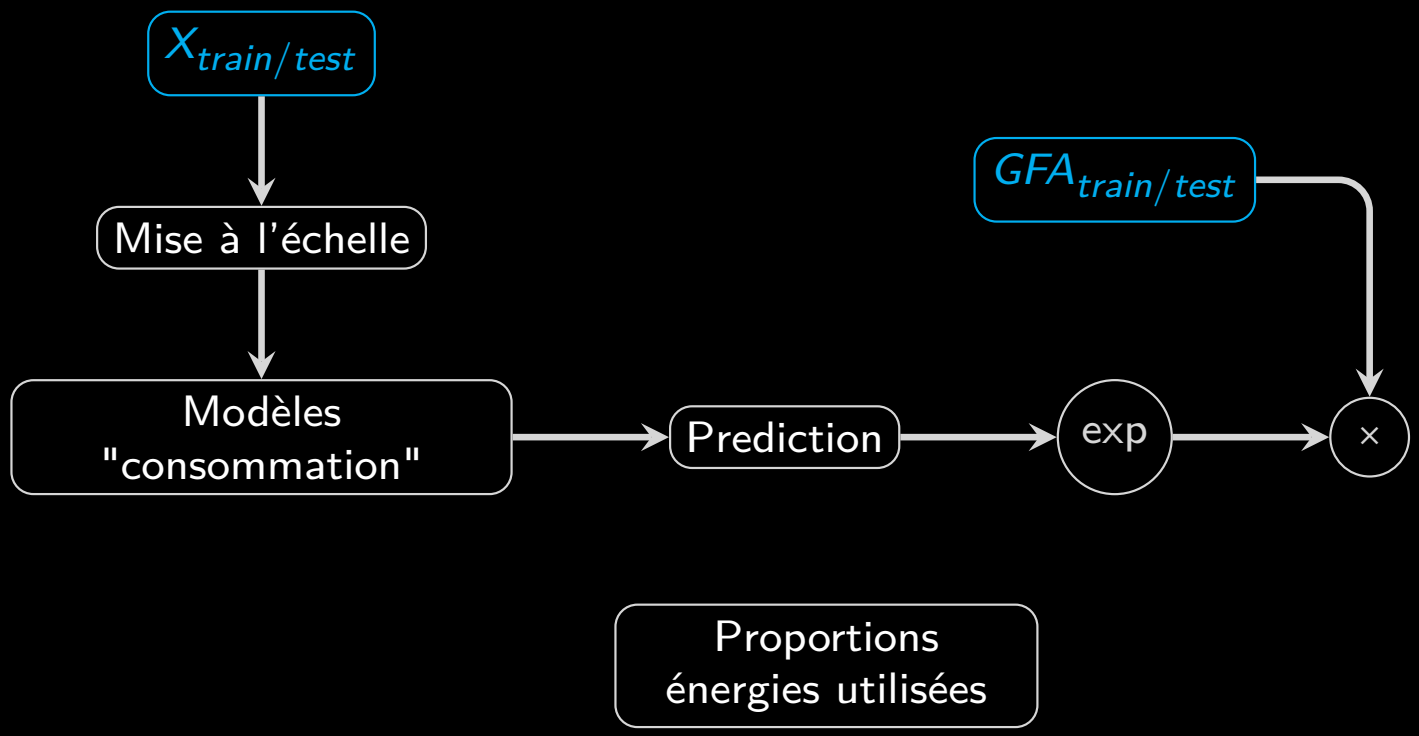
$X_{train/test}$
Mise à l'échelle
Modèles "consommation"
Prediction
exp
$GFA_{train/test}$
×
Proportions énergies utilisées

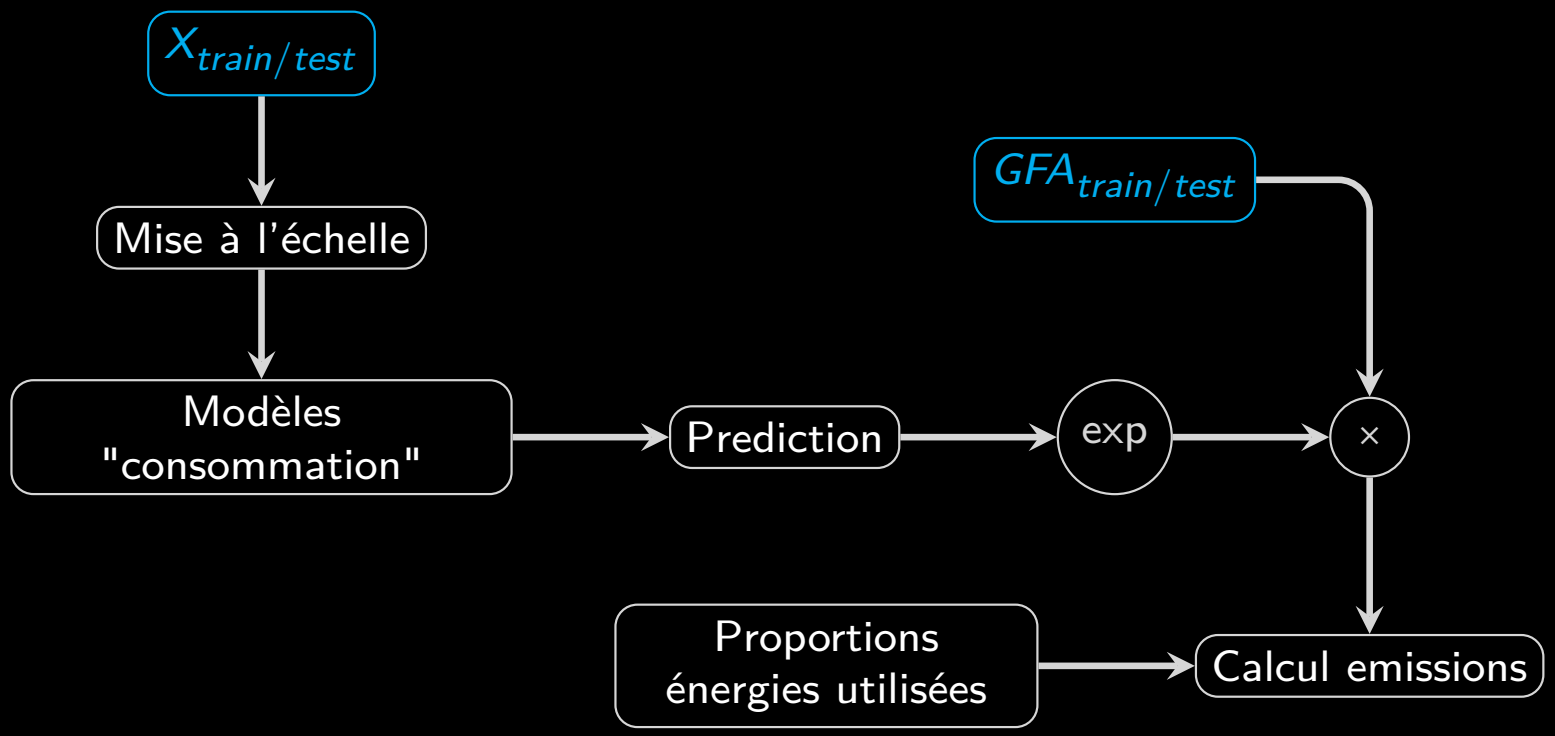
$X_{train/test}$
Mise à l'échelle
Modèles "consommation"
Prediction
exp
×
$GFA_{train/test}$
Proportions énergies utilisées
Calcul emissions

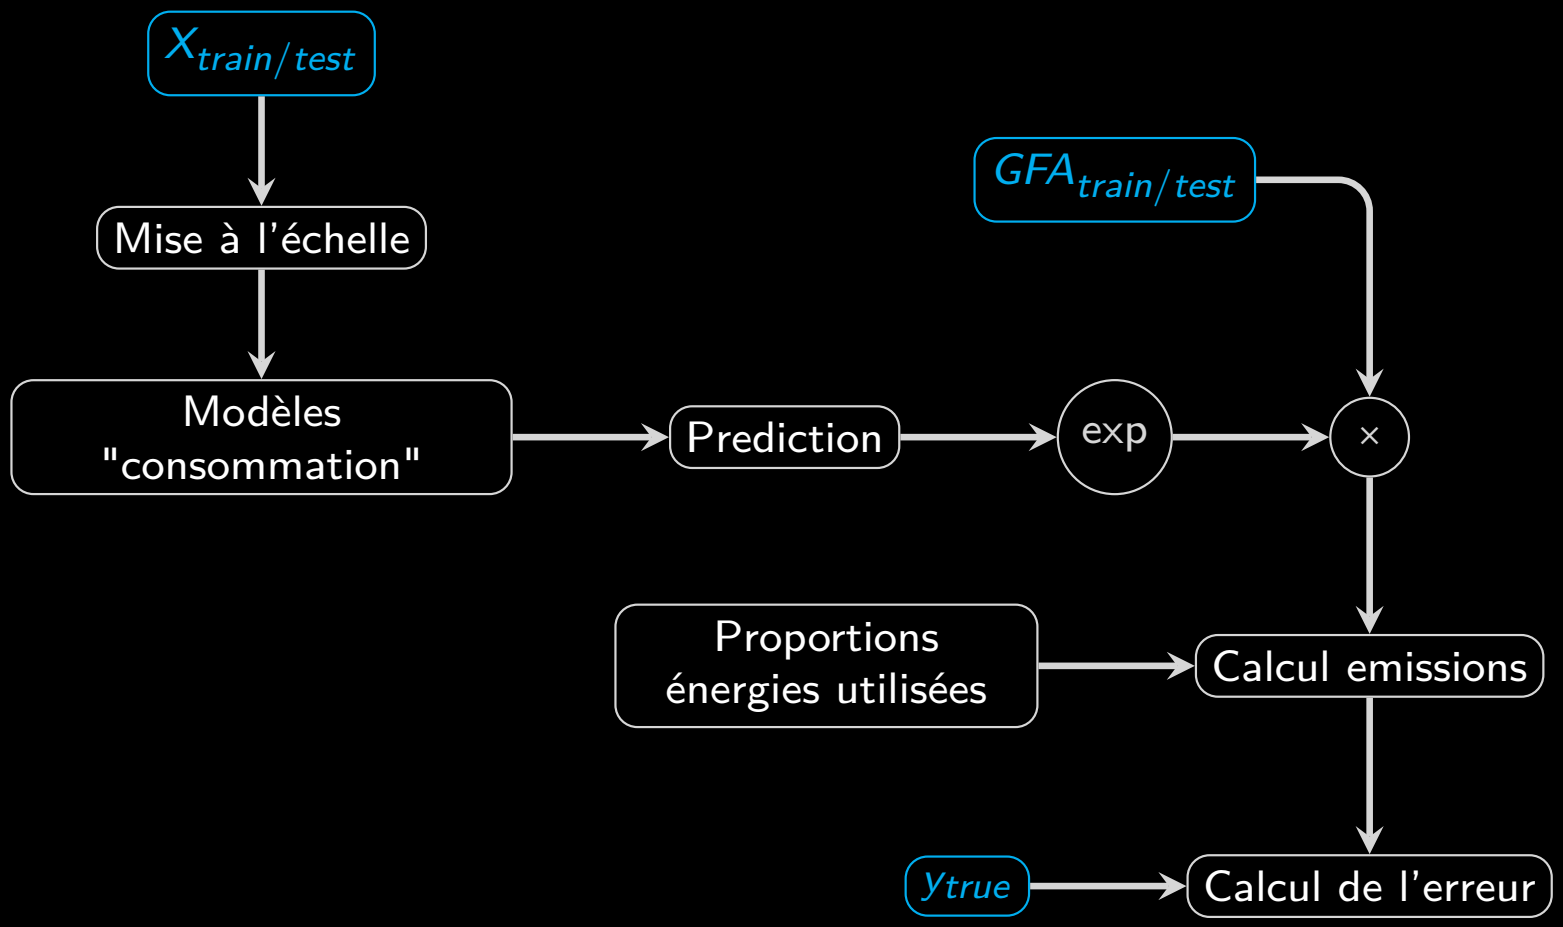
$X_{train/test}$
Mise à l'échelle
Modèles "consommation"
Prediction
exp
×
$GFA_{train/test}$
Proportions énergies utilisées
Calcul emissions
y_{true}
Calcul de l'erreur

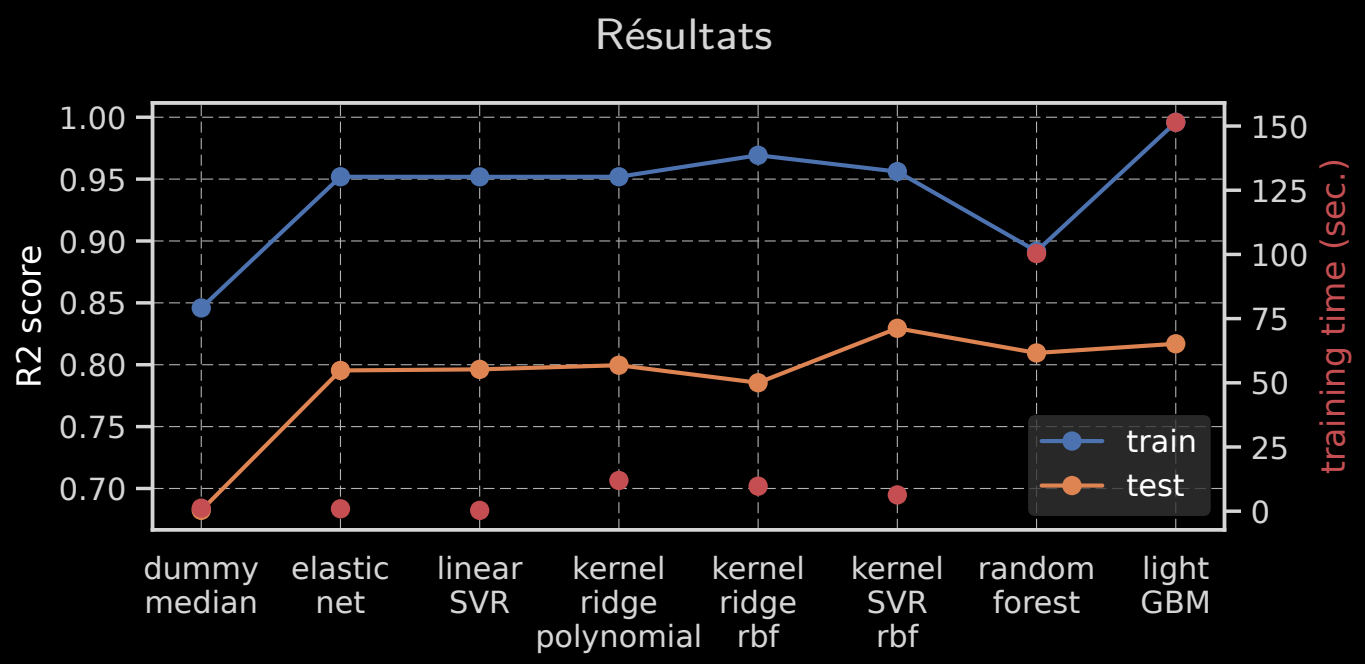
Résultats
R2 score
1.00
0.95
0.90
0.85
0.80
0.75
0.70
training time (sec.)
150
125
100
75
50
25
0
train
test
dummy median
elastic net
linear SVR
kernel ridge polynomial
kernel ridge rbf
kernel SVR rbf
random forest
light GBM

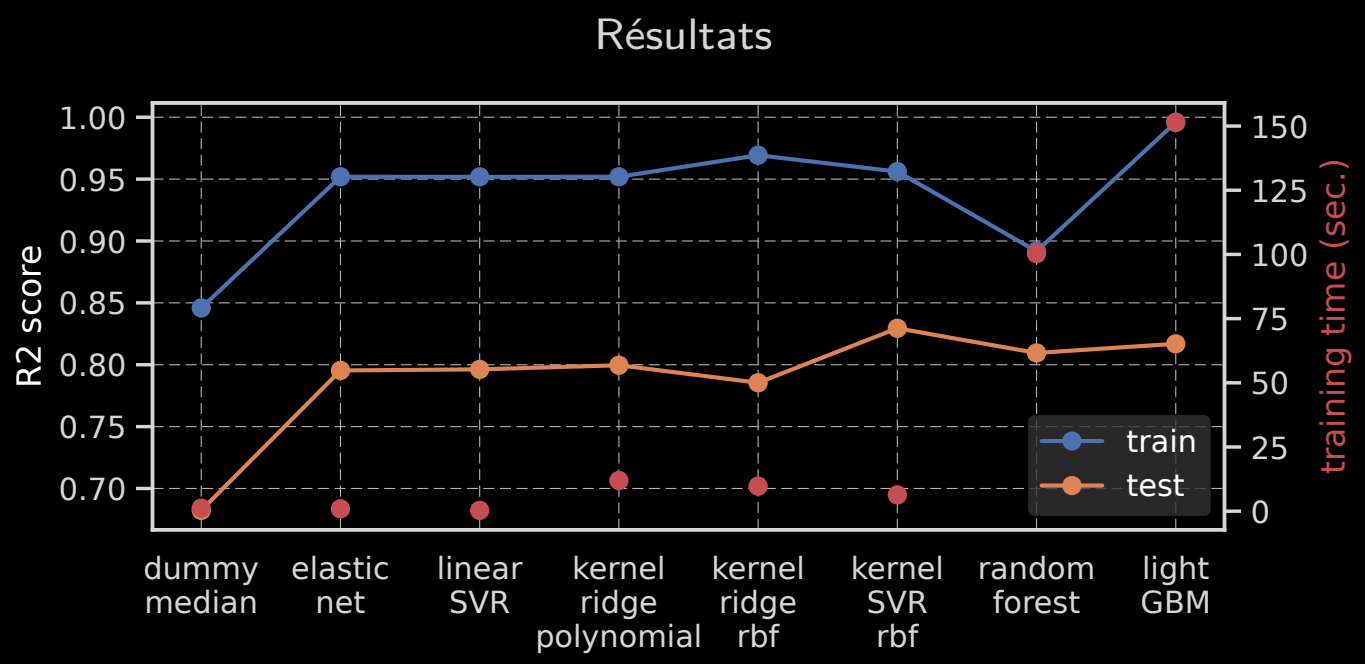

Les résultats sont **cohérents** avec ceux obtenus pour la consommation.

Résultats

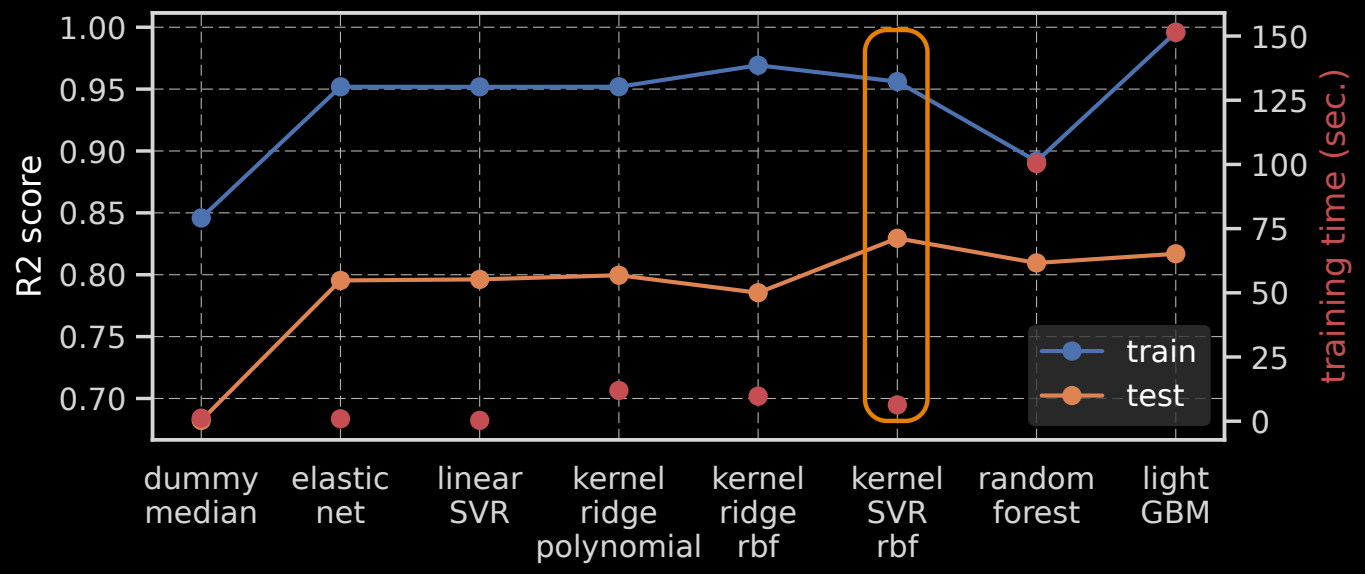

Les résultats sont **cohérents** avec ceux obtenus pour la consommation.

Le modèle "**kernel SVR rbf**" donne ici des **résultats satisfaisants** pour un temps de calcul relativement court.

CONCLUSION

Supprimer les **10% d'outliers** améliore les résultats.

Supprimer les **10% d'outliers** améliore les résultats.

Sans les outliers, les **résultats** des **différents modèles** sont **similaires**.

Supprimer les **10% d'outliers** améliore les résultats.

Sans les outliers, les **résultats** des **différents modèles** sont **similaires**.

L'**EnergySTARSCORE** est une variable **pertinente** mais **non essentielle** pour la prédiction de la consommation et des émissions.

Supprimer les **10% d'outliers** améliore les résultats.

Sans les outliers, les **résultats** des **différents modèles** sont **similaires**.

L'**EnergySTARSCORE** est une variable **pertinente** mais **non essentielle** pour la prédiction de la consommation et des émissions.

Les **émissions** peuvent être **déduites** des prédictions de la **consommation**.

PERSPECTIVES

Travailler avec un **expert métier**

Travailler avec un **expert métier**

GridsearchCV des hyper parametres

Travailler avec un **expert métier**

GridsearchCV des hyper parametres → **Optimisation bayesienne**

Merci pour votre **attention**.