OPENCLASSROOMS

Formation Ingénieur Machine Learning

Projet:

Classez automatiquement des questions

3 Juin 2023

thomas.durandtexte@protonmail.com

CONTEXTE

Aide à la communauté
stackoverflow / stackexchange

Aide à la communauté
stackoverflow / stackexchange

Questions posées

Aide à la communauté
stackoverflow / stackexchange

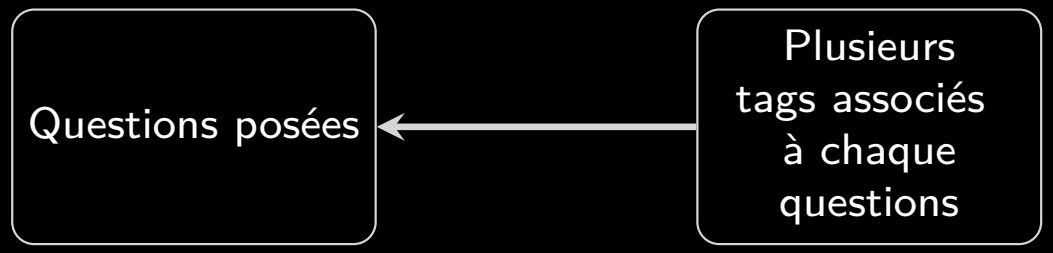

Aide à la communauté
stackoverflow / stackexchange

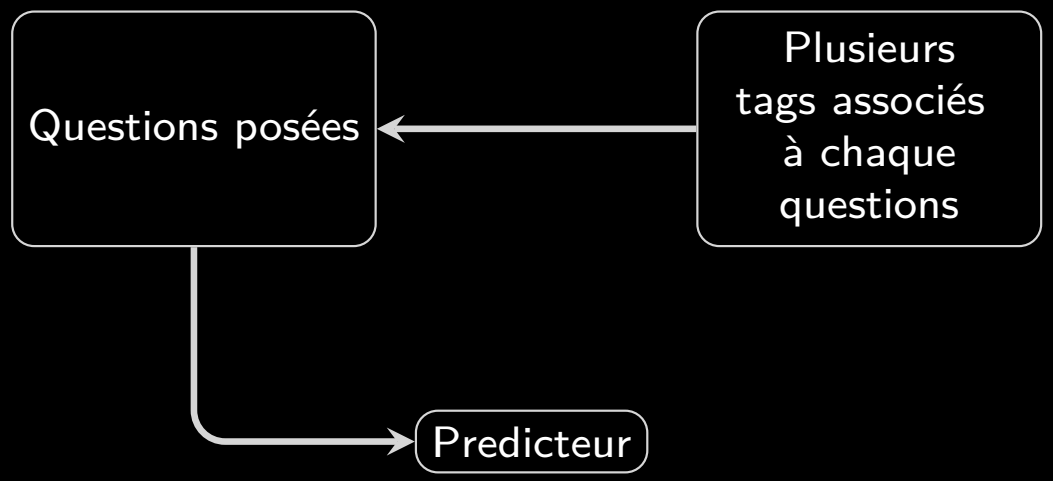

Aide à la communauté
stackoverflow / stackexchange

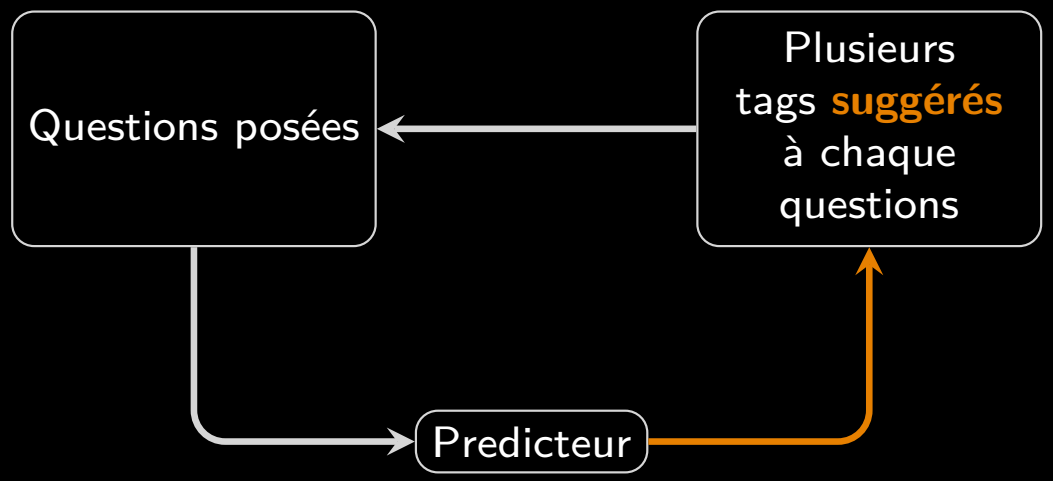

CONTEXTE

Base de données

Requête SQL

```sql
DECLARE @start_date DATE
DECLARE @end_date DATE
SET @start_date = '2011-01-01'
SET @end_date = DATEADD(year, 1, @start_date)

SELECT Id, CreationDate, Title, Body, Tags, ViewCount, FavoriteCount,
       CommentCount, AnswerCount, Score
FROM Posts
WHERE (PostTypeID = 1)
AND (CreationDate BETWEEN @start_date AND @end_date)
AND ViewCount > 10
AND CommentCount > 3
AND AnswerCount > 0
AND Score > 5
AND len(Tags) > 0
```

Requête SQL

```sql
DECLARE @start_date DATE
DECLARE @end_date DATE
SET @start_date = '2011-01-01'
SET @end_date = DATEADD(year, 1, @start_date)

SELECT Id, CreationDate, Title, Body, Tags, ViewCount, FavoriteCount,
       CommentCount, AnswerCount, Score
FROM Posts
WHERE (PostTypeID = 1)
AND (CreationDate BETWEEN @start_date AND @end_date)
AND ViewCount > 10
AND CommentCount > 3
AND AnswerCount > 0
AND Score > 5
AND len(Tags) > 0
```

1 requête par année jusqu'en 2022 inclus

Requête SQL

```sql
DECLARE @start_date DATE
DECLARE @end_date DATE
SET @start_date = '2011-01-01'
SET @end_date = DATEADD(year, 1, @start_date)

SELECT Id, CreationDate, Title, Body, Tags, ViewCount, FavoriteCount,
       CommentCount, AnswerCount, Score
FROM Posts
WHERE (PostTypeID = 1)
AND (CreationDate BETWEEN @start_date AND @end_date)
AND ViewCount > 10
AND CommentCount > 3
AND AnswerCount > 0
AND Score > 5
AND len(Tags) > 0
```

Questions

Requête SQL

```sql
DECLARE @start_date DATE
DECLARE @end_date DATE
SET @start_date = '2011-01-01'
SET @end_date = DATEADD(year, 1, @start_date)

SELECT Id, CreationDate, Title, Body, Tags, ViewCount, FavoriteCount,
       CommentCount, AnswerCount, Score
FROM Posts
WHERE (PostTypeID = 1)
AND (CreationDate BETWEEN @start_date AND @end_date)
AND ViewCount > 10
AND CommentCount > 3
AND AnswerCount > 0
AND Score > 5
AND len(Tags) > 0
```

Contraintes pour la "qualité" des données

Requête SQL

```sql
DECLARE @start_date DATE
DECLARE @end_date DATE
SET @start_date = '2011-01-01'
SET @end_date = DATEADD(year, 1, @start_date)

SELECT Id, CreationDate, Title, Body, Tags, ViewCount, FavoriteCount,
       CommentCount, AnswerCount, Score
FROM Posts
WHERE (PostTypeID = 1)
AND (CreationDate BETWEEN @start_date AND @end_date)
AND ViewCount > 10
AND CommentCount > 3
AND AnswerCount > 0
AND Score > 5
AND len(Tags) > 0
```

→ 275 325 questions

CONTEXTE

Protocole

Base de données

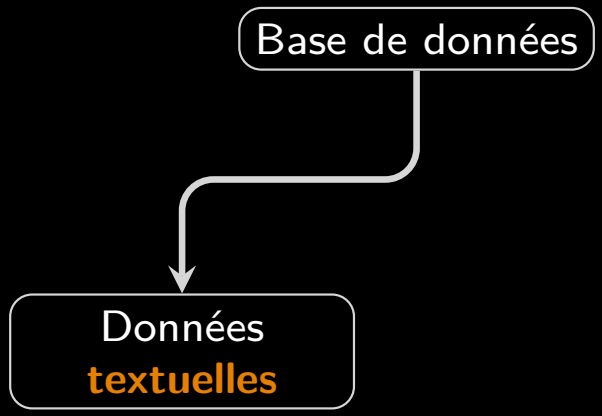
Base de données
Données
textuelles

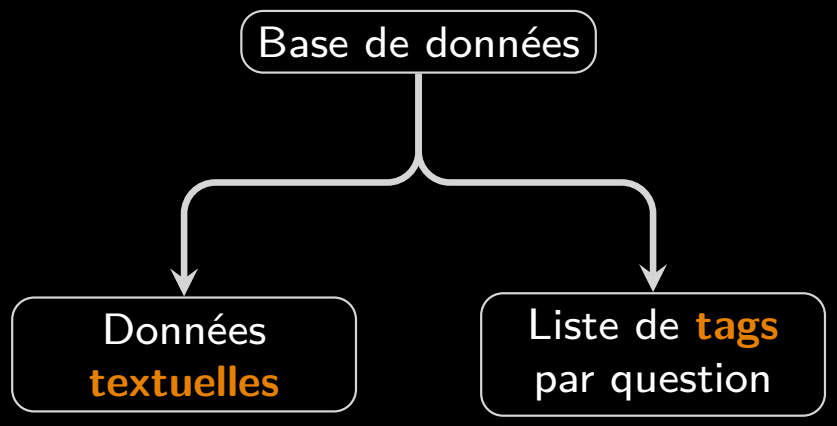
Base de données
Données textuelles
Liste de tags par question

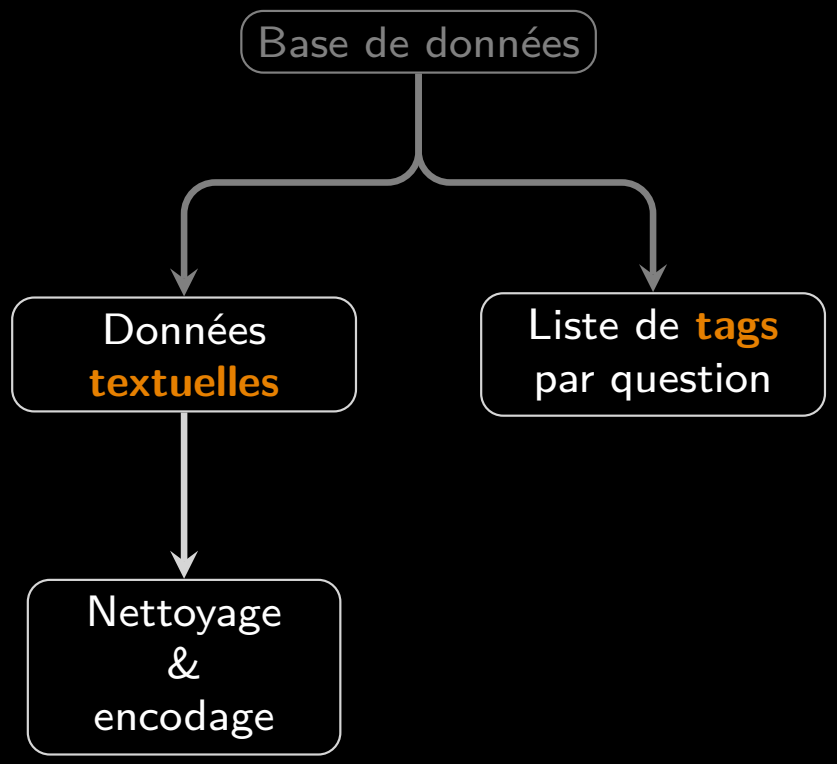
Base de données
Données textuelles
Liste de tags par question
Nettoyage & encodage

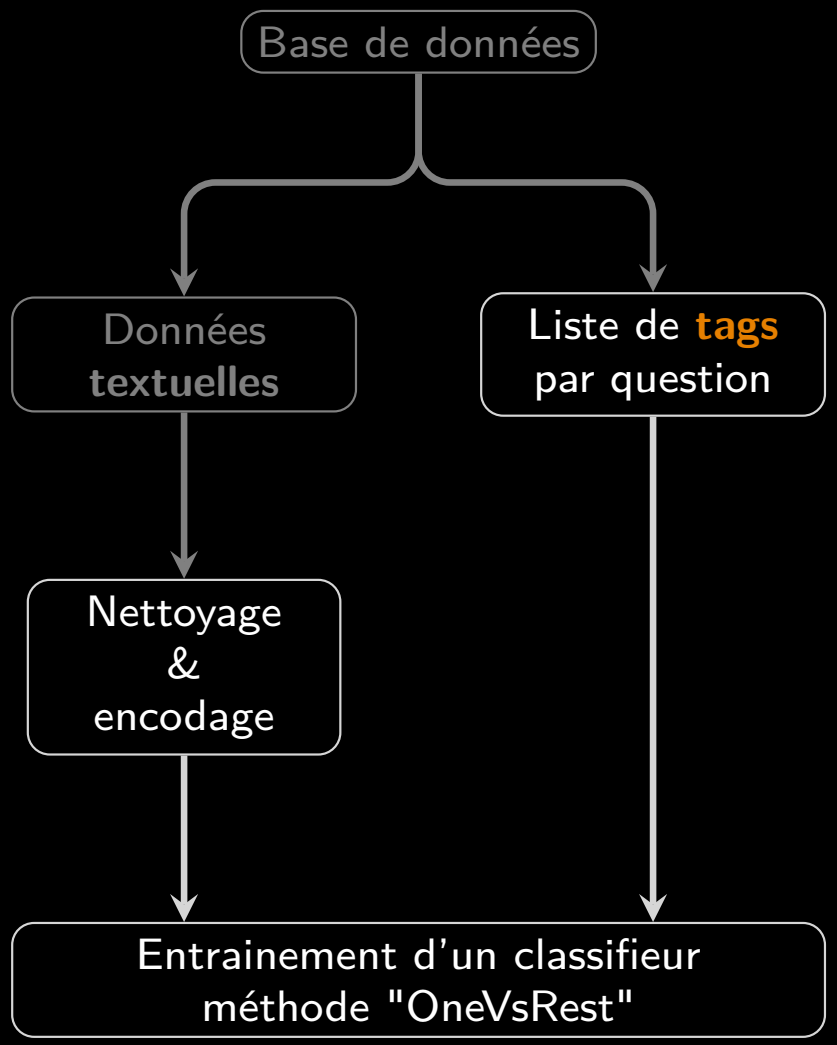
Base de données
Données textuelles
Liste de tags par question
Nettoyage & encodage
Entrainement d'un classifieur méthode "OneVsRest"

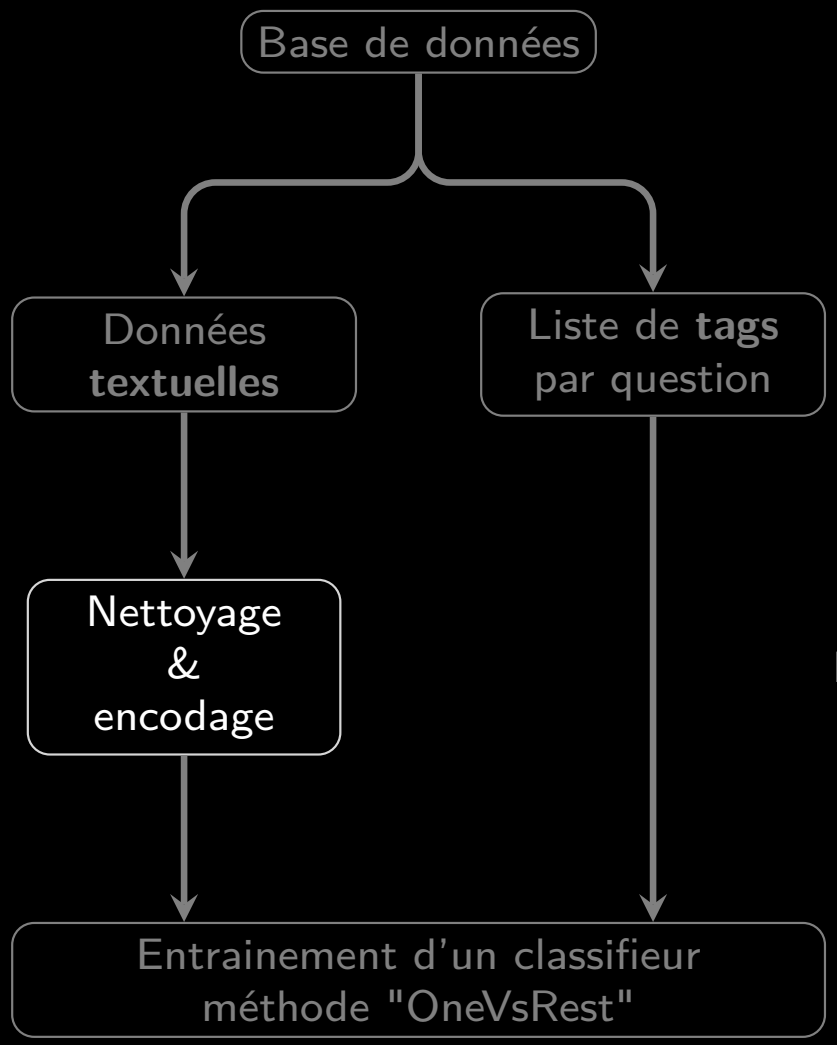

Essais de différents encodeurs

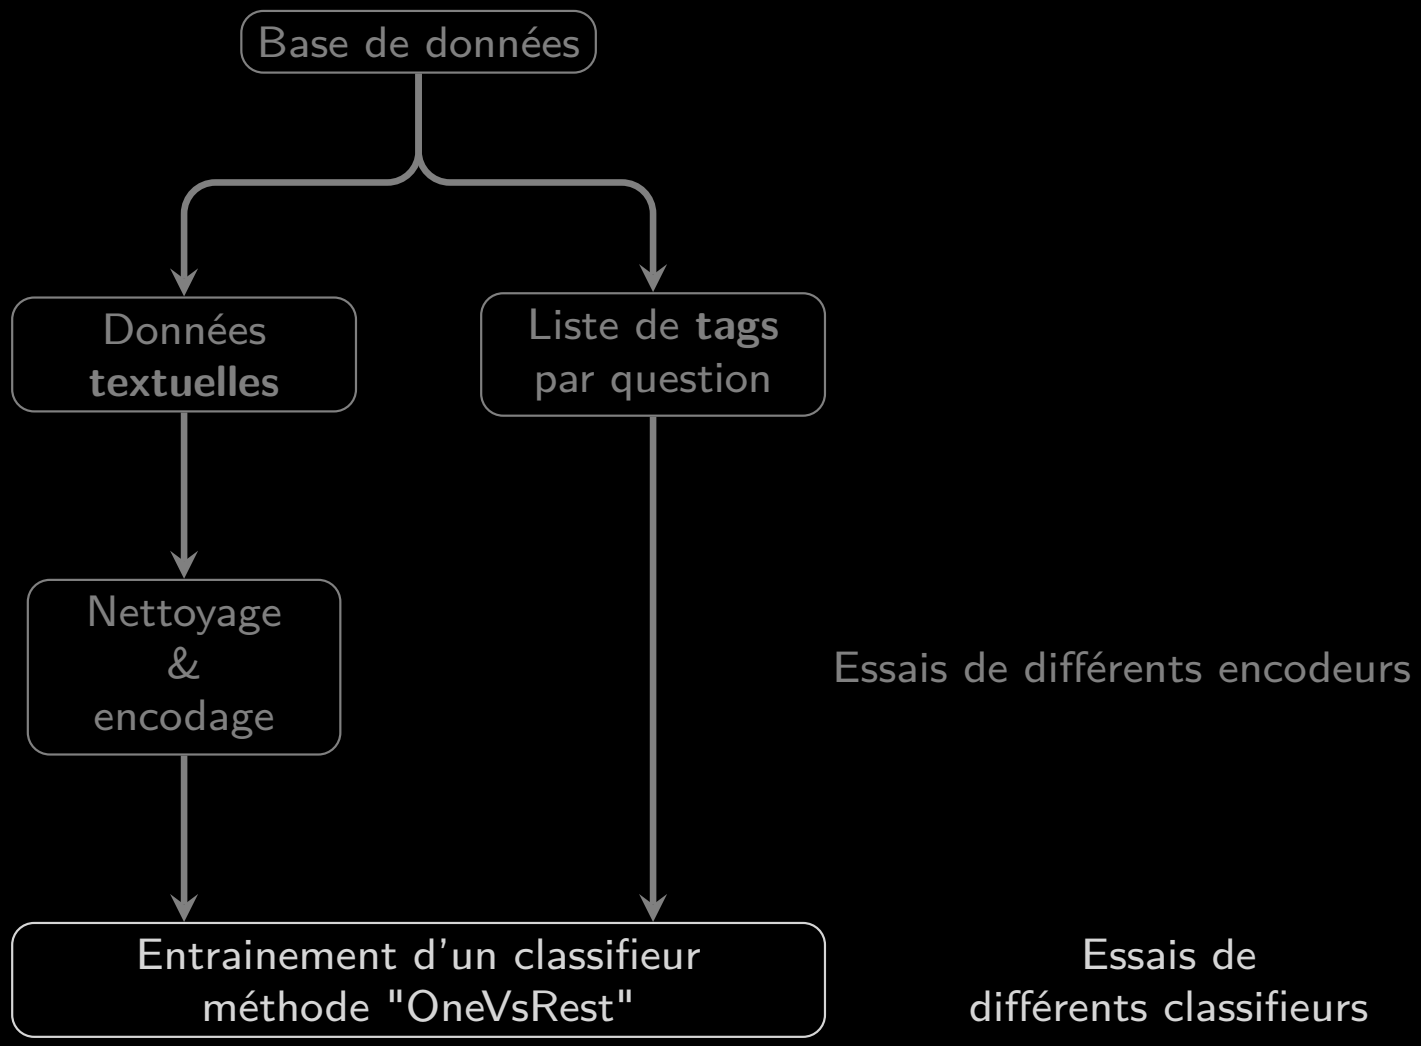
Base de données
Données textuelles
Liste de tags par question
Nettoyage & encodage
Essais de différents encodeurs
Entrainement d'un classifieur méthode "OneVsRest"
Essais de différents classifieurs

EXPLORATION DES DONNÉES

EXPLORATION DES DONNÉES

Valeurs manquantes

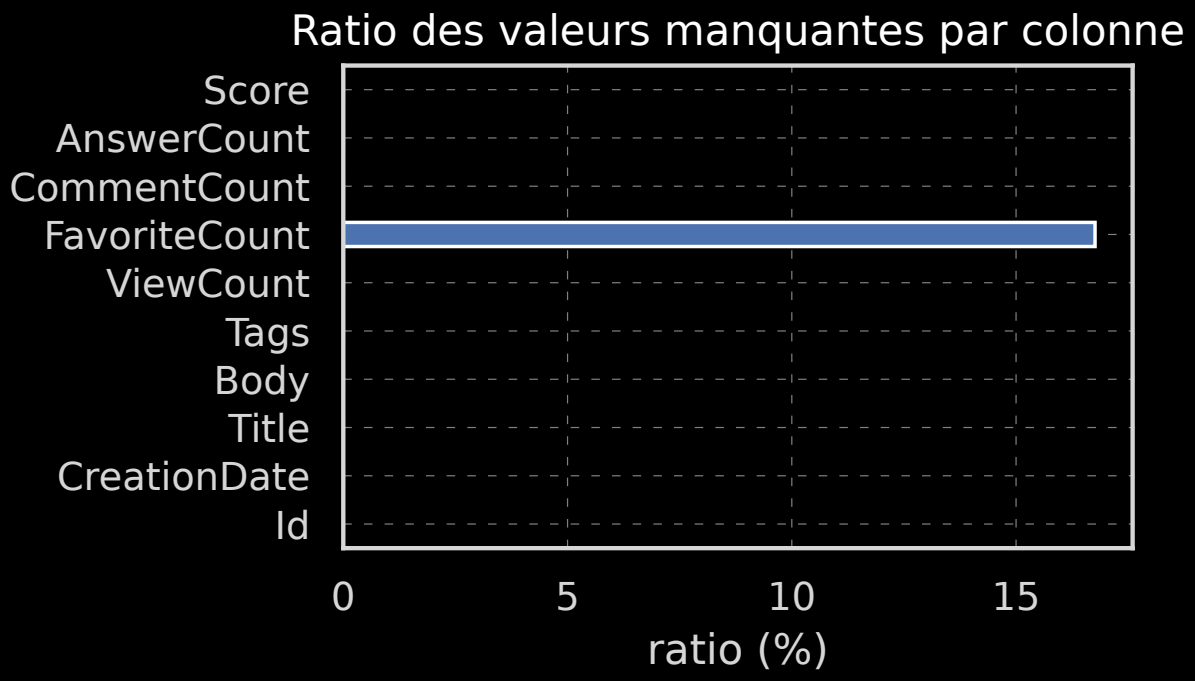
Ratio des valeurs manquantes par colonne
Score
AnswerCount
CommentCount
FavoriteCount
ViewCount
Tags
Body
Title
CreationDate
Id
0
5
10
15
ratio (%)

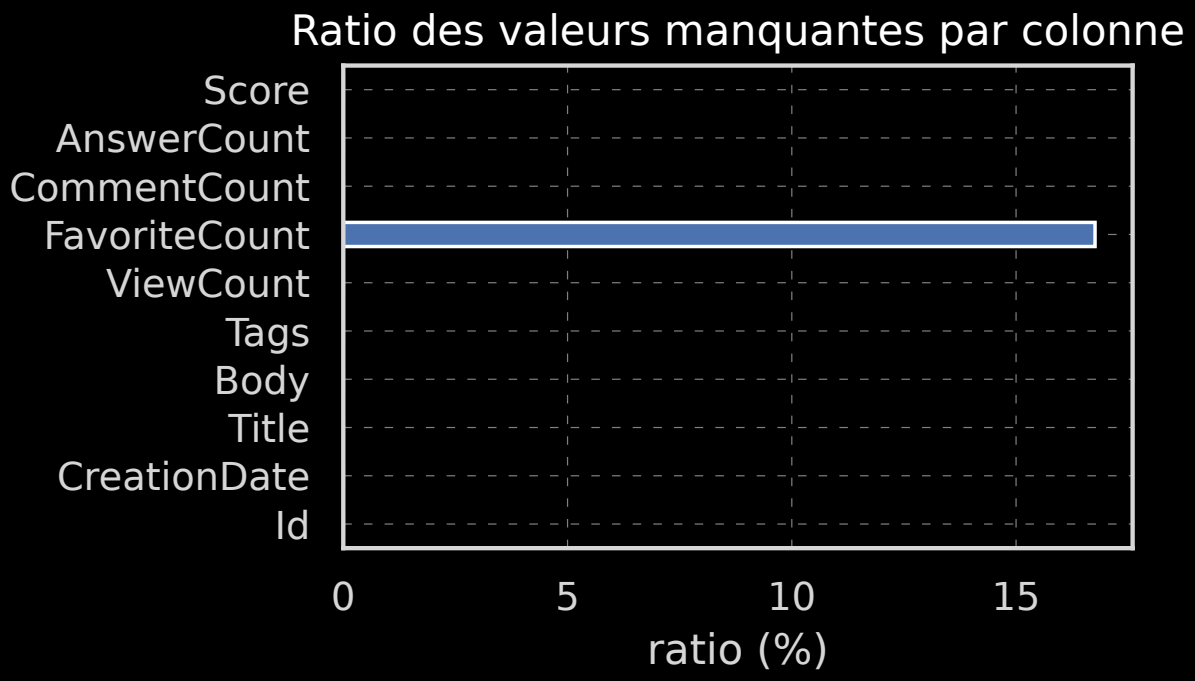

Mise à part le **FavoriteCount**, les **données** sont **complètes**

EXPLORATION DES DONNÉES

Questions

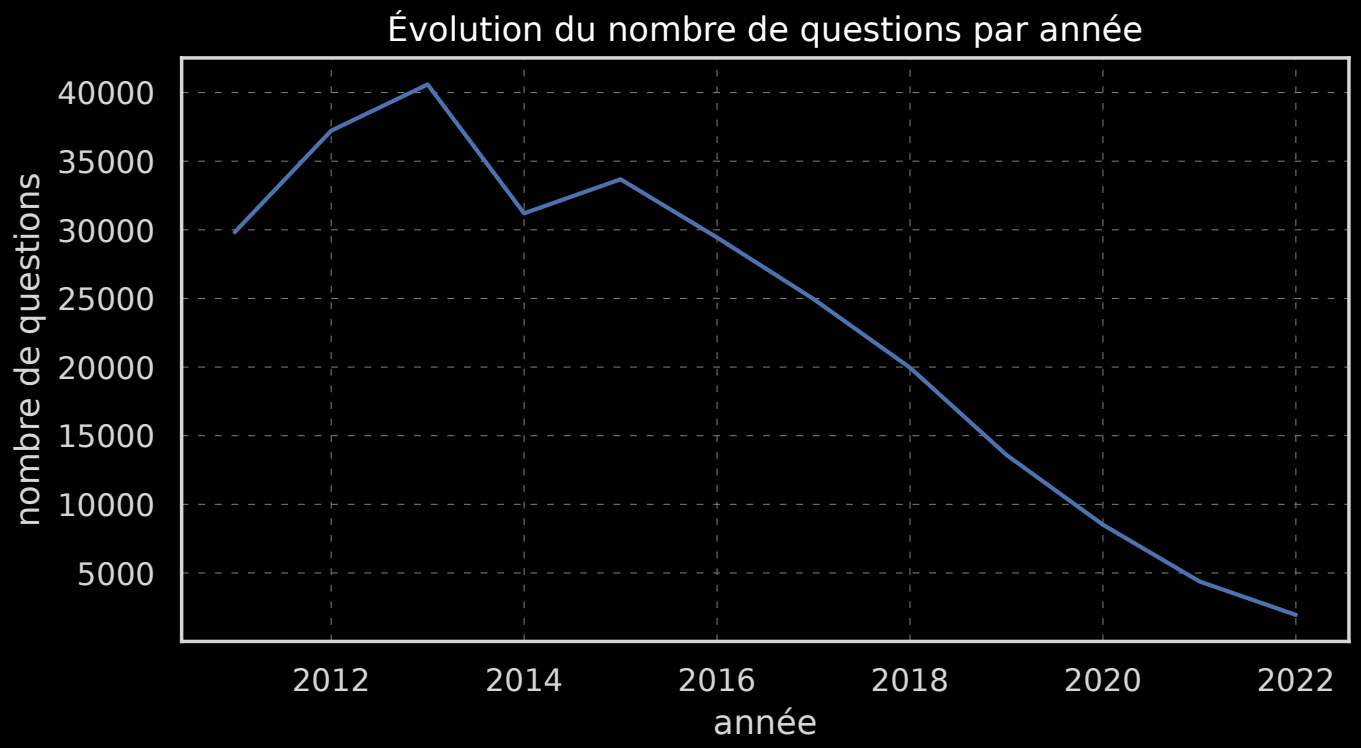
Évolution du nombre de questions par année
nombre de questions
40000
35000
30000
25000
20000
15000
10000
5000
2012
2014
2016
2018
2020
2022
année

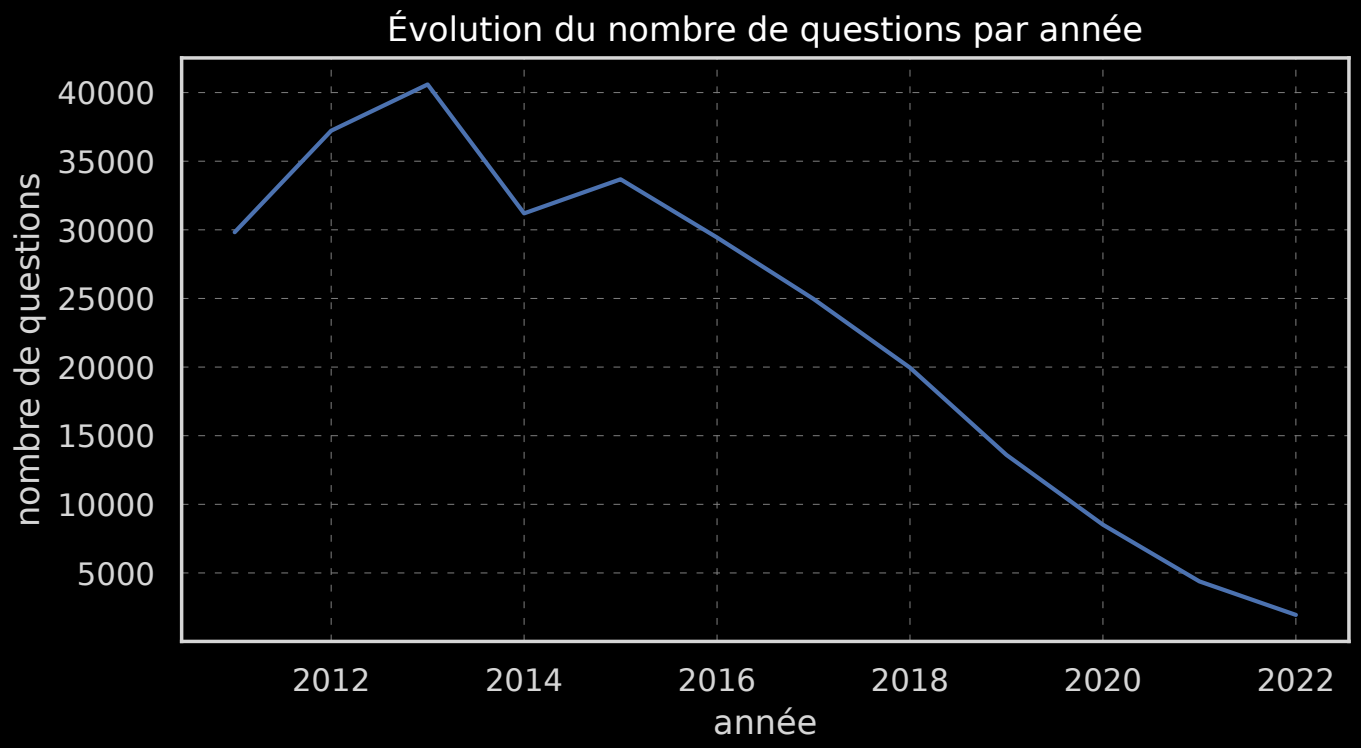

Diminution conséquente avec le temps (utilisation de l'existant, AI, ...)

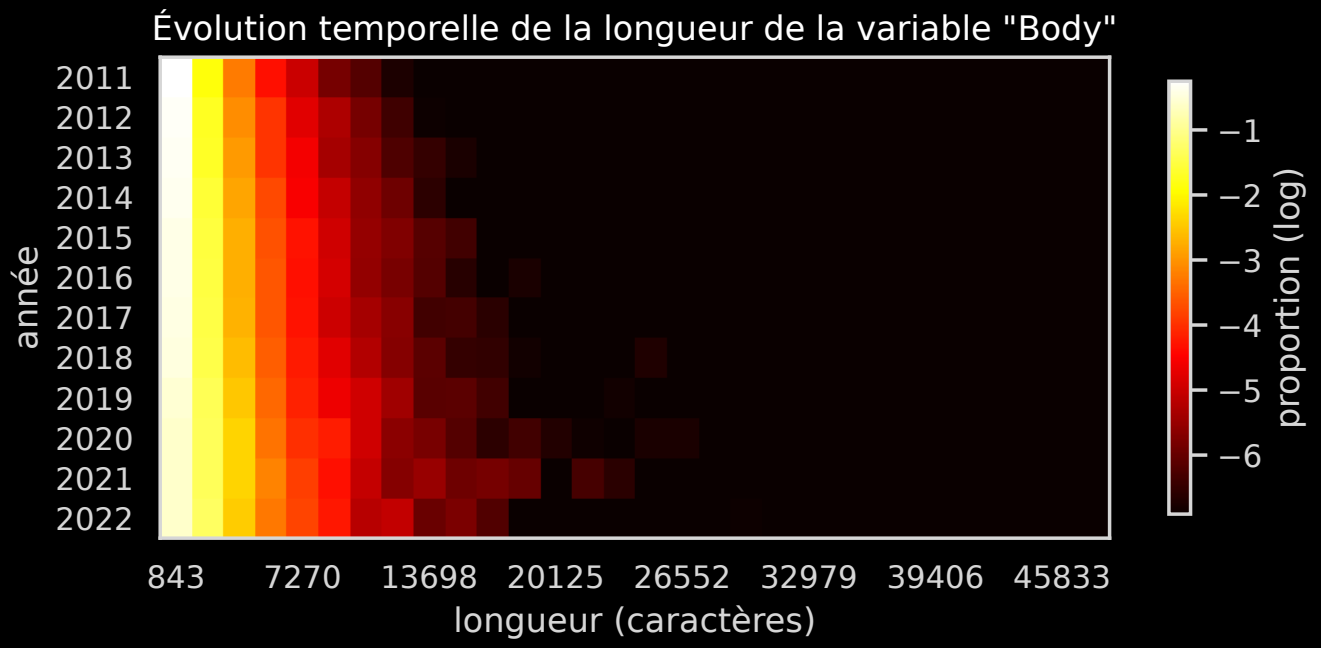
Évolution temporelle de la longueur de la variable "Body"
année
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
843
7270
13698
20125
26552
32979
39406
45833
longueur (caractères)
−1
−2
−3
−4
−5
−6
proportion (log)

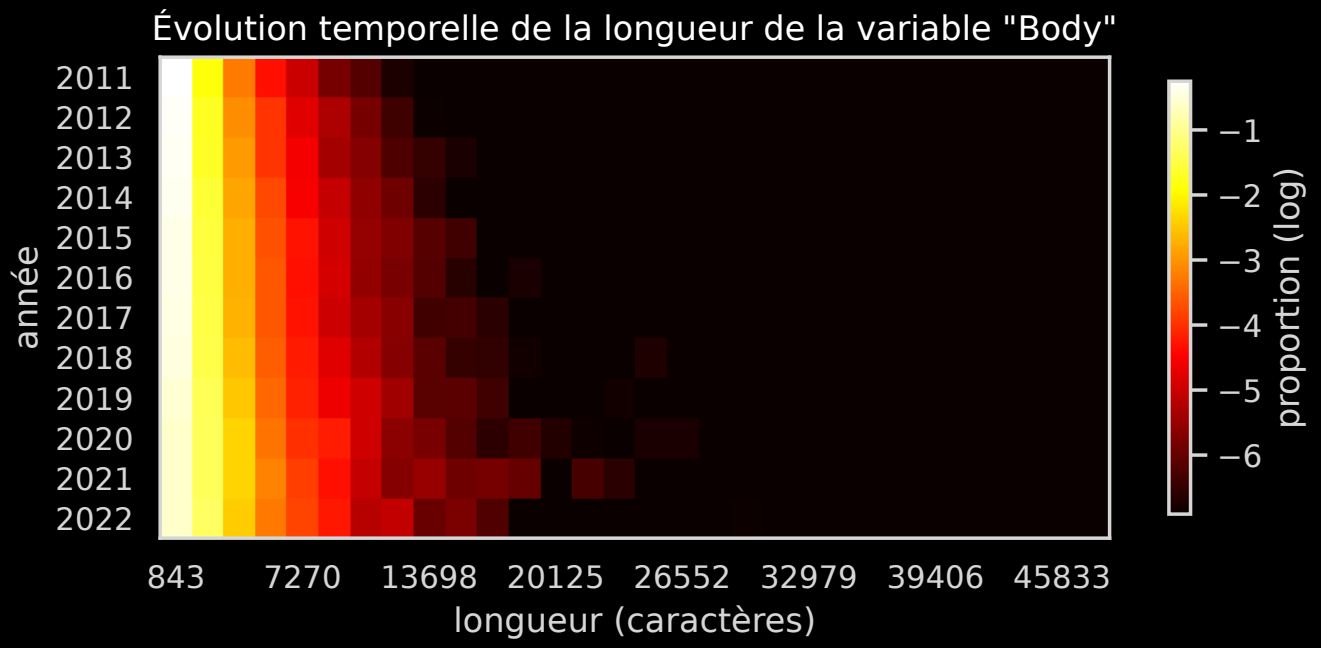

Longueur des corps de texte **relativement constante** dans le temps

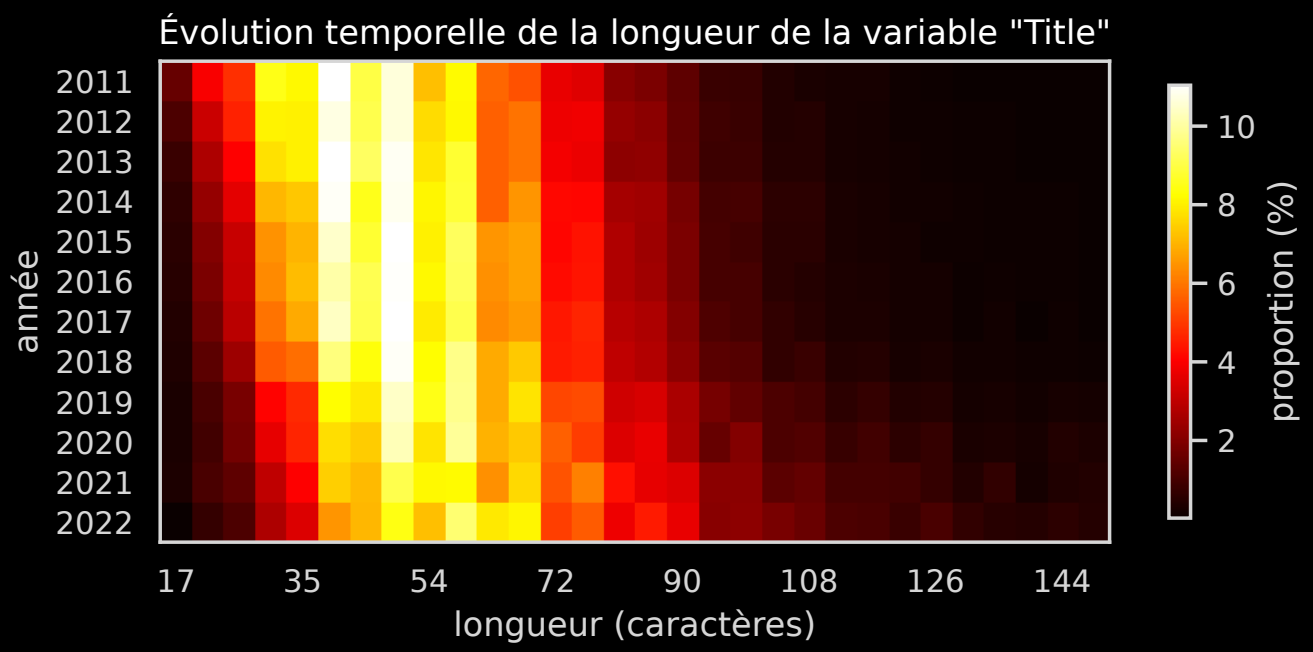
Évolution temporelle de la longueur de la variable "Title"
année
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
17
35
54
72
90
108
126
144
longueur (caractères)
10
8
6
4
2
proportion (%)

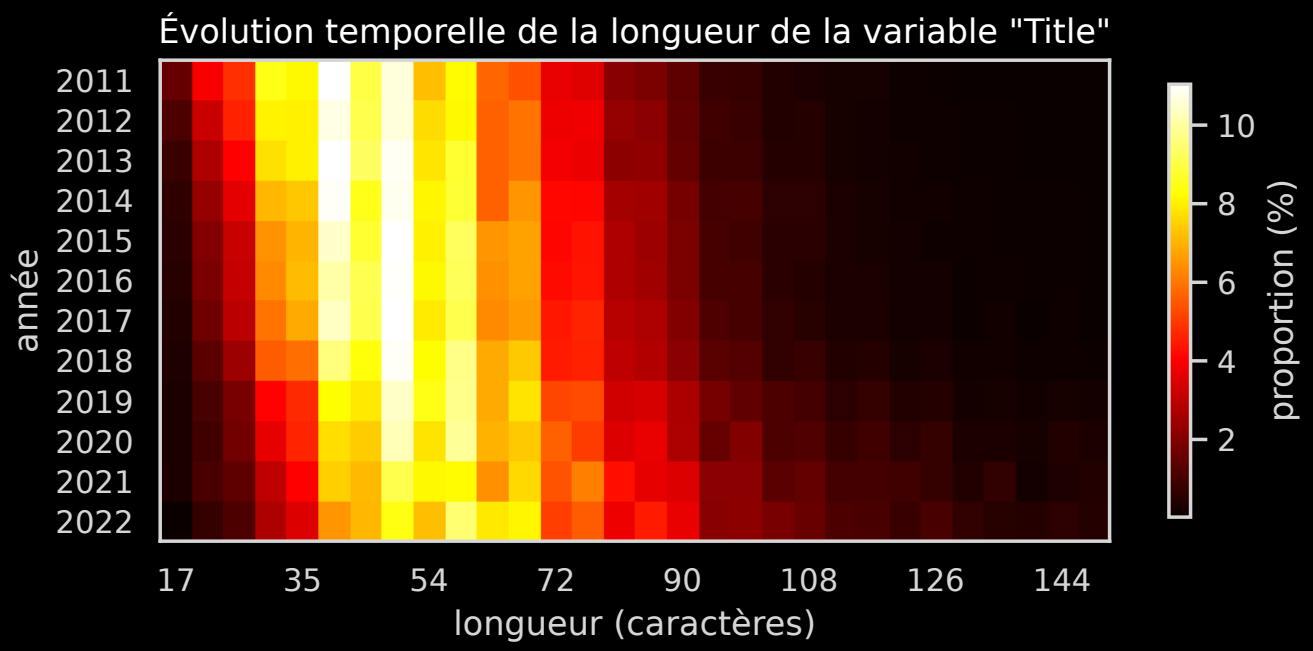

Allongement des **titres** des questions dans le temps

EXPLORATION DES DONNÉES

Tags

Tags les plus présents en 2011 et 2022

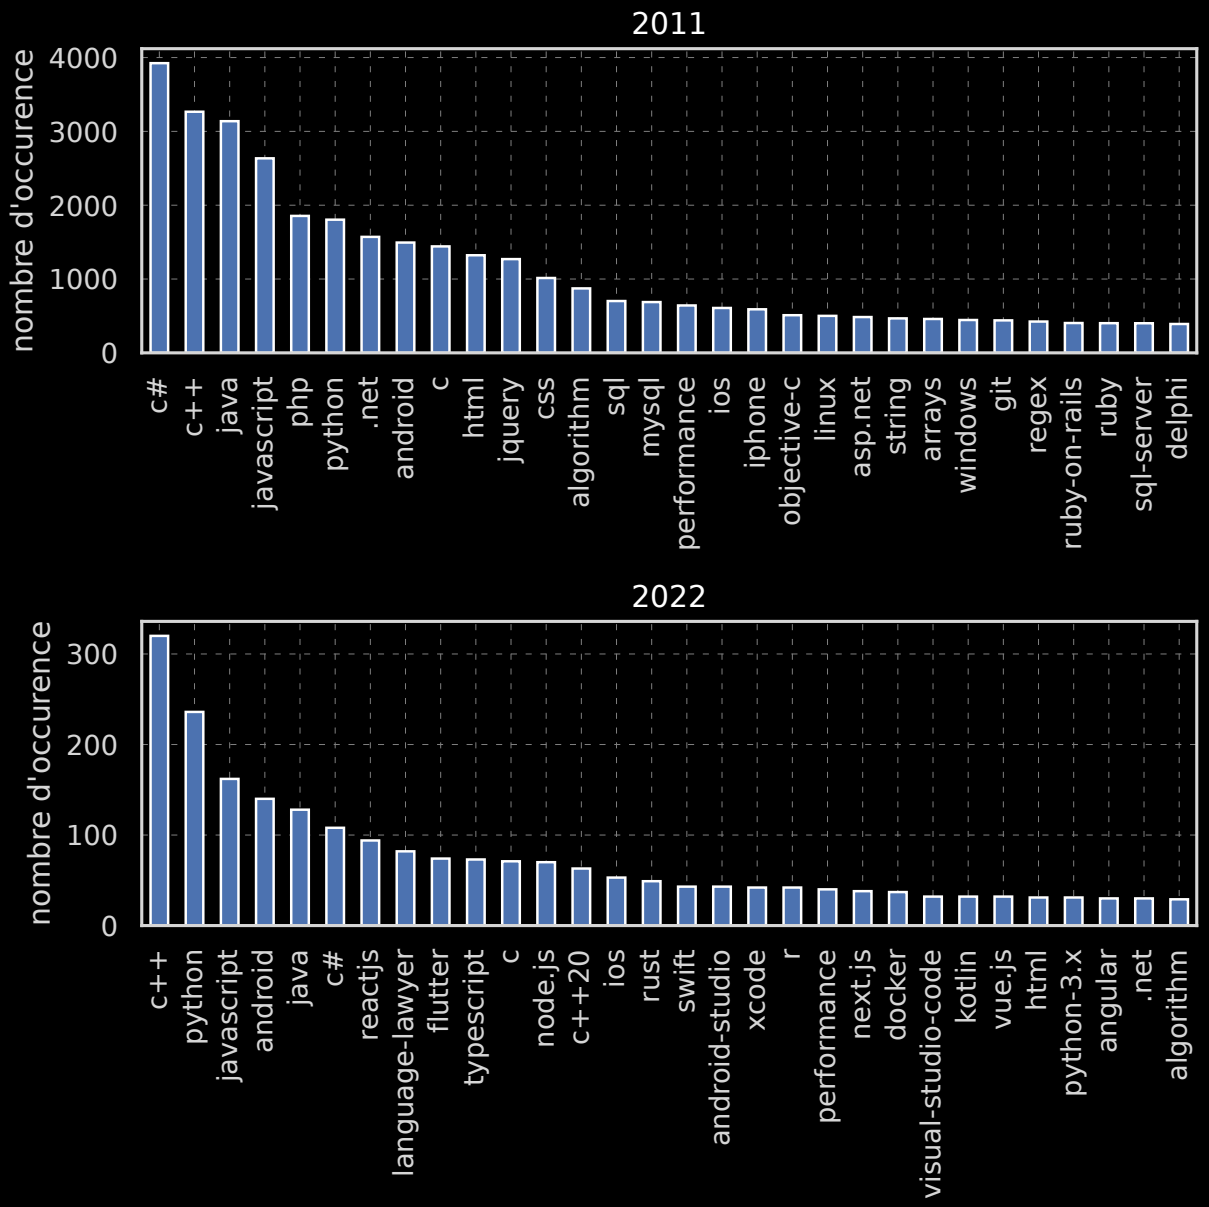

Tags les plus présents en 2011 et 2022

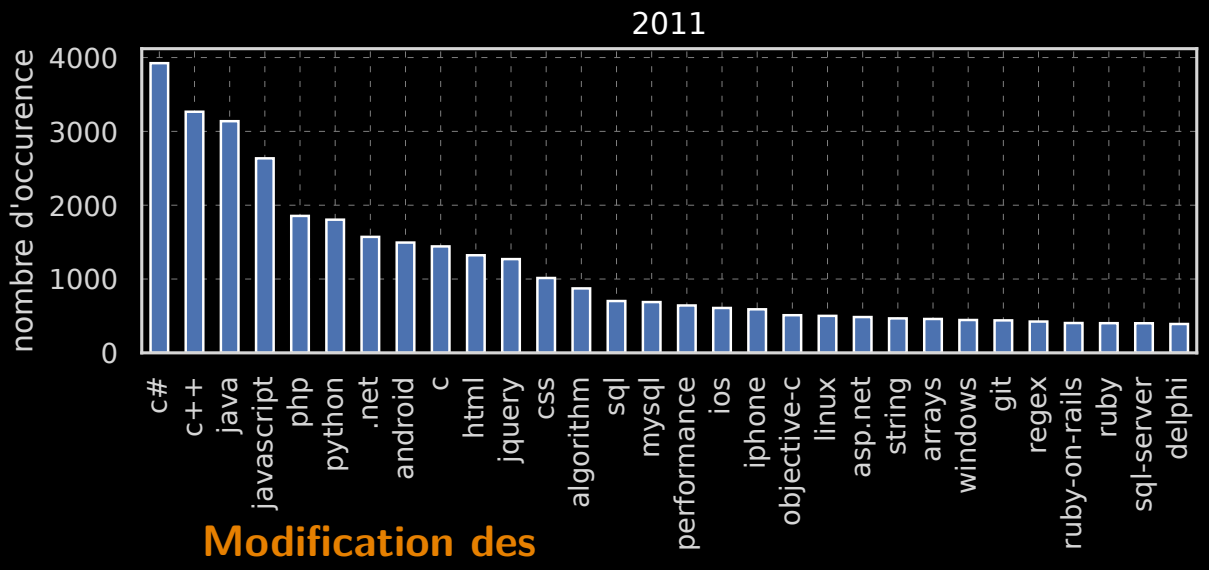

Modification des sujets avec le temps

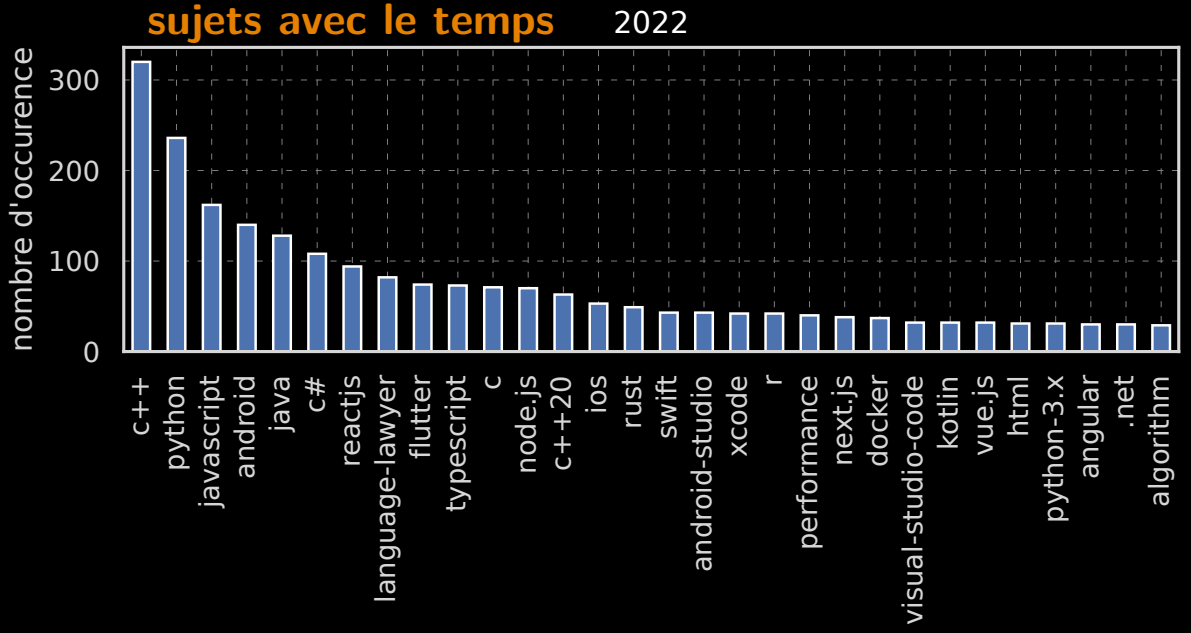

Estimation 2017 - 2023

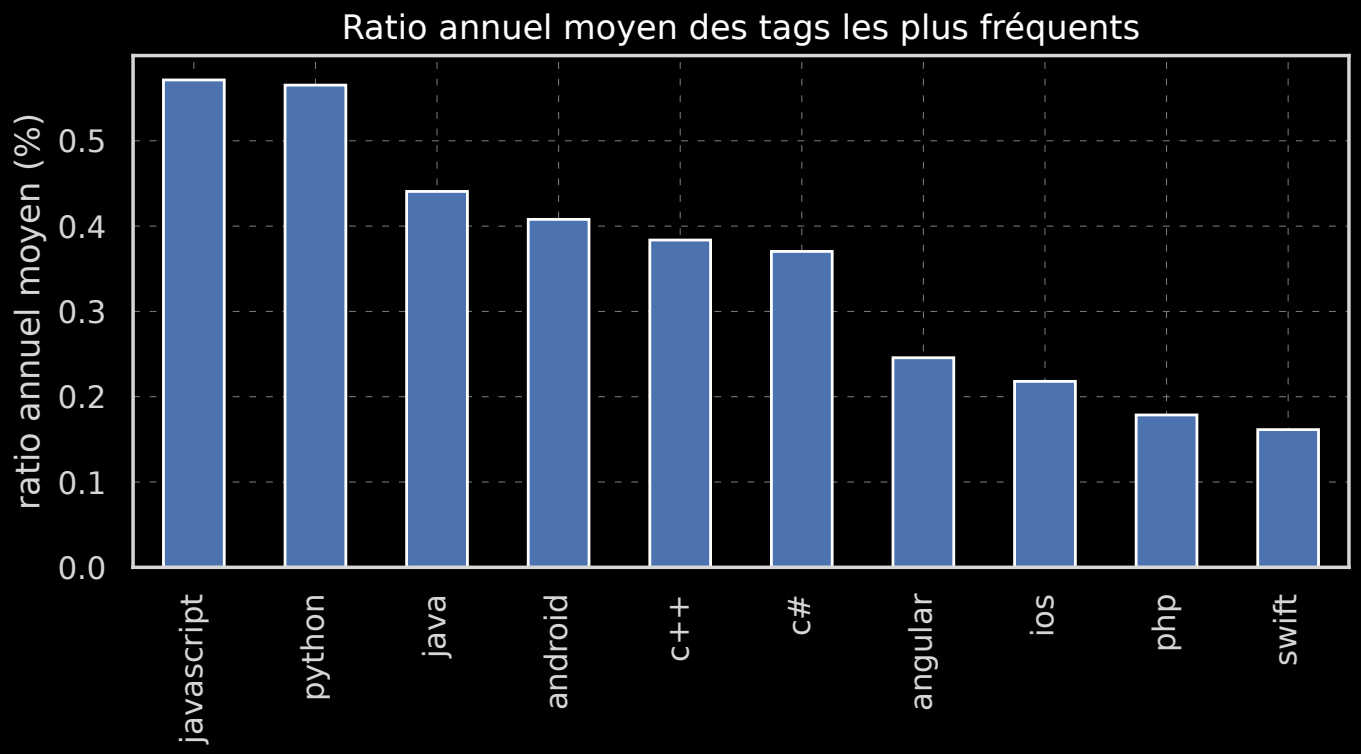

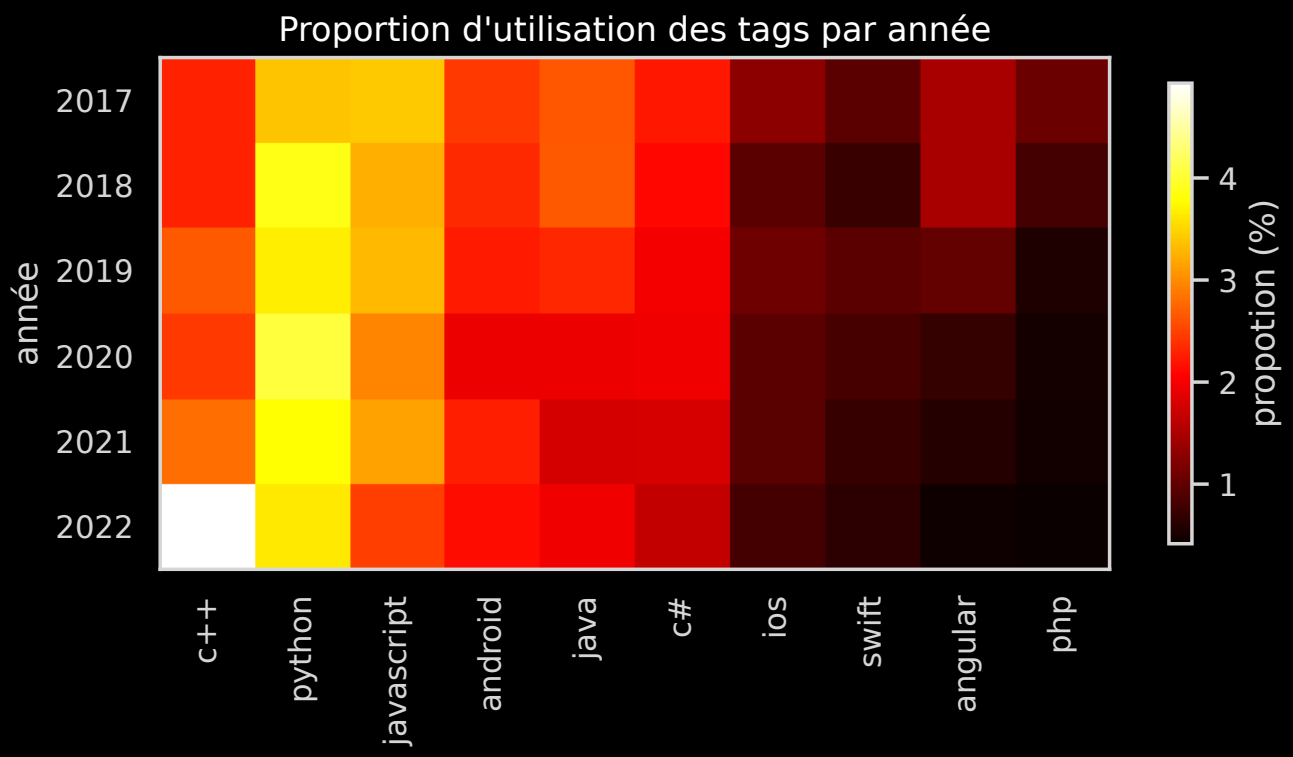
Proportion d'utilisation des tags par année
année
2017
2018
2019
2020
2021
2022
c++
python
javascript
android
java
c#
ios
swift
angular
php
propotion (%)
1
2
3
4

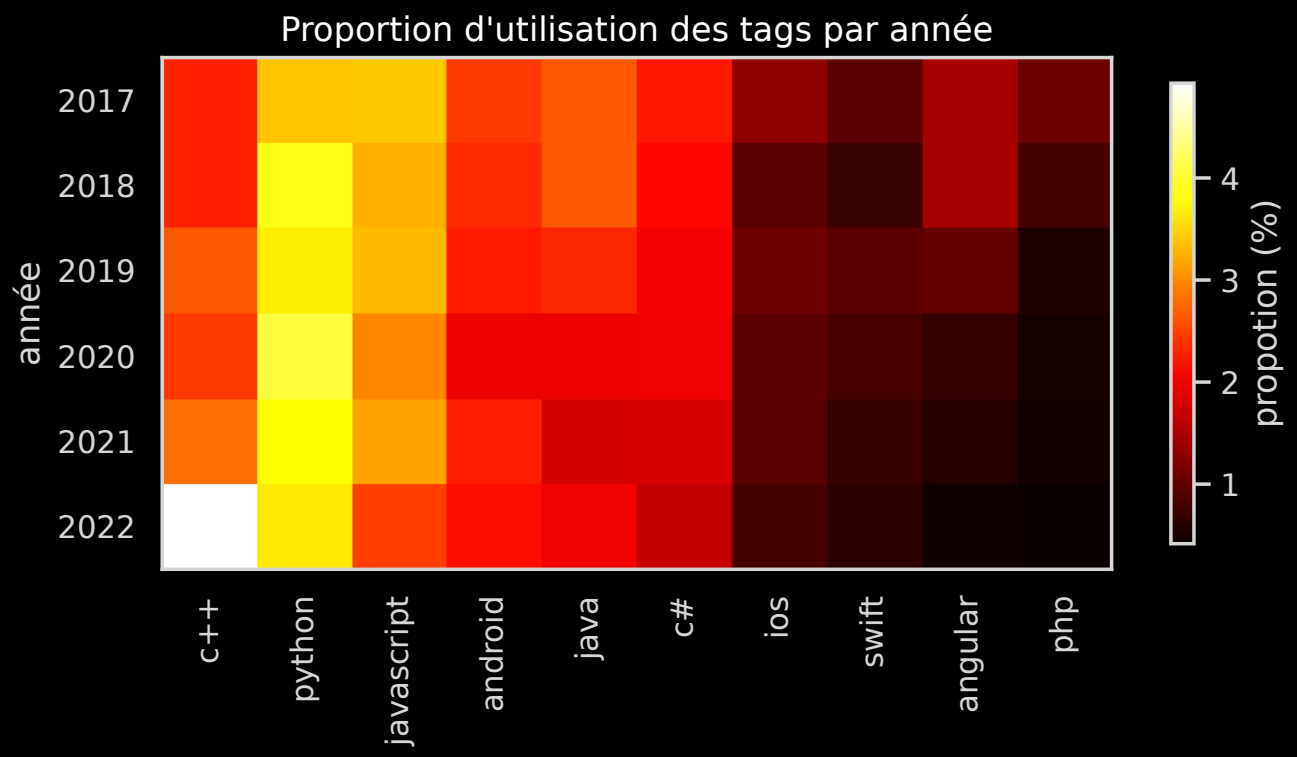

Les **proportions varient** dans le temps

Pour cette analyse, **10 tags** sont conservés

Pour cette analyse, **10 tags** sont conservés

Suppression des questions sans aucun des tags étudiés
(275 325 → **173 255 questions**)

Pour cette analyse, **10 tags** sont conservés

Suppression des questions sans aucun des tags étudiés
(275 325 → **173 255 questions**)

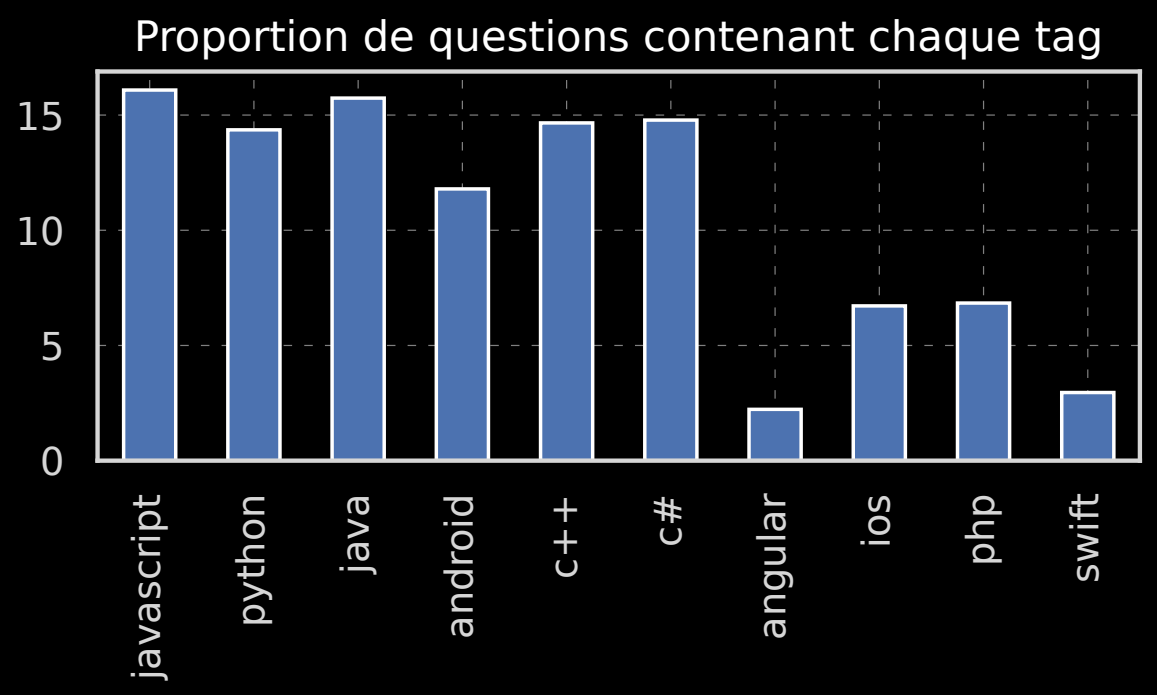

Pour cette analyse, **10 tags** sont conservés

Suppression des questions sans aucun des tags étudiés
(275 325 → **173 255 questions**)

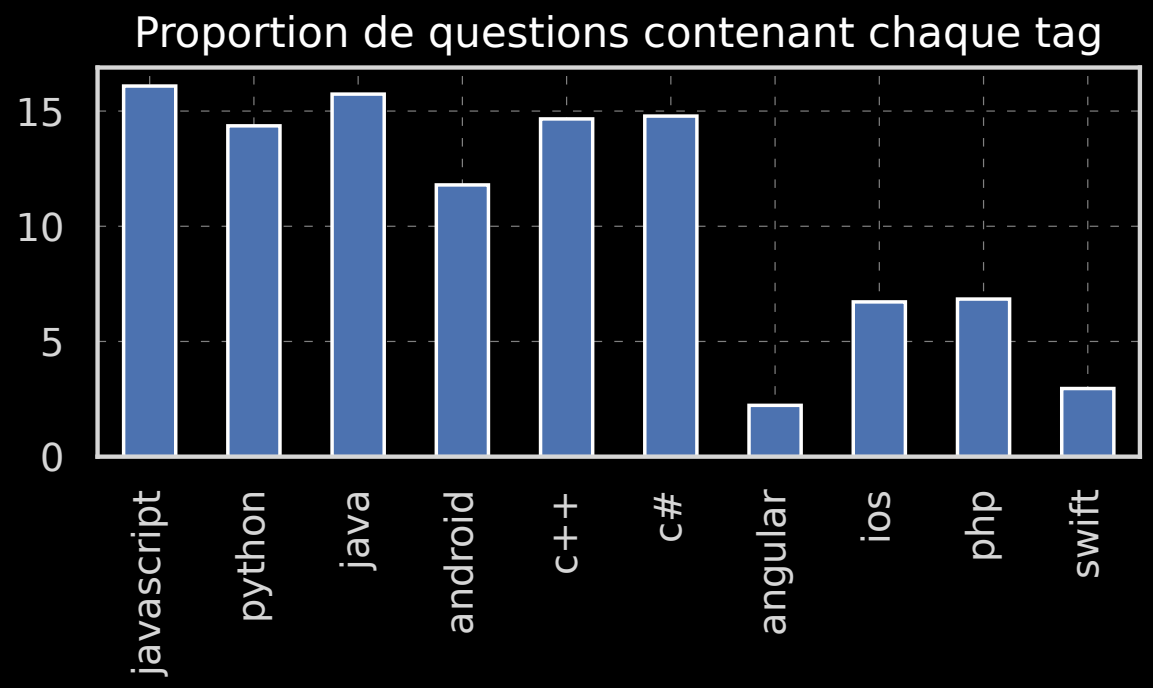

Seulement **10 441 questions** avec **plus d'un des tags** sélectionnés

EXPLORATION DES DONNÉES

Traitements

Chaîne de traitement des entrées

Chaîne de traitement des entrées

Nettoyage

Nettoyage

- Majuscules → minuscules ;
- remplacement des contractions ;
- suppression URL, html, non ascii, caractères spéciaux

Chaîne de traitement des entrées

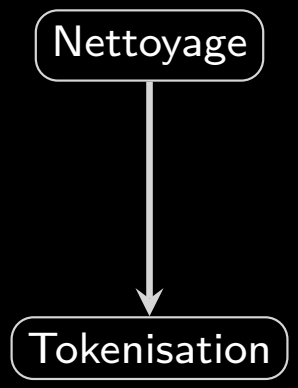

- Majuscules → minuscules ;
- remplacement des contractions ;
- suppression URL, html, non ascii, caractères spéciaux

Chaîne de traitement des entrées

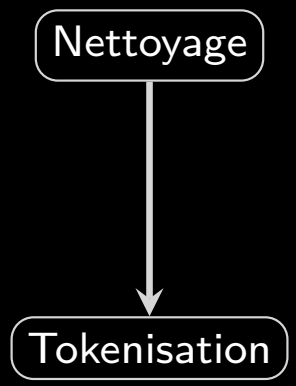

- Majuscules → minuscules ;
- remplacement des contractions ;
- suppression URL, html, non ascii, caractères spéciaux

- Séparation des mots
- Suppression des mots courants

Chaîne de traitement des entrées

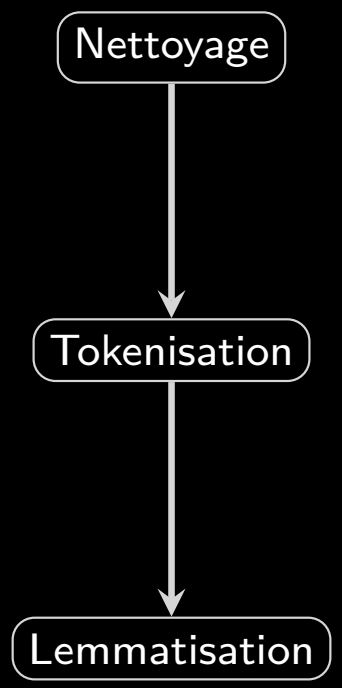

- Majuscules → minuscules ;
- remplacement des contractions ;
- suppression URL, html, non ascii, caractères spéciaux

- Séparation des mots
- Suppression des mots courants

Chaîne de traitement des entrées

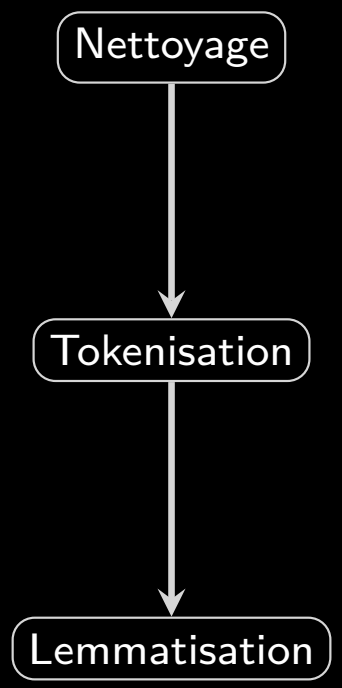

- Majuscules → minuscules ;
- remplacement des contractions ;
- suppression URL, html, non ascii, caractères spéciaux

- Séparation des mots
- Suppression des mots courants

- Translation des mots vers leur forme canonique

Exemple de traitement

Entrée brute:

Entrée brute:

<p>I've created a C# WinForms application using VS2010...

Exemple de traitement

Entrée brute:

<p>I've created a C# WinForms application using VS2010...

Entrée nettoyée:

Exemple de traitement

Entrée brute:

<p>I've created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Exemple de traitement

Entrée brute:

<p>I’ve created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

Exemple de traitement

Entrée brute:

<p>I’ve created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

’created’, ’c#’, ’winforms’, ’application’, ’using’, ’vs2010’...

Exemple de traitement

Entrée brute:

<p>I've created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

'created', 'c#', 'winforms', 'application', 'using', 'vs2010'...

Entrée lemmatisée:

Exemple de traitement

Entrée brute:

<p>I've created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

'created', 'c#', 'winforms', 'application', 'using', 'vs2010'...

Entrée lemmatisée:

'create', 'c#', 'winform', 'application', 'use', 'vs2010'...

Exemple de traitement

Entrée brute:

<p>I’ve created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

’created’, ’c#’, ’winforms’, ’application’, ’using’, ’vs2010’...

Entrée lemmatisée:

’create’, ’c#’, ’winform’, ’application’, ’use’, ’vs2010’...

Entrée stemmatisée (example):

Exemple de traitement

Entrée brute:

<p>I've created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

'created', 'c#', 'winforms', 'application', 'using', 'vs2010'...

Entrée lemmatisée:

'create', 'c#', 'winform', 'application', 'use', 'vs2010'...

Entrée stemmatisée (example):

'creat', 'c#', 'winform', 'applic', 'use', 'vs2010'...

Exemple de traitement

Entrée brute:

<p>I’ve created a C# WinForms application using VS2010...

Entrée nettoyée:

i have created a c# winforms application using vs2010...

Entrée tokenisée:

’created’, ’c#’, ’winforms’, ’application’, ’using’, ’vs2010’...

Entrée lemmatisée:

’create’, ’c#’, ’winform’, ’application’, ’use’, ’vs2010’...

~~Entrée stemmatisée (exemple):~~

~~’creat’, ’c#’, ’winform’, ’applic’, ’use’, ’vs2010’...~~

ESSAIS DE MODÉLISATIONS

ESSAIS DE MODÉLISATIONS

Méthode non supervisée : Latent Dirichlet Allocation

Encodeur : TFIDF (1000 mots)

Encodeur : TFIDF (1000 mots)

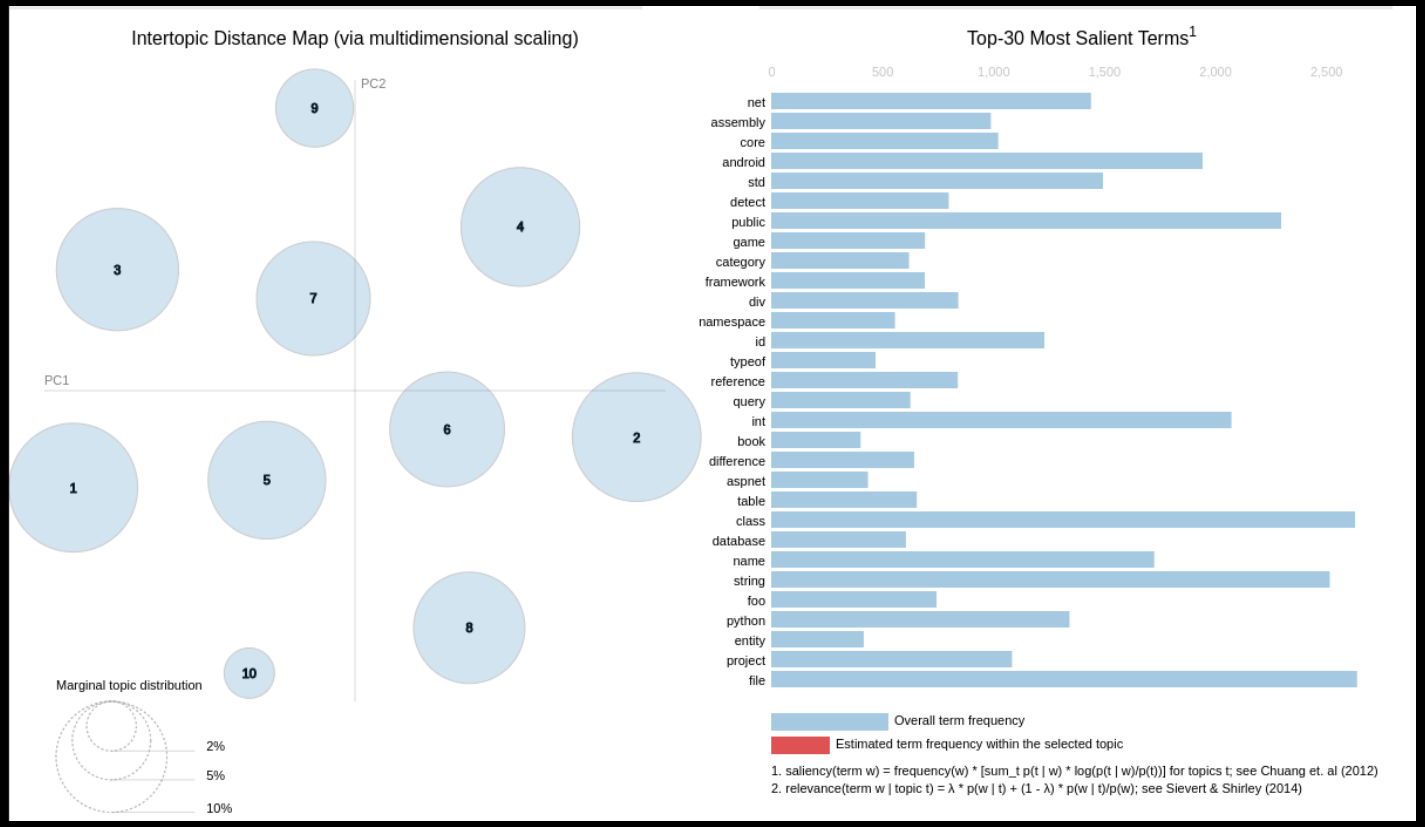

Encodeur : TFIDF (1000 mots)

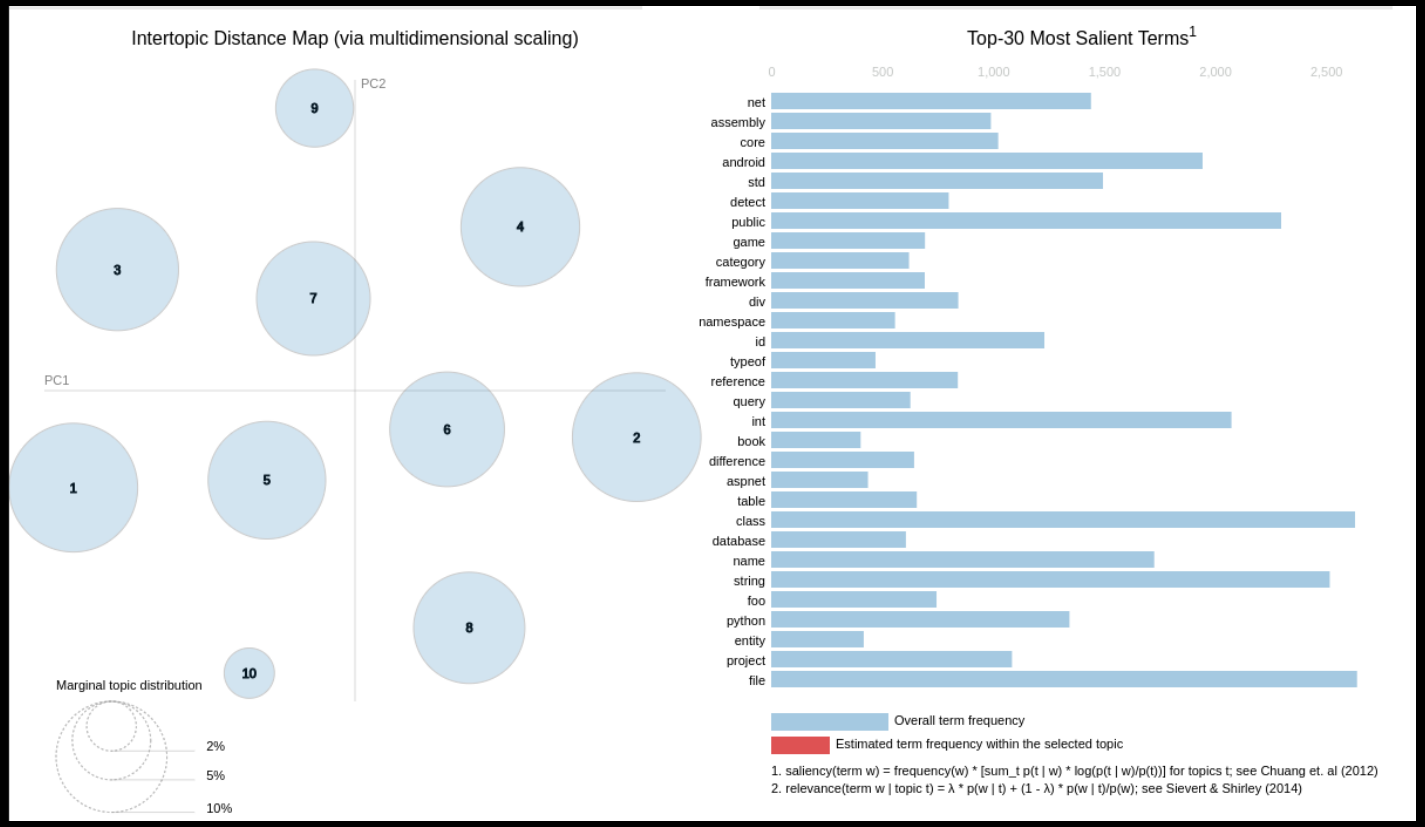

À priori pas utilisable pour ce projet

ESSAIS DE MODÉLISATIONS

Quel classifieur ?

Encodeur : TFIDF (300 mots)

Encodeur : TFIDF (300 mots)

Modèles explorés:

Encodeur : TFIDF (300 mots)

Modèles explorés:

Logistic Regression

Encodeur : TFIDF (300 mots)

Modèles explorés:

Logistic Regression

SGD Classifier

Encodeur : TFIDF (300 mots)

Modèles explorés:

Logistic Regression

SGD Classifier

Multinomial NB

Encodeur : TFIDF (300 mots)

Modèles explorés:

Logistic Regression

SGD Classifier

Multinomial NB

Perceptron

Encodeur : TFIDF (300 mots)

Modèles explorés:

- Logistic Regression
- SGD Classifier
- Multinomial NB
- Perceptron
- Passive Aggressive Classifier

Encodeur : TFIDF (300 mots)

Modèles explorés:

- Logistic Regression
- SGD Classifier
- Multinomial NB
- Perceptron
- Passive Aggressive Classifier

Modèles non-explorés:

Encodeur : TFIDF (300 mots)

Modèles explorés:

- Logistic Regression
- SGD Classifier
- Multinomial NB
- Perceptron
- Passive Aggressive Classifier

Modèles non-explorés:

- SVC: non convergeant

Encodeur : TFIDF (300 mots)

Modèles explorés:

- Logistic Regression
- SGD Classifier
- Multinomial NB
- Perceptron
- Passive Aggressive Classifier

Modèles non-explorés:

- SVC: non convergeant
- ExtraTrees: calculs très longs

Encodeur : TFIDF (300 mots)

Modèles explorés:

Logistic Regression

SGD Classifier

Multinomial NB

Perceptron

Passive Aggressive Classifier

Modèles non-explorés:

SVC: non convergeant

ExtraTrees: calculs très longs

Dans un **contexte industriel**:
calculs effectués sur **serveur**

Résultats

Résultats

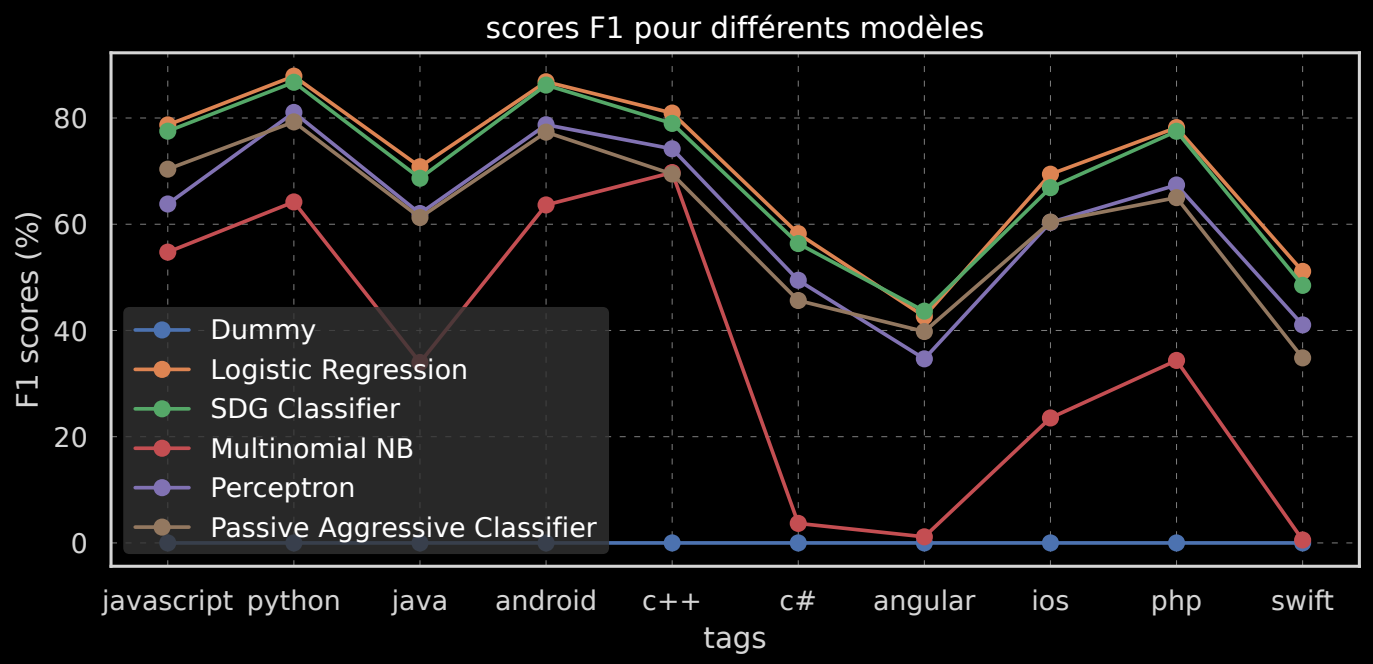
scores F1 pour différents modèles
F1 scores (%)
0
20
40
60
80
Dummy
Logistic Regression
SDG Classifier
Multinomial NB
Perceptron
Passive Aggressive Classifier
javascript
python
java
android
c++
c#
angular
ios
php
swift
tags

Résultats

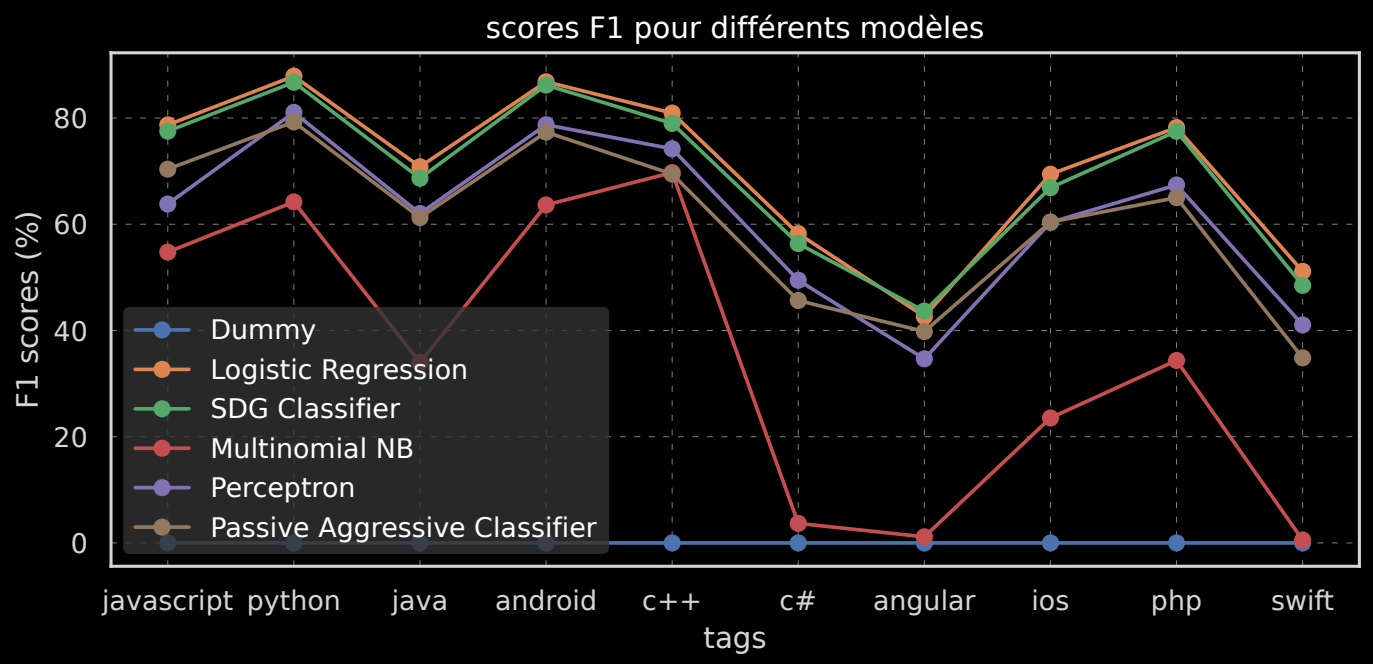

La **régression logistique** fourni les **meilleurs résultats**

Résultats

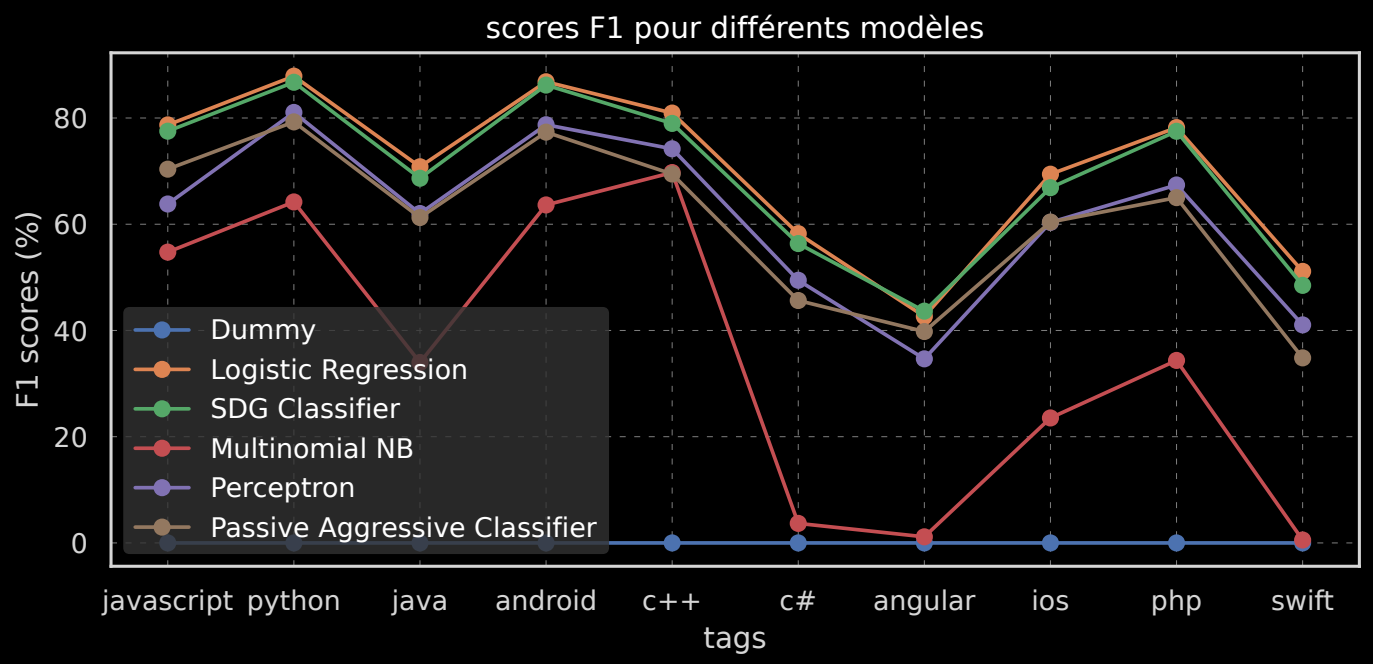

La **régression logistique** fourni les **meilleurs résultats**

Le **classifieur SGD** est **plus rapide** à entrainer
pour des **résultats proches** (temps divisé par 1,4)

ESSAIS DE MODÉLISATIONS

Intérêt d'un PCA ?

Encodeur : TFIDF (1000 mots)
modèle : regression logistique

Encodeur : TFIDF (1000 mots)
modèle : regression logistique

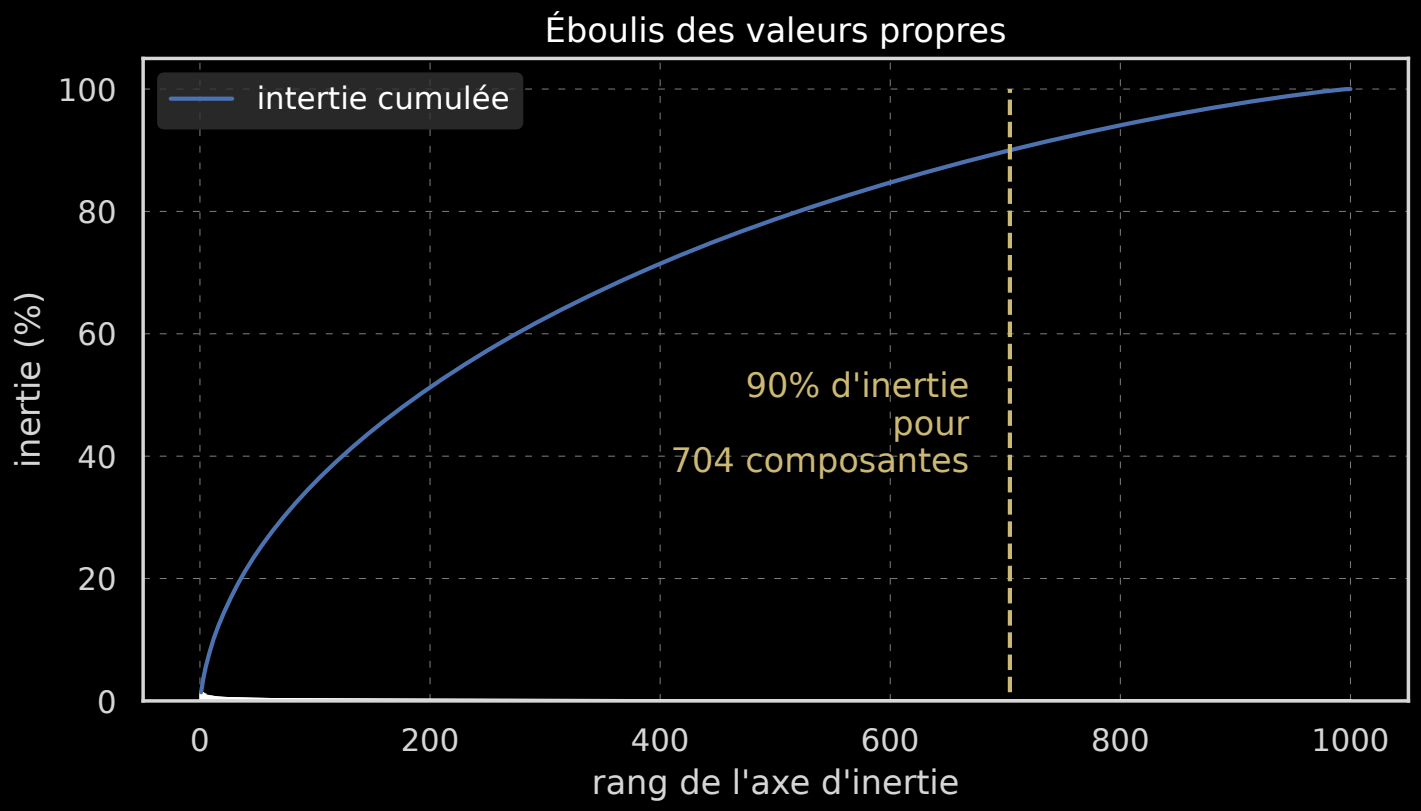

Encodeur : TFIDF (1000 mots)
modèle : regression logistique

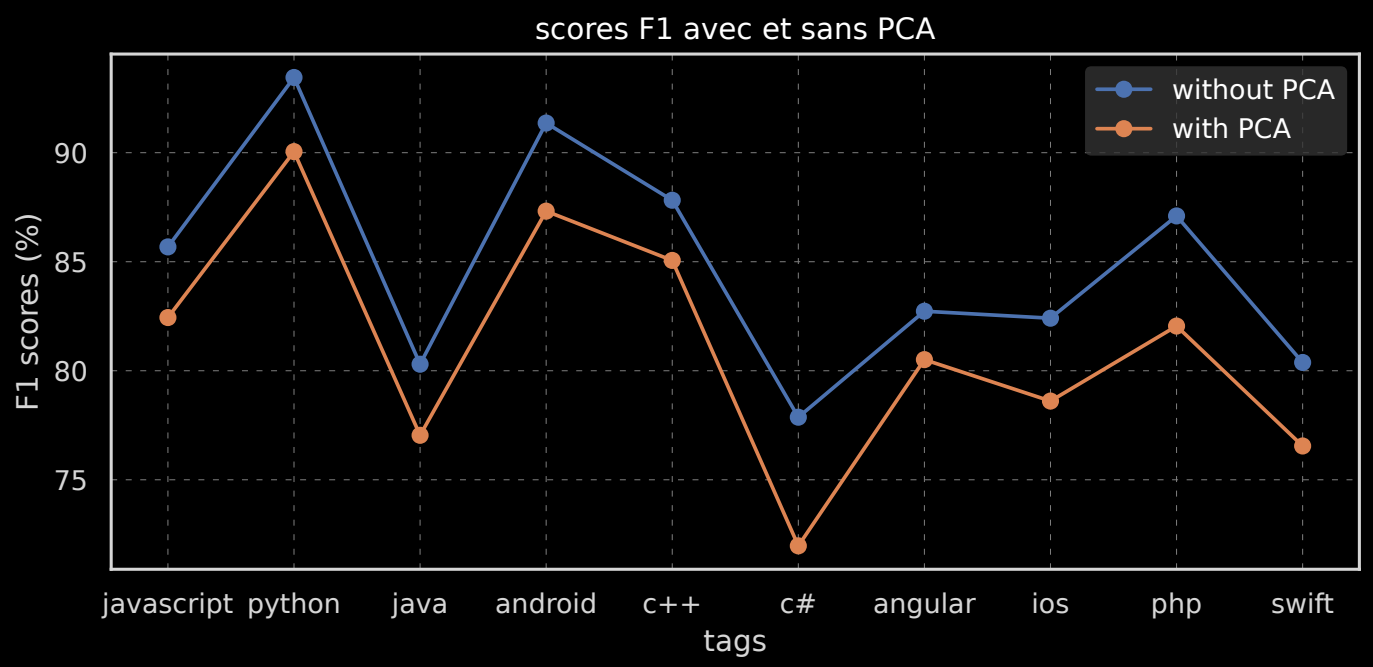

Encodeur : TFIDF (1000 mots)
modèle : regression logistique

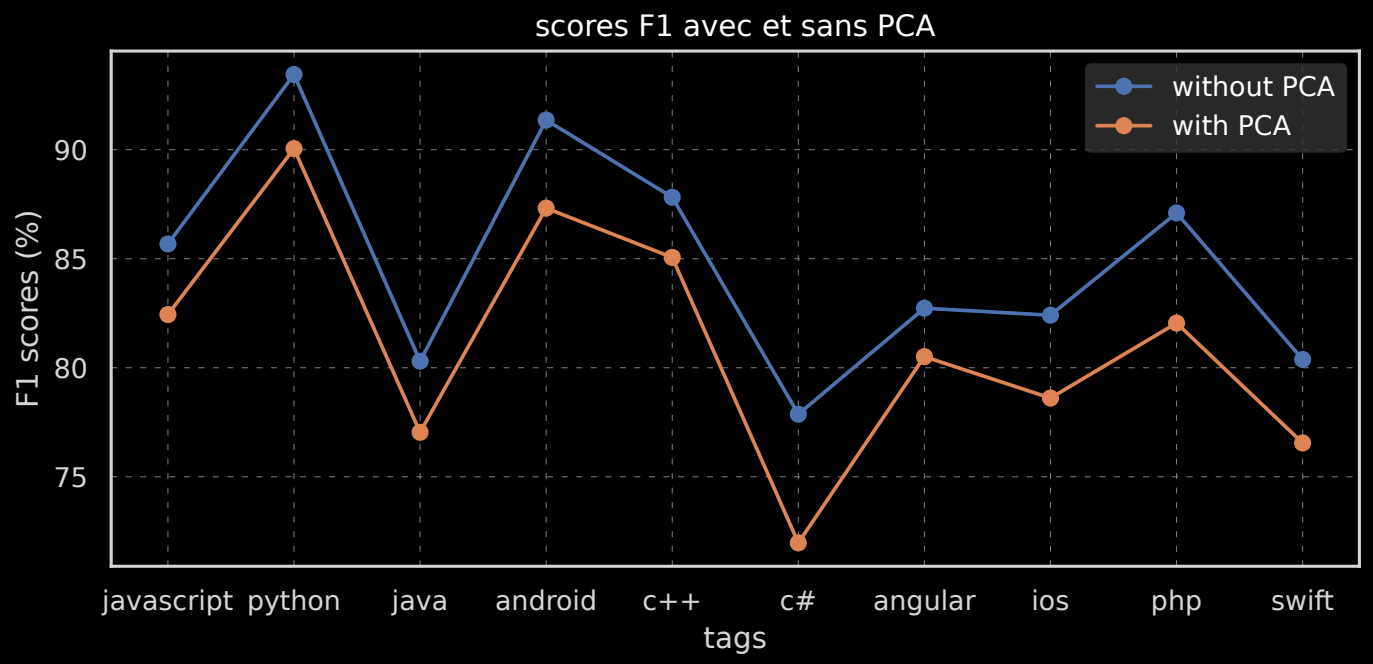

PCA non pertinente ici

ESSAIS DE MODÉLISATIONS

Intérêt d'une régularisation ?

Encodeur : TFIDF (900 mots)
modèle : regression logistique

Encodeur : TFIDF (900 mots)
modèle : regression logistique

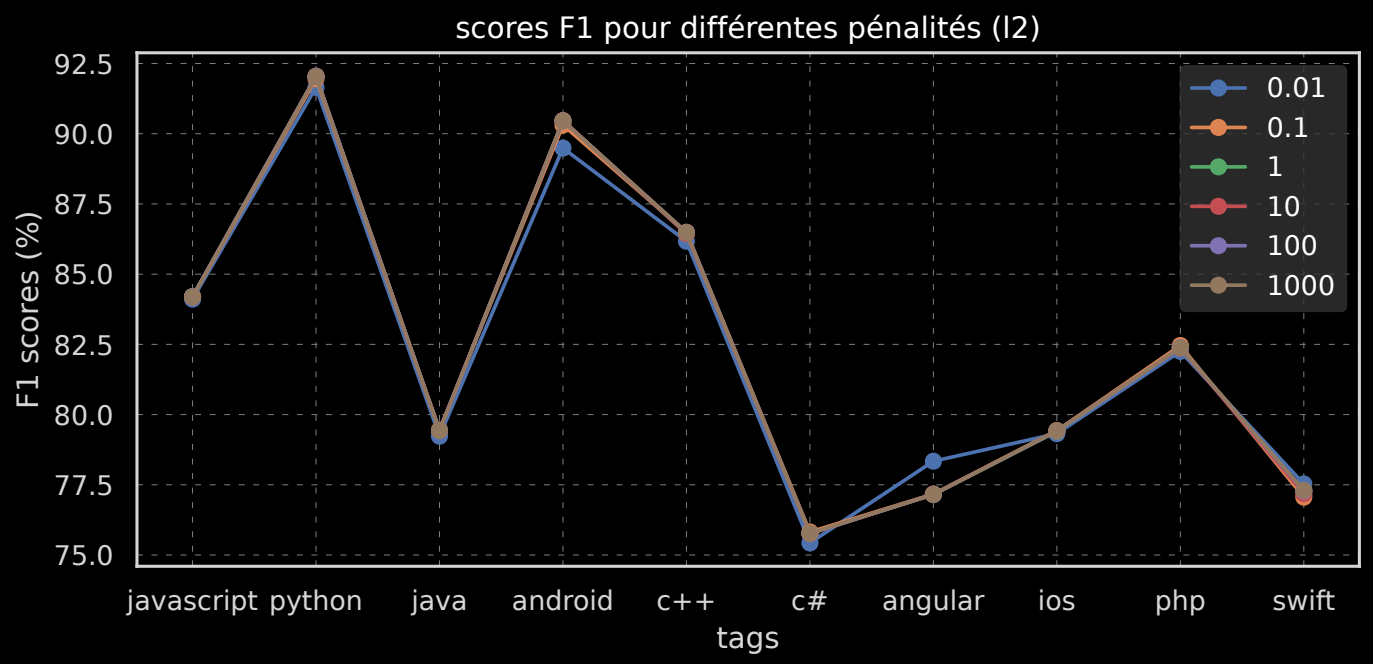

Encodeur : TFIDF (900 mots)
modèle : regression logistique

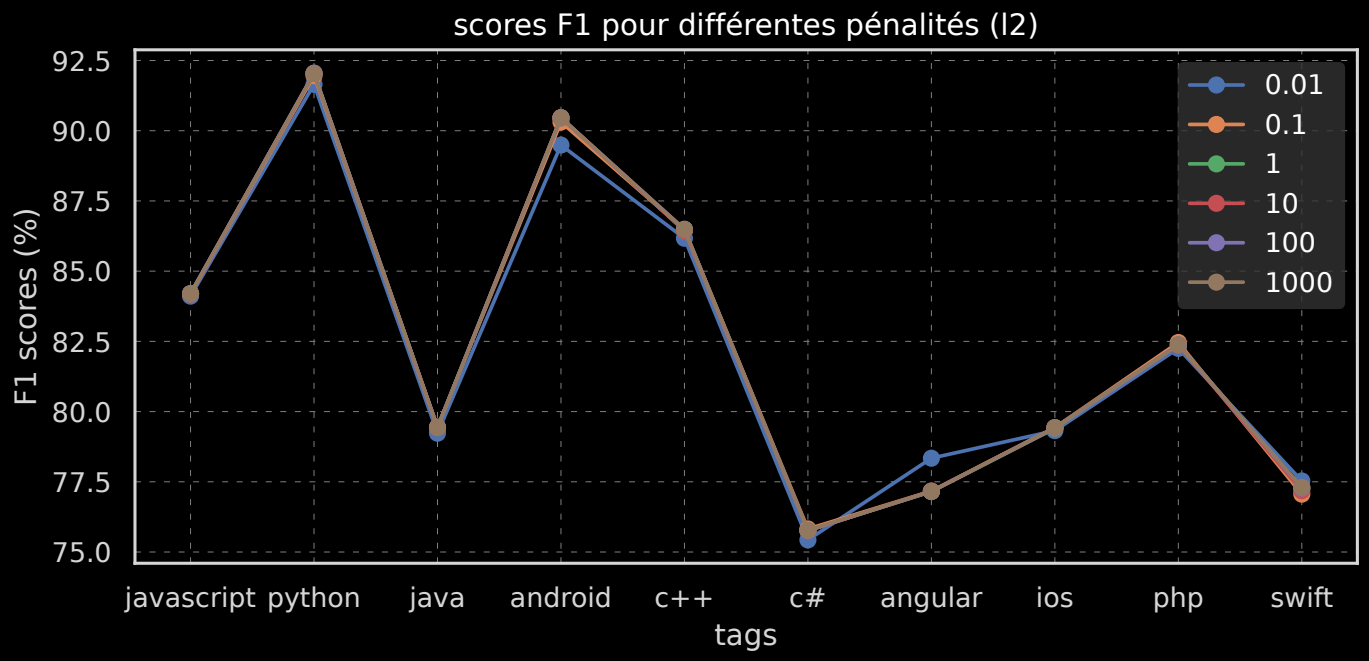

Influence faible sur les résultats

ESSAIS DE MODÉLISATIONS

Longueur du vocabulaire ?

Encodeur : TFIDF
modèle : regression logistique

Encodeur : TFIDF
modèle : regression logistique

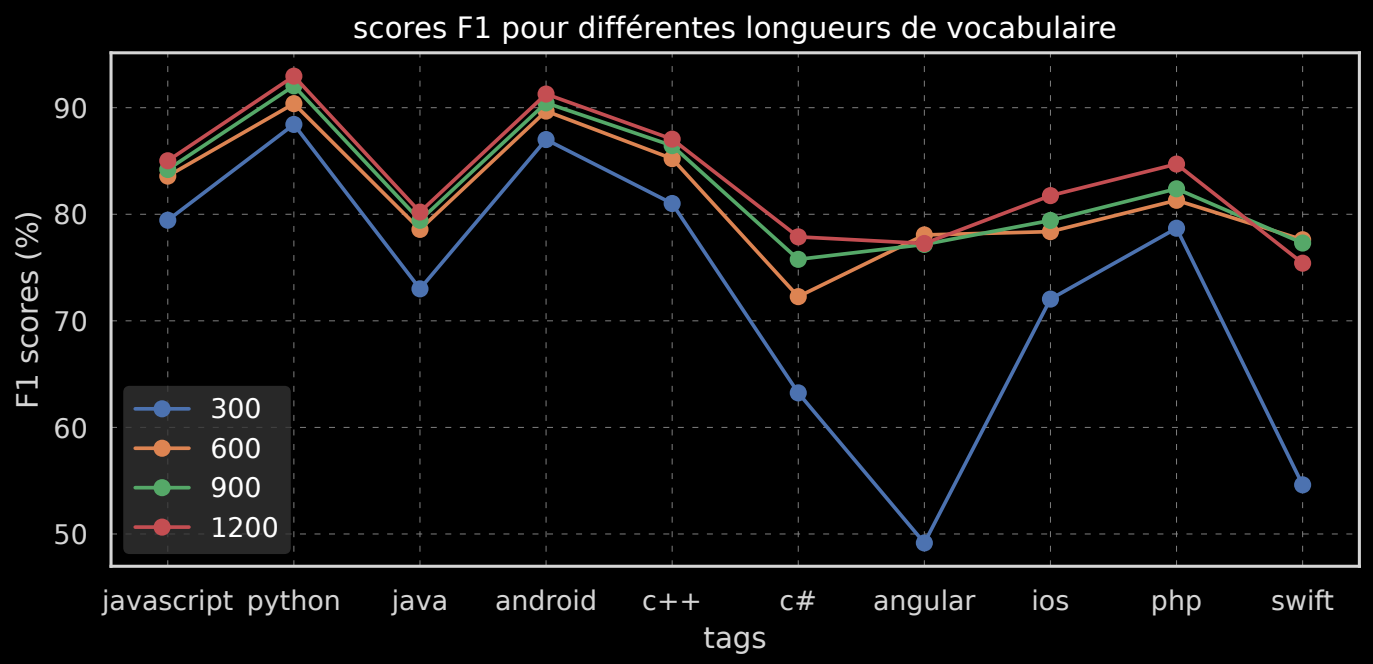

Encodeur : TFIDF
modèle : regression logistique

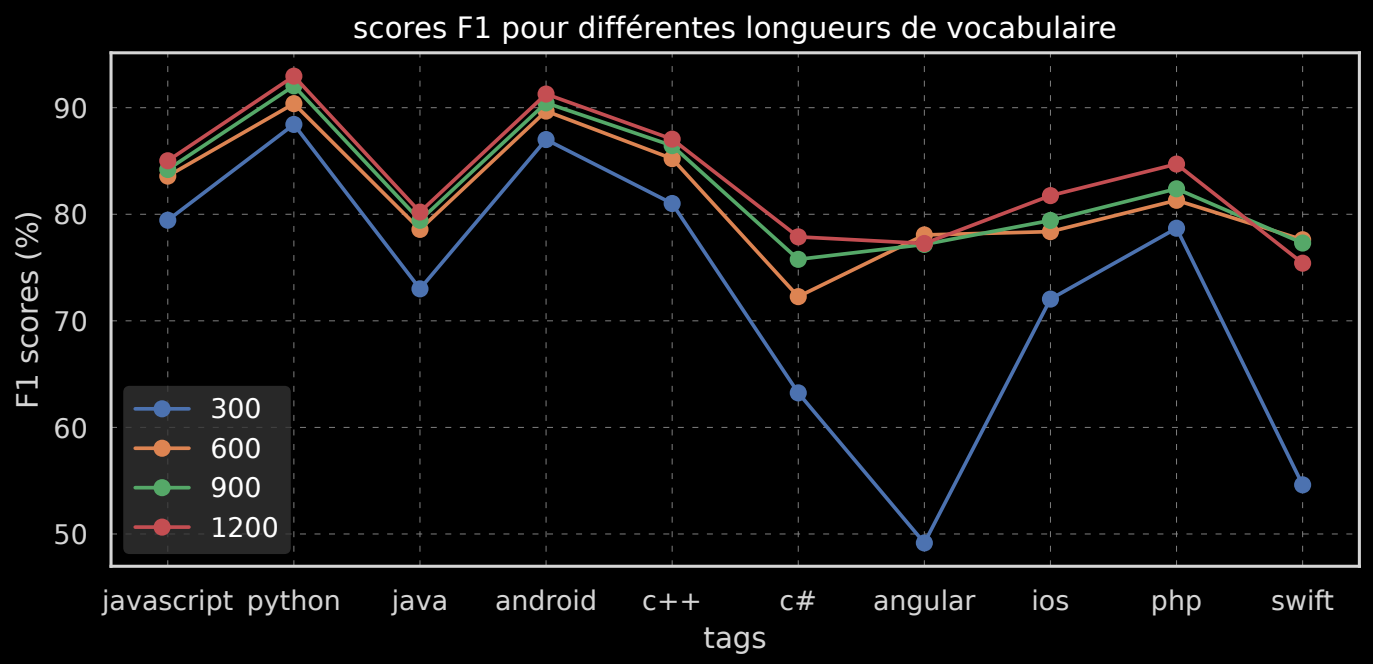

Influence variable selon les tags

ESSAIS DE MODÉLISATIONS

Optimisation du seuil de décision

Optimisation du seuil de décision par tag

Optimisation du seuil de décision par tag

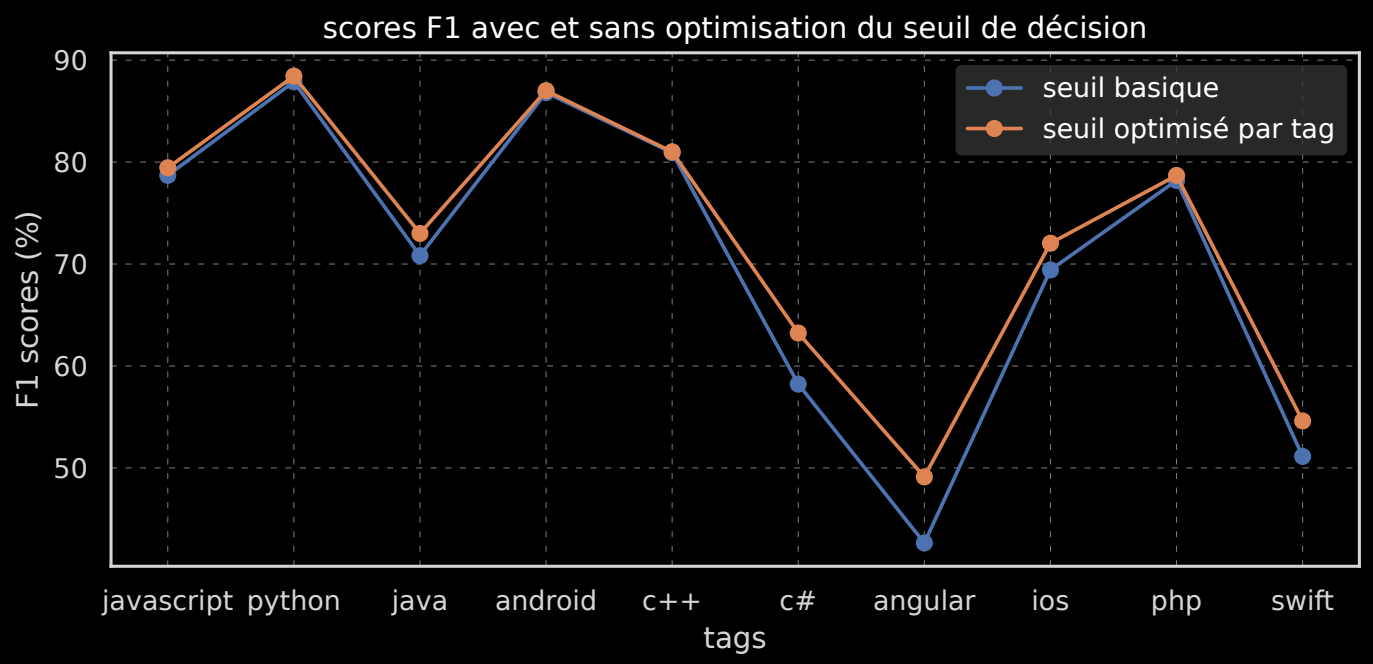

Optimisation du seuil de décision par tag

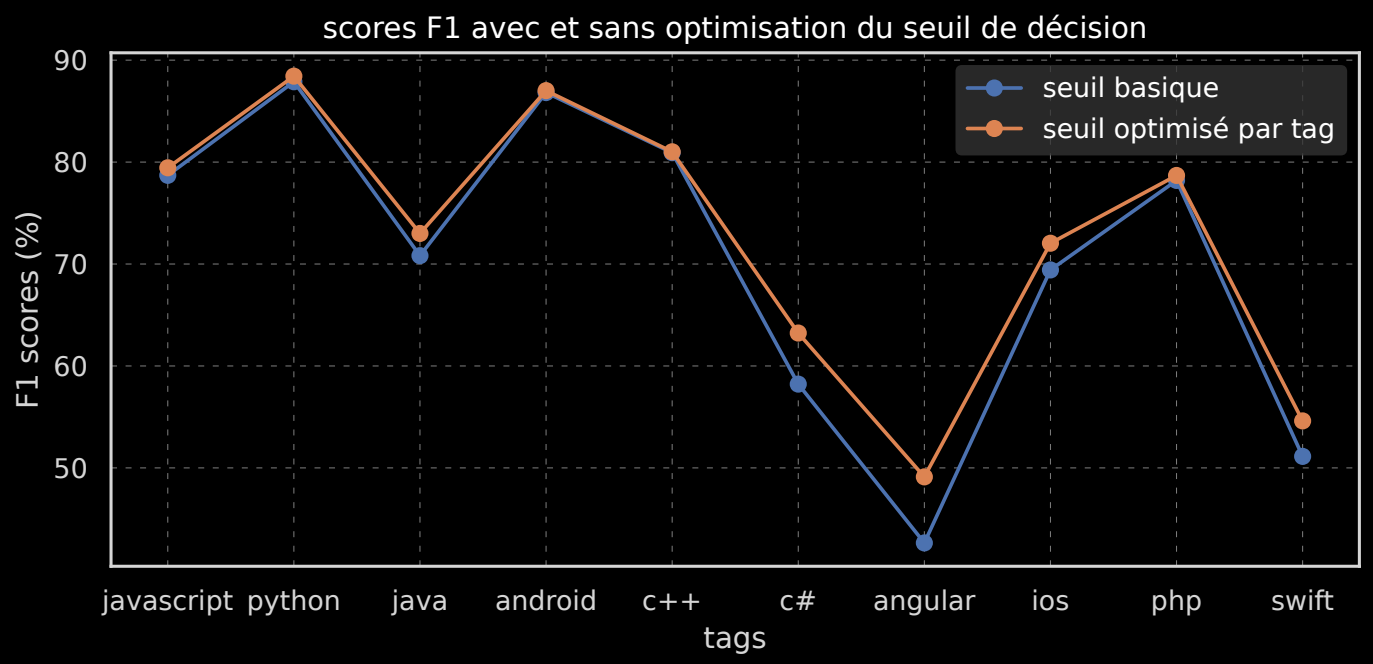

Amélioration intéressante pour les scores les plus bas

ESSAIS DE MODÉLISATIONS

Quel encodeur ?

Différents encodeurs

Différents encodeurs

Méthodes explorées:

Différents encodeurs

Méthodes explorées:

TFIDF (900 mots)

Différents encodeurs

Méthodes explorées:

TFIDF (900 mots)

Word2Vec

Différents encodeurs

Méthodes explorées:

TFIDF (900 mots)

Word2Vec

Sentence BERT

Différents encodeurs

Méthodes explorées:

- TFIDF (900 mots)
- Word2Vec
- Sentence BERT
- Universal Sentence Encoder

Différents encodeurs

Méthodes explorées:

- TFIDF (900 mots) — approche **bag-of-word**
- Word2Vec
- Sentence BERT
- Universal Sentence Encoder

Différents encodeurs

Méthodes explorées:

TFIDF (900 mots)

approche **bag-of-word**

Word2Vec

Sentence BERT

Universal Sentence Encoder

approche
word/sentence embedding

Différents encodeurs

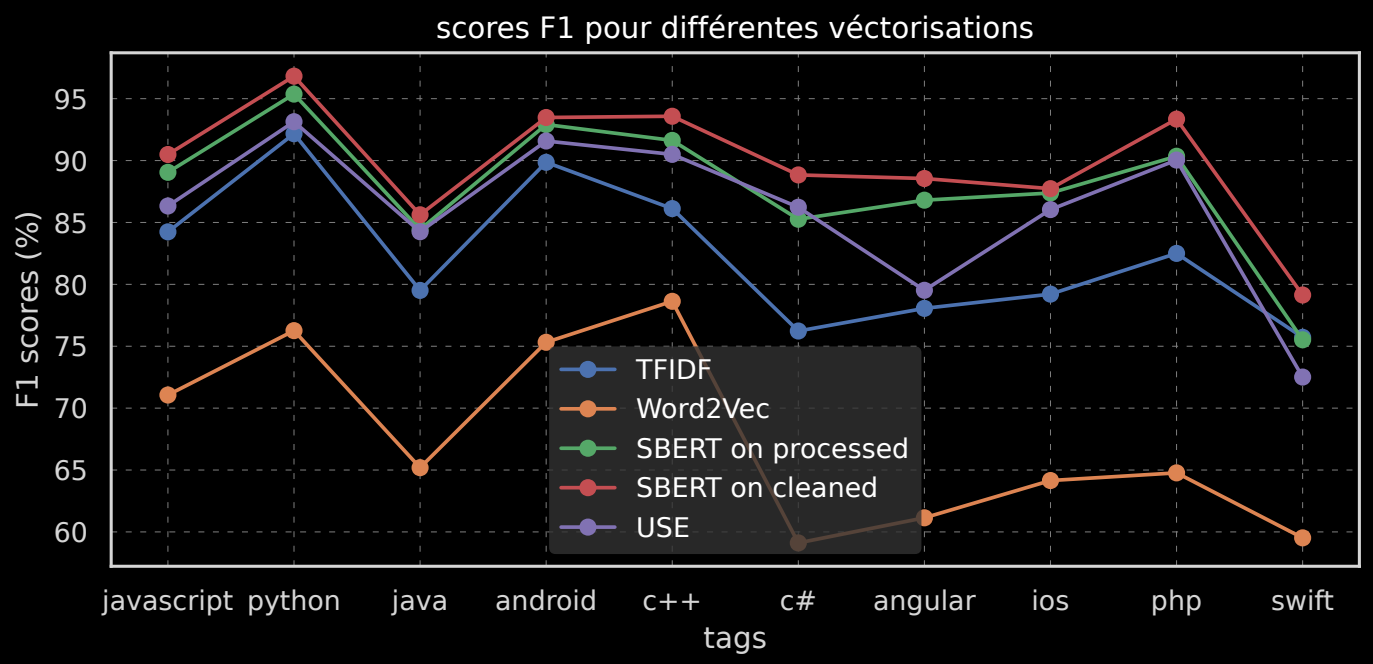

Différents encodeurs

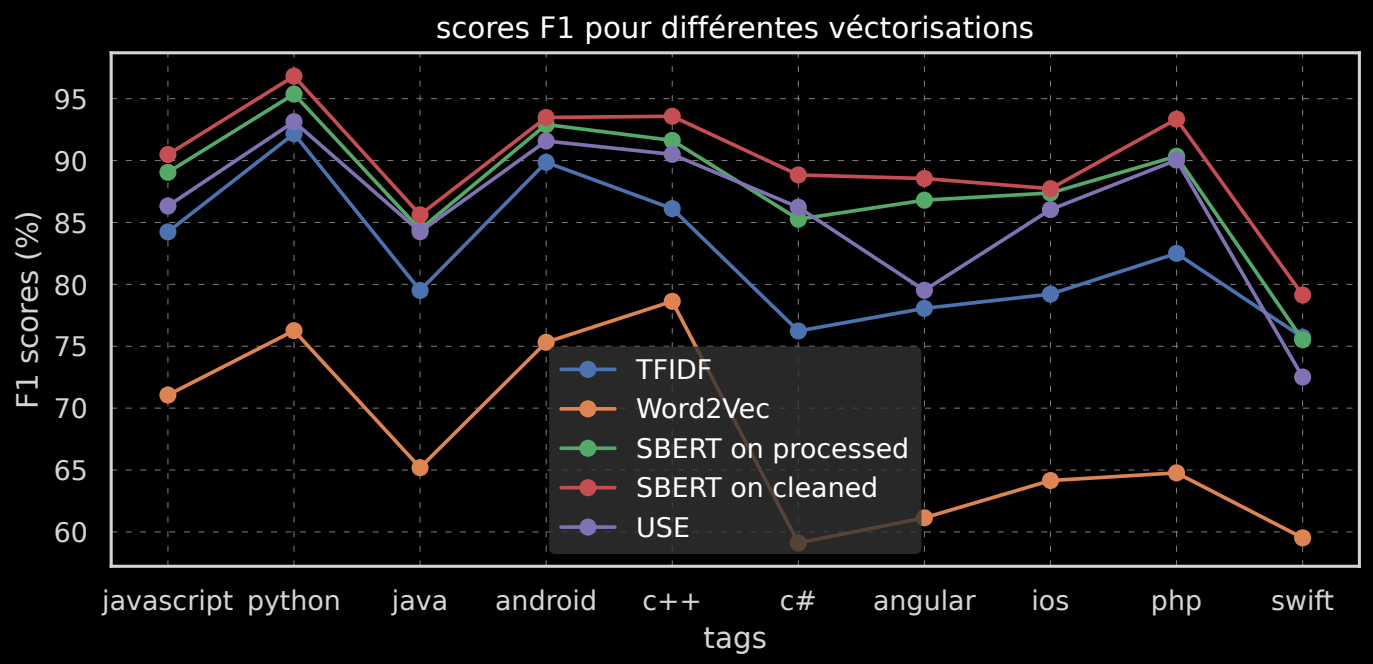

Les **meilleurs résultats** sont obtenus avec **Sentence BERT**

ESSAIS DE MODÉLISATIONS

Conclusions

Conclusions des essais

Conclusions des essais

La **PCA** semble **non appropriée** pour ce projet

Conclusions des essais

La **PCA** semble **non appropriée** pour ce projet

L'encodeur **Sentence BERT** est choisi

Conclusions des essais

La **PCA** semble **non appropriée** pour ce projet

L'encodeur **Sentence BERT** est choisi

La **régression logistique** est sélectionnée comme classifieur

API

Interface de programmation d'application (API)

API servie sous **flask**

Interface de programmation d'application (API)

API servie sous **flask**

Sur un **serveur AWS**

Interface de programmation d'application (API)

API servie sous **flask**

Sur un **serveur AWS**

En utilisant **gunicorn**

Interface de programmation d'application (API)

API servie sous **flask**

Sur un **serveur AWS**

En utilisant **gunicorn**

Démonstration

CONCLUSIONS

Découverte de la **gestion** des **données textuelles**

Découverte de la **gestion** des **données textuelles**

Sélection de la meilleur solution:
Sentence BERT + **régression logistique**

Découverte de la **gestion** des **données textuelles**

Sélection de la meilleur solution:
Sentence BERT + **régression logistique**

Développement d'une
interface de programmation d'application

Découverte de la **gestion** des **données textuelles**

Sélection de la meilleur solution:
Sentence BERT + **régression logistique**

Développement d'une
interface de programmation d'application

Déployement de l'**interface** sur un **serveur AWS**

PERSPECTIVES

Entrainer un **ExtraTrees** sur un **serveur**

Entrainer un **ExtraTrees** sur un **serveur**

Entrainer le modèle à prédir **plus de tags**

Entrainer un **ExtraTrees** sur un **serveur**

Entrainer le modèle à prédir **plus de tags**

Déployement de l'interface sécurisé → **https**

Merci pour votre **attention**.